

目录

第一部分 物质、空间与时间	1
1.1 物质、时间、空间	2
1.2 相互作用	4
第二部分 质点运动学	6
2.1 坐标系与运动的描述	7
第三部分 牛顿力学	10
3.1 牛顿运动定律	11
3.2 动量、角动量与能量	16
第四部分 振动与波	20
4.1 简谐振动与波动方程	21
4.2 机械波的能量与传播	25
4.3 机械波的干涉和衍射	31
第五部分 电磁学	35
5.1 库仑定律到静电场	36
5.2 电流磁效应到静磁场	41
5.3 电磁感应到麦克斯韦方程组	46
5.4 电磁波与电磁场的能量	53
5.5 光也是一种电磁波	58

第六部分 几何光学	61
6.1 光的几何性质	62
第七部分 热力学	65
7.1 分子动理论、理想气体定律和修正	66
7.2 分子分布律和统计规律	72
7.3 热力学定律	78
7.4 熵的规律	83
第八部分 分析力学	86
8.1 虚功原理	87
8.2 拉格朗日方程和作用量变分为零原理	91
8.3 诺特定理	97
第九部分 哈密顿力学	101
9.1 从拉格朗日到哈密顿	102
9.2 泊松括号与正则变换	107
9.3 哈密顿-雅可比方程和刘维尔定理	112

Part I

物质、空间与时间

1.1 物质、时间、空间

不管你是否承认，世界就在那里。

我们的身边有很多东西。随手抓一个什么吧！倘若你抓到一本纸质书，你能看见书是由封皮和内部的纸组成的。仔细看，纸上或许还有纹路。如果我们再仔细一些，或许就能看到一丝一丝的纤维。倘若我们再仔细一些，或许能发现纤维是由一些高分子的物质混合而成的。高分子的物质又是由小分子的物质组成的，进而又可以看到一个一个的原子。原子内部有原子核和电子，原子核内又有质子和中子。质子和中子由夸克和胶子组成，从哲学的角度出发，还能继续往下分。你当然可以认为，这本书是由一层一层的小物质堆积而成的。由此发散，我们不难发现，从小到大，从微观到宏观再到宇观，世界是由物质组成的。

显然，如果你把这本书放在桌子上，推它一下。没有什么阻挡的话，它就会往前去，而你的手就会发生微小的挤压。显然你能感受到这一点。那么，就能够说明，书和你的手，都发生了运动。以此推广，运动是无处不在的。科学观测早就发现，原子会做无规则的热运动。路上的小汽车，能向着某一个方向跑动。我们的地球，有空气的运动，就是所谓的风；有地壳的运动，可能会产生地震（要注意好防护啊！）；有水的运动，就会有潮汐……植物会运动，它们能从土壤里、空气中，吸收它们需要的东西，还能排出废物。动物也会运动。对我们人类来说，除了机械的运动，还有思考的运动（就是大脑内部的细胞的组织的运动），这二者的关系暂且不论，但是运动总是无处不在的。放眼宇宙，月球可以说在绕着地球转，地球在绕着太阳转，太阳系又只是处在银河系中的一个小旋臂上，整个银河系又在做它自己的运动……也就是说，运动是无处不在的。运动是绝对的，而静止不动是相对的，这就是我们的物质的运动观。

怎样衡量一个物体的运动呢？就拿人跑步来说吧。怎样衡量人跑步时相对于地面的这一运动呢？我们都知道，运动会改变位置，进而引入距离、位移的概念。又由于要衡量运动的过程，所以还要引入时间的概念。现在，我们就有办法衡量人跑步的运动了！我们测量出其跑步的距离，同时记录下时间，两数相除，就可以得到平均速度：

$$\bar{v} = \frac{\Delta s}{\Delta t}$$

这样，我们引入的时间就有了作用！又显然，我们的长方体有长有宽有高，延展出去，就有了静止不变的三维平直空间，同样地，这一理论模型的局限性暂且不论。我们就同时引入了空间！因为运动的存在，时间和空间都有了意义。换言之，不包含物质运动的时间和空间没有什么意义。

这三者之间的关系究竟是怎么样的呢？爱因斯坦的相对论给出了答案。他说时空是一个整体，而物质确定了时空呈现什么样的几何性质，时空又会对物质的运动起反作用。爱因斯坦的场方程暂且不说，光是这一认识就足以说明：时空和物质之间的关系是辩证的！不难认识到，既然物质总是处于不断的运动之中的，那么时空的几何性质也是处于不断的改变之中的，这就能看出三维平直时空观念只是在一定条件下的近似，而不是世界的绝对真理了！

时空和物质的运动都不是机械存在的，物质与时空的关系是辩证的！这就是自然辩证法的基本规律！这就是物理学的基本规律！

1.2 相互作用

还是接续说我们推一本纸质书的故事。我们推书，书就往前走，我们的手感到挤压。这就说明，我们的手，收到了来自于书的作用。那么书呢？书往前走了啊！如果我们一直都不推它，它就不会往前走。这就说明书也受到了我们的手的作用。也就是说，书和我们的手接触的时候产生了相互作用！

还有什么相互作用呢？红旗翻飞，是由于风对它的作用；风的方向和速度大小改变了，是红旗对风的作用导致的。人开着车，车对地面有挤压的作用；地面对车就有托举的作用。地球绕着太阳转，是受到了太阳的引力作用；地球对太阳的引力作用会使太阳也轻微移动，只不过不甚明显而已。推广到一切物质上来，相互作用总是普遍存在的。你对我有作用，我对你也不是没有。这样的两个方面就会形成矛盾。由于相互作用是普遍存在的，所以我们说这样的矛盾也是普遍存在的。

然而，矛盾与矛盾之间又有不同。我们不能认为，我们的手推书时的矛盾和地球绕着太阳转的矛盾能够称作同一种矛盾。手推书显然是宏观上接触了的，而地球和太阳显然隔得很远。这就说明，矛盾与矛盾之间亦有不同。所以我们说矛盾也是具有特殊性的。

研究相互作用，必须要客观地、全面地研究矛盾着的两个方面。要研究地球的绕着太阳转的运动，就要知道双方的相互作用力——相互的万有引力：

$$F = G \frac{Mm}{r^2}$$

正因为有了万有引力，地球才能在自身惯性的基础上做椭圆运动，太阳的运动也才受到微小的扰动。只认为地球在做椭圆运动，而不认为太阳在宇宙中的运动也会受到地球的影响的，就陷入了形而上学的观念了。但是这并不意味着我们在分析地球的运动的时候，一定要把别的星球的运动加上去。如果我们确定分析的就是地球的这一运动，那么别的星球（比如月球）对地球的影响就不那么重要了。这就说明我们一定要抓住影响事物本质的主要矛盾，不能揪着次要矛盾不放。当然，这里并不是说一定不能考虑月球的影响，而是大多数时候，不甚精确地研究的时候，主要的矛盾就只有太阳和地球的矛盾。如果要求更加高一些，那么主要矛盾就同时包括太阳和地球、地球和月球之间的矛盾了。同时也要注意，如果研究的是地球的公转，那么主要影响的是太阳的引力，月球的引力是次要的；如果研究的是地球的潮汐、自转轴，那么月球的引力就是主要的，而太阳的引力就是次要的了。所以我们就说，主要的矛盾里面也有主要的方面和次要的方面，而且主要的方面和次要的方面并不是一成不变，而是可以互相转化的。

就像太阳和地球互相吸引，同时作用于对方一样，以相互作用为代表的矛盾，其中的两个方面总是同时存在的，并且其地位和性质也可以互相转化，这种就叫做矛盾的同一性。而这两个方面总是在不断地互相影响，不断地对对面的地位和性质进行改变，这种就叫矛盾的斗争性。

相互作用的本质是矛盾！相互作用的方面正是矛盾的方面。相互作用的规律，正是矛盾的规律。这就是物理学研究相互作用的矛盾的分析法！

Part II

质点运动学

2.1 坐标系与运动的描述

在我们的空间中，一个物体，如果其大小和形状并不在我们考虑的范围之内，其自身又不存在自转，我们就可以简单地把它模型化来方便我们的研究。这样的模型就叫做质点。

简单地，我们考虑三维平直空间，建立直角坐标系 $Oxyz$ 。那么，质点处在这个空间中的位置必定可以用坐标来表示。从原点 O 到质点（记作 P ）的向量就是以 P 点坐标为对应坐标的向量，向量又叫作矢量。也就是：

$$\vec{OP} = (x, y, z)$$

我们管这样的向量叫做质点 P 的位矢。显然，对于运动着的质点 P 来说，必定会有速度这样一个物理量。很容易能理解，速度肯定具有大小。然而，对于某一个瞬间的运动，速度当然只能朝着某一个方向去。也就是说，速度是同时具有大小和方向的矢量。考虑极小时间内的运动，肯定运动的位移也极小。用这一极小的位移去除以极小的时间，在时间趋于无穷小的时候，就得到了某时刻的瞬时速度，这就叫作对时间 t 求了一次导数。三个坐标方向都是一样，组合起来就得到了空间中运动质点的速度：

$$\vec{v} = \frac{dx}{dt}\vec{i} + \frac{dy}{dt}\vec{j} + \frac{dz}{dt}\vec{k}$$

继续考虑对速度的变化进行分析和描述，不难想到，再对时间 t 求导一次，得到加速度：

$$\vec{a} = \frac{d^2x}{dt^2}\vec{i} + \frac{d^2y}{dt^2}\vec{j} + \frac{d^2z}{dt^2}\vec{k}$$

如果你还想要继续描述加速度的变化，还可以继续求导，这里就不过多说明了。

矢量是同时具有大小和方向的。缺失了大小，只有方向，则不知道在描述什么；缺失了方向，只有大小，就会显得混乱，甚至退化成标量。有些时候，单独地计算出矢量的大小，再人为的用语言指出它的方向的描述方法是可行的。但是这样的描述方法往往会落入“大小是严格计算，而方向则是主观判断”的嫌疑之中。在连续计算的过程中，很有可能会使得方向的描述陷入混乱；哪怕最后能够找到正确的方向，这结论的来源过程也显得非常的主观，甚至常常落入唯心主义的范畴。并且这样的表述方法，人为地把矢量的大小和方向——两个辩证统一的属性——割裂开了。哪怕步骤不甚多的时候，能够有效地进行描述，也显得非常的机械和繁琐。像这样的如果能够正确的对物质进行分析的，我们就称之为形而上学的唯物主义，而并非辩证的唯物主义。如果连正确的分析都故意不能够做到，那么就变成了唯心主义。

其实辩证唯物主义的表示方法呢，已经在上文给出了。在这样的利用直角坐标系进行的描述中，矢量的大小和方向都被统一在了坐标里。同一个式子既能够简洁地描述其大小，又能够准确地描述方向。大小和方向就被辩证地统一在了矢量坐标式中。

对具体问题进行具体分析，显然有些质点的在平面上的运动大致上能够近似于圆（暂时不去考虑这些运动跟圆周运动究竟有什么关系）。确定 Ox 轴，那么原点和 Ox 的正方向均确定了。从 Ox 轴逆时针旋转，直到与 O 到 P 的射线重合，这样转过的角度就是正数，记作极角 θ 。 O 到 P 的线段长度，记作极径 ρ 。于是我们就得到了一组描述质点 P 位置的新的数据，记作坐标对： (ρ, θ) 。

规定两个矢量：从 O 到 P 伸长极径的单位矢量 $\vec{e}_\rho$ ，逆时针旋转的单位矢量 $\vec{e}_\theta$ 。通常 ρ 是关于 θ 的函数，而 θ 又是关于时间 t 的函数。所以可以对时间 t 求导得到速度：

$$\vec{v} = \dot{\rho}\vec{e}_\rho + \rho\dot{\theta}\vec{e}_\theta$$

再次求导得到加速度：

$$\vec{a} = (\ddot{\rho} - \rho\dot{\theta}^2)\vec{e}_\rho + (\rho\ddot{\theta} + 2\dot{\rho}\dot{\theta})\vec{e}_\theta$$

观察这个式子，不难发现，在伸长极径的方向上和逆时针旋转的方向上（也就是单位向量前的系数里）都同时存在着极角和极径的量。你中有我，而我中有你，这就体现了二者的联系；求导的过程则体现了二者的发展过程。这就是辩证唯物主义的质点运动的描述方法。

为什么直角坐标系没有这样的特性呢？在刚才的内容中，我们不难发现直角坐标系的三个单位向量都是静止的固定的，并不随着空间中质点的运动而进行改变。虽然说，直角坐标系的表述方式，相对于直接用语言描述大小和方向更加的辩证，但是二维的极坐标系以及其推广得到的三维的柱坐标系和球坐标系，比起二维或是三维的直角坐标系都显得更加辩证和科学。

以上的坐标系都建立在欧几里得的平直时空的基础上。如果放弃欧几里得第五公设，会得到更一般的非欧几何；在此基础上进一步引入时间维度，就得到闵可夫斯基几何，再推广就得到了黎曼几何（虽然历史上先有的黎曼几何，而闵可夫斯基几何是它的一个特例）。由于这两种几何都需要大量的篇幅描述，否则难以理解，所以我们在这里不过多说明。我们只需要知道，闵可夫斯基几何是狭义相对论的基础，而黎曼几何是广义相对论的基础，这两种都更加辩证和贴合实际就可以了。

由此我们就可以认识到三次飞跃：从语言描述矢量的大小和方向到直角坐标系，是第一次飞跃；再到极坐标系、球坐标系、柱坐标系是第二次飞

跃：最后到闵可夫斯基几何和黎曼几何是第三次飞跃。每一次飞跃都意味着辩证和科学的程度有了极大的加深，贴合实际的程度也加大的发展。这就体现了辩证唯物主义的联系的观点和发展的观点。这就不断的完善了参考系和运动的描述体系。

Part III

牛顿力学

3.1 牛顿运动定律

我们还是从那本书说起。

你把它放在桌上，推它一下，它往前滑了一段，然后停下来了。相同的距离，你推的力气越大，它滑得越远；力气小一些，滑得就近一些。这个现象我们从小就知道，熟悉到几乎不会再去想它。但你有没有想过一个问题：书为什么停下来？你可能会说：因为我不推它了啊。手离开之后，没有力推它了，它自然就停了。这个回答看起来天经地义。古希腊的亚里士多德也是这么想的。他观察身边所有的运动——木车、石块、抛出去的球——发现都是这样：推着就动，不推就停。于是他总结说：力是维持运动的原因，没有力就没有运动。这个说法统治了西方科学将近两千年，因为它确实符合大多数人的日常经验。

但是，我们再仔细想一想。书停下来，真的是因为“没有力推它”吗？试试看，把书放在一个更光滑的表面上——比如玻璃桌面。你推它一下，它是不是滑得更远了？如果再光滑一些，比如冰面，它是不是还要滑得更远？如果有一种表面，光滑到完全没有摩擦，也没有空气来阻挡它，你把书推一下之后撒手，它会怎么样？它不会停下来，它会一直滑下去。我们平时看到“不推就停”，是因为有摩擦力、空气阻力这些看不见的力在起作用。手离开之后，书并不是“没有受力”，而是受到了摩擦力这个阻力。这也就是说，真正让它停下来的，不是“没有推力”，而是“有阻力”。如果没有阻力，它根本不需要力来维持运动。这就引出一个与日常直觉相反的结论：运动本身不需要力来维持。这是物体普遍具有的一种性质。这种性质就叫作惯性。质量越大的物体，惯性越大，越不容易改变它的运动状态——在相同的条件下，推一辆卡车比推一辆自行车费劲得多，就是因为卡车的惯性大。

但是，这里有一个问题。“没有外力的时候，物体保持静止或匀速直线运动”，这个说法成立的前提是，我们得知道什么是“没有外力”。显然相互作用是普遍存在的，也就是说外力是普遍存在的，但是倘若我们能够忽略次要矛盾的影响，只考虑主要矛盾，那么就能够说没有外力。而且还有一点要注意的是，我们得知道我们是在什么样的参考系里说这句话。

你坐在一辆正在加速的公交车里，看到座位上的一只背包自己往后滑动，但是没有人推它。这是因为书包具有惯性，要保持原来的运动状态，因此相对于车厢向后滑。你坐着的那个车厢本身就不是一个“惯性系”。你在加速的参考系里看东西，不受力的物体也会自己动起来。所以牛顿第一定律其实在做一件更根本的事情：它在告诉我们，存在这样一类参考系，在这样的参考系中，不受力的物体确实会保持静止或匀速直线运动。这类参考系就叫惯性参考系。

在惯性参考系里我们就可以忽略次要矛盾了。地面附近就可以近似地看作一个惯性系。但是，由于地球在自转，地球本身也不是严格的惯性系——你在赤道上放一个不受力的物体，它并不会相对于地心做匀速直线运动，而是会随着地球一起转动。只有在那些相对于遥远恒星没有转动的参考系里，惯性定律才能相对严格地成立。只有在惯性参考系里，后面要说的牛顿第二定律才能成立。第一定律不是在说第二定律的一个特例，而是在给整个牛顿力学划定舞台——没有这个舞台，后面的定律就没法搭起来。你找不到一个不受力的物体，也找不到一个严格的惯性系，但这不妨碍我们通过理想化抽象出“惯性”这个概念，也不妨碍我们在越来越好的近似中逼近惯性系——这是从现象中把握本质、从相对中逼近绝对的过程。

现在，我们选定了惯性参考系——比如近似地把地面当作惯性系——然后回到那本书上。你推书的时候，书从静止开始动起来，速度从零变成了某个值，这说明它的运动状态发生了改变。改变得有多快呢？如果从静止加速到某个速度用的时间很短，我们就说它改变得快；用的时间长，就改变得慢。这个“改变得快慢”就是加速度。你可能会发现，同样一本书，你用力大一些，它加速就快；用力小一些，加速就慢。换一个东西呢？比如你推一辆自行车和推一辆卡车，用同样大的力，自行车加速快，卡车加速慢——因为卡车的惯性大，更难改变它的运动状态。把这两层关系放在一起，就得到了一个规律：力等于质量乘以加速度，即

$$\vec{F} = m\vec{a}$$

但这个写法其实默认了质量是不变的。更一般的情况是，力改变的是物体的动量，动量就是质量乘以速度，写成

$$\vec{p} = m\vec{v}$$

力究竟改变了什么？它改变的是动量，而不是简单的速度。如果质量不变，动量变化率就体现在速度变化率上，也就是 $m\vec{a}$ ；但如果质量也在变——比如火箭一边飞一边往外喷燃料——那么力同样在改变动量，只是不能简单地说是“质量乘以加速度”了。所以牛顿第二定律更一般的形式是：

$$\vec{F} = \frac{d\vec{p}}{dt}$$

也就是说，力等于动量的变化率。这个式子不分质量变不变，都成立。如果质量是常数，把它提到微分符号外面，就回到了

$$\vec{F} = m\vec{a}$$

你看，这个式子把三个东西连在了一起：力、动量、时间。动量本身又是质量与速度的乘积——质量是物质惯性大小的量度，速度是运动状态的表征，二者合起来就是“运动的量”。力不是凭空起作用的，它必须在一段时间里持续作用，才能改变动量。你推书的那一下，虽然时间很短，但毕竟不是零；你持续推一本书，它就持续加速。力、动量、时间，这三个概念不是在孤立中定义的，而是在这个关系式中互相规定、互相联系。没有时间，就谈不上力的作用；没有动量，力就失去了作用的对象；没有力，动量就不会改变。这就是联系的观点——不是我们事后把“联系”这个概念贴上去，而是这个物理规律本身呈现出来的就是事物之间的内在联系。

现在再来看看手和书的关系。你推书的时候，手对书有一个力，书被你推动了。但你的手有没有感觉到什么？手被书顶回来了，感觉到挤压。也就是说，书也对手施加了一个力。你推得越用力，书推回来的力也越大。这两个力方向相反——你推书向前，书推你向后。这就引出了牛顿第三定律：两个物体之间的作用力和反作用力总是大小相等、方向相反，作用在同一条直线上。用向量写出来就是：

$$\vec{F}_{\text{手} \rightarrow \text{书}} = -\vec{F}_{\text{书} \rightarrow \text{手}}$$

注意，这两个力虽然大小相等、方向相反，但它们不会互相抵消。因为它们作用在不同的物体上——一个作用在书上，一个作用在手上。书受到的合力是手给它的那个力（如果忽略摩擦力的话），所以书会加速向前；手受到的合力是书给它的那个力加上别的东西（比如你的胳膊拉着它），所以手不会无限后退，而是感觉到一个挤压。

这里呈现出来的，就是矛盾的两个方面。手对书的力和书对手的力，这两个方面同时存在、互为前提——没有手推书，就没有书推手；没有书推手，手推书也无从谈起，因为手摸到的是空的。它们性质相同——都是弹力；它们方向相反——一个朝前，一个朝后；它们作用在不同物体上，各自改变对方的运动状态。这不就是矛盾吗？不是我们把“矛盾”这个概念硬塞进来，而是力的相互作用本身就是一对矛盾——两个对立着的方面，在同一次相互作用中同时产生、相互依存、相互对抗。这就是矛盾在物理学中的直接呈现。没有这种矛盾，就没有运动状态的改变——如果手推书而书不推手，那手就会毫无阻碍地穿过去，书纹丝不动；如果书推手而手不推书，那书自己就会飞起来。正是这对矛盾，才让运动状态的变化得以发生。

现在我们再回头看一下第一定律。第一定律说存在惯性系，在惯性系中不受力的物体保持静止或匀速直线运动。这个“保持”就是惯性的体现——物质自身就有维持运动状态不变的属性。但这个属性不是孤立地起作用的，它必须通过具体的物理情境才能被认识到：在惯性系中，我们观察到物体在

没有外力时状态不变，由此我们抽象出惯性这个概念。而惯性的大小——质量——又在第二定律中作为抵抗加速度的量出现。你看，第一定律和第二定律不是孤立的：第一定律定义了惯性系，给了我们讨论问题的舞台；第二定律给出了在这个舞台上，力、质量、加速度之间的定量关系。没有第一定律，第二定律里的 $\vec{F} = m\vec{a}$ 就不知道在哪个参考系里成立；没有第二定律，第一定律就只是一个定性的描述，无法进行定量计算。它们相互依存、相互补充，共同构成了对物质运动的完整描述。

如果我们在一个非惯性参考系里——比如在刚才说的那辆加速前进的公交车里——能不能也用牛顿第二定律来分析问题呢？可以，但要加一个修正。你在公交车上看到那只背包自己往后滑，如果非要用牛顿第二定律来描述，就得认为背包受到一个向后的力。但这个力不是任何物体施加给它的——没有谁在推它——它纯粹是因为你选的参考系本身在加速而“冒出来”的。这种力叫作惯性力。在非惯性系里，如果我们想在形式上保留 $\vec{F} = m\vec{a}$ 这个写法，就得在真实力之外再加一项惯性力。设非惯性系相对于某个惯性系的加速度为 $\vec{a}_0$ ，那么在一个质量为 m 的物体上，惯性力就是 $-m\vec{a}_0$ ——方向与参考系的加速度方向相反。你在公交车上，车向前加速，惯性力就向后，而且摩擦力不足以抵消这个惯性力，所以背包向后滑。你在一个转动的圆盘上，会感到一种往外甩的力，那叫离心力，也是一种惯性力。这些力在惯性系里看根本不存在，但在非惯性系里，它们却是可感的——你坐过山车的时候身体被压在座椅上，那种感觉不是别的物体在推你，而是你的身体在非惯性系里受到的惯性力。

这里又出现了一种关系：惯性系和非惯性系的关系。同一个物理过程，在惯性系里看是一种描述，在非惯性系里看是另一种描述，但背后的客观实在——物体之间的真实相互作用——是不变的。惯性系不是绝对静止的某种神秘背景，而是一类特殊的参考系，在其中物理规律具有最简单的形式。非惯性系则是通过加速度与惯性系联系起来。没有绝对的参考系，只有相对的、在相互联系中定义的不同参考系。而牛顿第一定律所定义的惯性系，本身就是一个理想化的极限概念——我们在现实中找不到绝对的惯性系，但我们可以在越来越好的近似中逼近它。这是从相对中把握绝对、从现象中把握本质的过程。惯性力没有反作用力，这反而让我们更清楚地认识到什么是真实的相互作用——真实的力总是成对出现的，是物质之间实实在在的相互作用；惯性力没有反作用力，因为它不是物质之间的相互作用，而是参考系选择带来的“副产品”。正是通过这种对比，我们对“力”这个概念的理解才更加深入、更加全面。

你看，牛顿运动定律不是三条孤立的命题。第一定律划定了舞台——惯性参考系，同时揭示了物质自身保持运动状态不变的属性（惯性）；第二定

律在这个舞台上给出了力与运动之间的定量关系，把力、动量、时间联系在一起；第三定律揭示了力的相互作用本质，把一对矛盾摆在了我们面前。而当我们把目光从惯性系扩展到非惯性系时，惯性力的出现又反过来让我们更深刻地理解什么是惯性系、什么是真实的力。这些概念不是孤立定义的，它们是在相互联系、相互规定中构成一个整体的。第一定律离不开第二定律——没有第二定律的定量描述，惯性就只是一个空洞的词语；第二定律离不开第一定律——没有惯性系，第二定律就不知道在哪里成立；第三定律又和第二定律紧密相连——没有第三定律，第二定律中的力就成了无源之水。这就是联系和发展的观点在物理学中的具体呈现。我们从推书这个再平常不过的事情出发，一路走下来，看到的不仅是一条条定律，更是物质世界自身的辩证结构——惯性是物质自身的属性，但在与外力的关系中才能被认识；力是物体之间的相互作用，必然以矛盾的形式成对出现；参考系是描述运动的前提，而惯性系本身就是从非惯性系中通过理想化抽象出来的。这些关系不是我们事后贴上去的哲学标签，而是物理学本身向我们展示的——物质世界就是这样联系着的、发展着的。

3.2 动量、角动量与能量

我们就从滑冰说起。

一个人在光滑的冰面上滑行，不用蹬冰就能一直匀速前进，这是惯性。蹬冰，就加速；相撞，速度就变；旋转，收拢手臂就变快；摩擦，就慢慢停下。这些过程都不是一瞬间完成的，都有力的持续作用。牛顿定律告诉我们某时刻力和加速度的关系，但要理解运动是怎样传递、怎样保存、又怎样转化的，我们必须看力的积累效果。

我们先看力在时间上的积累。两个静止在冰面上的人，互相一推，就会向相反的方向滑出去。质量大的人滑得慢，质量小的人滑得快；如果两个人质量一样，滑出去的速度就大小相等。经过研究，我们很容易发现，不管两个人质量和速度怎么分配，质量乘以速度的总和，在推之前和推之后是一样的。推之前总和是零，推之后一个正一个负（如果我们提前规定了某一个方向为正方向的话），加起来还是零。

这个质量乘以速度的量，就是动量 $\vec{p} = m\vec{v}$ 。它不是我们凭空定义的，是从碰撞和相互作用中自然浮现出来的不变量。只有这个量，能准确描述物质的运动，能在相互作用中从一个物体转移到另一个物体，而总量保持不变。

上一节我们已经得到，牛顿第二定律最普遍的形式是

$$\vec{F} = \frac{d\vec{p}}{dt}$$

它直接告诉我们，力的作用就是改变物体的动量。把这个式子在一段时间上积分，就得到

$$\int_{t_1}^{t_2} \vec{F} dt = \vec{p}_2 - \vec{p}_1$$

左边是力在时间上的积累，叫作冲量。这个式子就是动量定理：冲量等于动量的变化量。

如果我们把相互作用的两个滑冰者看成一个整体，他们之间的推力是内力。根据牛顿第三定律，作用力和反作用力大小相等、方向相反，作用时间完全相同，所以它们的冲量也大小相等、方向相反，加起来正好抵消。内力只能让动量在两个人之间转移，不会改变系统的总动量。只有来自系统之外的外力，才能改变总动量。当系统不受外力，或者合外力为零时，总动量保持不变，这就是动量守恒定律。

我们再来看转动。花样滑冰运动员旋转的时候，张开手臂转得慢，一收拢手臂，转速立刻就快了。这个现象用动量是解释不了的，因为运动员的总动量始终为零。我们需要一个新的量，来描述绕某一点转动的运动量。

一个物体绕某一点转动的效果，不仅和它的动量有关，还和它到转轴的距离有关。所以描述转动的量，必须同时包含位置矢量 $\vec{r}$ 和动量 $\vec{p}$ 。唯一能同时满足矢量性质和转动效果的组合，就是它们的叉积

$$\vec{L} = \vec{r} \times \vec{p}$$

这个量就是角动量。

相应地，改变角动量的不是力，而是力矩。力矩是力和位置矢量的叉积

$$\vec{M} = \vec{r} \times \vec{F}$$

和力改变动量完全对应，力矩改变角动量

$$\vec{M} = \frac{d\vec{L}}{dt}$$

这就是角动量定理。当系统所受的合外力矩为零时，角动量保持不变，这就是角动量守恒定律。

运动员旋转的时候，冰面的摩擦力矩很小，可以忽略，所以角动量守恒。在农业作业中，常常会用到带有高速运转的传动轴的机器。在我们关闭电源后，由于阻力的力矩很小，传动轴几乎还是角动量守恒的，这时候如果我们不小心触碰到传动轴，就会发生严重的安全事故，所以一定要注意等它完全停止了才能靠近。现在来看，为什么手臂的收放会改变转速。把运动员看成由无数个小质点组成的整体，每个质点的角动量都是 $\vec{r}_i \times m_i \vec{v}_i$ 。对于绕固定轴转动的物体，每个质点的速度 $\vec{v}_i = \vec{\omega} \times \vec{r}_i$ ，其中 $\vec{\omega}$ 是整个物体共同的角速度。把这个代入角动量的表达式，每个质点的角动量大小就是 $m_i r_i^2 \omega$ 。把所有质点的角动量加起来，整个物体的总角动量就是

$$\vec{L} = \left(\sum m_i r_i^2 \right) \vec{\omega}$$

括号里这个只和质量分布有关的量，就是转动惯量，记作 $I = \sum m_i r_i^2$ 。于是角动量可以写成和平动动量完全对应的形式

$$\vec{L} = I \vec{\omega}$$

平动里，质量 m 是惯性的量度，质量越大，越难改变平动状态；转动里，转动惯量 I 是转动惯性的量度，转动惯量越大，越难改变转动状态。这两个动量的形式具有高度的相似性，体现了平动和转动之间的联系。

现在就清楚了：运动员张开手臂，质量分布离转轴远， r_i 大，转动惯量 I 就大；收拢手臂，质量分布靠近转轴， r_i 小，转动惯量 I 就小。因为角动量

守恒，所以 I 变大， ω 就变小； I 变小， ω 就变大。这就是转速变化的根本原因。

现在看力在空间上的积累。你蹬冰的时候，力不仅作用了一段时间，还让你的身体移动了一段距离。力在位移方向上的积累，就是功。只有沿着位移方向的力，才会改变运动的快慢；垂直于位移方向的力，只会改变运动的方向，不会改变快慢。所以功的定义是力和位移的点乘 $W = \vec{F} \cdot \vec{s}$ 。把牛顿第二定律代入，我们可以严格推导出功的效果。对于一个微小的位移 $d\vec{r}$ ，力做的功是

$$dW = \vec{F} \cdot d\vec{r} = m \frac{d\vec{v}}{dt} \cdot d\vec{r} = m\vec{v} \cdot d\vec{v} = d\left(\frac{1}{2}mv^2\right)$$

积分之后就得到

$$W = \frac{1}{2}mv_2^2 - \frac{1}{2}mv_1^2$$

右边这个只和质量与速度有关的量，就是动能

$$E_k = \frac{1}{2}mv^2$$

这个式子就是动能定理：合外力对物体做的功，等于物体动能的变化量。

对于转动，同样有力矩做功。根据右手螺旋定则，我们可以把微角位移定义为沿转轴方向的矢量 $d\vec{\theta}$ ，力矩在角位移上的积累是

$$W = \int \vec{M} \cdot d\vec{\theta}$$

把 $\vec{M} = I\vec{\beta} = I\frac{d\vec{\omega}}{dt}$ 代入，就能推导出它对应的是转动动能的变化

$$W = \frac{1}{2}I\omega_2^2 - \frac{1}{2}I\omega_1^2$$

平动和转动，再一次呈现出完美的对应。

动能是物体因为运动而具有的能量。但还有一种能量，不是因为运动，而是因为物体之间的相互作用和相对位置而具有的，这就是势能。滑冰者从一个小坡上滑下，高度降低，速度增大，位置的变化转化为运动的变化；向上滑，则运动的变化转化为位置的变化。

我们发现，重力做功只和初末位置的高度差有关，和运动的路径无关。不管你是直接滑下来，还是绕个弯滑下来，重力做的功都是一样的。具有这种性质的力，叫作保守力。只有保守力，才能定义势能。保守力做的功，等于势能变化的负值

$$W_{\text{保}} = -\Delta E_p$$

这里必须明确：势能不是单个物体的属性，而是相互作用的系统的属性。重力势能是滑冰者和地球共有的，没有地球的引力，就没有重力势能。孤立的物体，不可能有势能。

当只有保守力做功时，动能和势能相互转化，总量保持不变，这就是机械能守恒。当有摩擦力这样的非保守力做功时，机械能会减少，但减少的机械能并没有消失，而是转化成了内能。冰刀和冰面摩擦的地方会微微发热，就是这个道理。在了解场的时候，我们也会进一步知道场自己也有能量。

无数的实验证明，所有形式的能量——机械能、内能、电磁能、化学能、核能——都可以相互转化，而总能量始终保持不变。这就是能量守恒与转化定律。

到这里，我们得到了三条守恒定律：动量守恒、角动量守恒、能量守恒。很长一段时间里，人们以为这三条定律是经典力学的推论，是牛顿定律的副产品。直到诺特定理的提出，我们才真正理解了它们的本质。

诺特定理说的是：自然界中每一种连续的对称性，都必然对应一条守恒定律。什么是对称性？对称性就是物理规律在某种变换下保持不变的性质。

空间平移对称性，就是说物理规律不会因为空间位置的改变而改变。你在冰场的这头做实验，和在那头做实验，得到的结果是完全一样的。这种对称性，对应的就是动量守恒定律。

空间转动对称性，就是说物理规律不会因为空间方向的改变而改变。你把实验装置转一个角度，得到的结果还是一样的。这种对称性，对应的就是角动量守恒定律。

时间平移对称性，就是说物理规律不会因为时间的改变而改变。你今天做实验，和明天做实验，得到的结果还是一样的。这种对称性，对应的就是能量守恒定律。

守恒律是普遍存在的，这与牛顿力学是否适用没有什么关系。这就说明，这样的矛盾是普遍存在的。而守恒律互相之间描述的内容又有不同，也就是矛盾具有特殊性。我们对具体的问题做具体的分析，就要使用合适的守恒定律。牛顿定律揭示了物质运动过程的互相联系，守恒律又揭示了物质运动的发展过程。从瞬时到连续，从特殊到一般，我们得到了更普遍的规律。

Part IV

振动与波

4.1 简谐振动与波动方程

弹簧是我们生活中熟悉的机械零件，想必对于弹簧的性质每个人都能说出一两点吧。很显然，如果我们按压一个小弹簧，弹簧会变短，手也能感受到弹簧施加的推力；拉伸它，它变长，手也能感受到弹簧的拉力。能够发现，弹簧给你的力总是朝着恢复自由长度，也就是初始长度的方向。这样的力就叫做回复力。如果弹簧上连接了物体，就容易形成周期性的振动。观察任意一个这样的振动，如果物体在振动的方向上仅仅只受到弹簧作用，就会形成永不停止的振动，这就是简谐振动。简谐运动的回复力和物体运动的惯性构成主要矛盾的两个方面，共同推动简谐运动的不断进行。

实验发现，简谐振动存在回复力为 0 的平衡位置，而回复力本身和偏离平衡位置的位移有关。英国的科学家胡克通过实验总结出来了弹簧回复力和偏离平衡位置的位移之间的关系，也就是胡克定律：

$$\vec{F} = -k\vec{x}$$

其中 k 是常量，叫做劲度系数。然而，简谐运动并没有必须有个弹簧的条件。只要运动能满足胡克定律就能叫简谐运动了。

方便起见，先考虑一维简谐运动情况。弹簧一端固定，另一端连接质量为 m 的光滑木块放在光滑水平地面上。对木块，由牛顿第二定律，有：

$$\vec{F} = m\vec{a}$$

而

$$\vec{a} = \ddot{\vec{x}}$$

带入 $\vec{F} = -k\vec{x}$ 有

$$\ddot{\vec{x}} + \frac{k}{m}\vec{x} = \mathbf{0}$$

由于木块质量 m 和劲度系数 k 都是正数，对于这个确定的简谐振动，可以定义一个新的常数 ω ，叫做简谐振动的固有角频率，满足：

$$\omega^2 = \frac{k}{m}$$

所以最终得到了二阶微分方程：

$$\ddot{\vec{x}} + \omega^2\vec{x} = \mathbf{0}$$

由于就是一个自由度的情况，完全可以选定正方向，把矢量化为标量，通过正负来表示方向，就得到了运动方程：

$$\ddot{x} + \omega^2 x = 0$$

这就是判断一个运动是否为简谐运动的通用标准。显然 x 是时间 t 的函数，解这个方程就得到了：

$$\vec{x}(t) = A \cos(\omega t + \varphi)$$

其中 A 是简谐运动的振幅，指的是偏离平衡位置的最远距离， φ 是初相位，描述的是起步时振动的状态，或者说步调。如果确定 $t = 0$ 时的位移 x_0 ，速度 v_0 ，则振幅和初相位都可以算出来：

$$A = \sqrt{x_0^2 + \left(\frac{v_0}{\omega}\right)^2}$$

$$\varphi = -\arctan\left(\frac{v_0}{\omega x_0}\right)$$

观察上述形式，不难联想到匀速圆周运动的情形。能够认为一维简谐运动是匀速圆周运动在单一方向上的投影，也可以认为一维简谐运动可以通过旋转矢量画圆的方式，创造事实上不存在的 y 轴，进而拓展为复平面上的匀速圆周运动。这样，平衡位置就成为圆心所在的位置， A 就成为圆的半径， ω 就成为匀速圆周运动的频率， φ 就成为初始的极角（用极坐标来描述），每一个量都有了清晰的几何含义。

从弹簧振动的实践出发，抽象出简谐振动的通用运动方程，再深化到波动方程，进一步到矢量在复平面上的旋转，最终回到实际意义中去，认识的循环就在这个过程中得以体现了。

如果提高到二维的振动，则显然可以由两个独立方向的振动合成，用矩阵的形式描述：

$$\begin{pmatrix} \ddot{x} \\ \ddot{y} \end{pmatrix} + \begin{pmatrix} \omega_1^2 & 0 \\ 0 & \omega_2^2 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

而当 $\omega_1 = \omega_2 = \omega$ 时，方程组退化为

$$\begin{pmatrix} \ddot{x} \\ \ddot{y} \end{pmatrix} + \omega^2 \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

以此类推，可以得到更高阶的振动的合成。

对于连续均匀的介质，简谐运动的效果会在其中传播，形成机械波。这就是机械波和简谐运动的联系，而机械波是简谐运动的发展。像我们上下抖动绳子一样，简谐振动方向和产生的波的传播方向垂直的波，叫做横波。像我们沿弹簧摆放方向推拉弹簧一样，简谐振动方向和产生的波的传播方向共线的波，叫做纵波。

下面我们来考虑一维的波动方程的求解：

考虑一根均匀弦，线密度为 μ ，张力为 T ，作微小横振动，位移仅沿竖直方向，记为 $u(x, t)$ 。取弦上一微元段 $(x, x + dx)$ ，其质量为 $dm = \mu dx$ 。由于弦发生弯曲，微元两端的切线方向不同，两端张力的竖直分量不相等，从而产生横向合外力。小振动下，弦的倾角很小，张力大小近似保持为 T 。微元所受横向合外力为

$$dF = T \left(\left. \frac{\partial u}{\partial x} \right|_{x+dx} - \left. \frac{\partial u}{\partial x} \right|_x \right) \approx T \frac{\partial^2 u}{\partial x^2} dx.$$

根据牛顿第二定律 $dF = dm \cdot \frac{\partial^2 u}{\partial t^2}$ ，代入得

$$T \frac{\partial^2 u}{\partial x^2} dx = \mu dx \frac{\partial^2 u}{\partial t^2}.$$

消去两边公共因子 dx ，整理得一维波动方程

$$\frac{\partial^2 u}{\partial t^2} = \frac{T}{\mu} \frac{\partial^2 u}{\partial x^2}.$$

为解释其中常数 $\frac{T}{\mu}$ 的物理意义，设简谐行波解为

$$u(x, t) = A \cos \left[\omega \left(t - \frac{x}{v} \right) + \varphi_0 \right],$$

其中 v 为波速，可正可负： $v > 0$ 对应沿 x 正方向传播， $v < 0$ 对应沿 x 负方向传播。

求其二阶偏导数：

$$\frac{\partial^2 u}{\partial t^2} = -\omega^2 u, \quad \frac{\partial^2 u}{\partial x^2} = -\left(\frac{\omega}{v}\right)^2 u.$$

将此代入前述波动方程：

$$-\omega^2 u = \frac{T}{\mu} \left(-\frac{\omega^2}{v^2} u \right).$$

约去非零公因子 $-\omega^2 u$ ，可得波速与介质参数的关系：

$$v^2 = \frac{T}{\mu}.$$

因此，一维波动方程的标准形式可记为

$$\frac{\partial^2 u}{\partial t^2} = v^2 \frac{\partial^2 u}{\partial x^2}.$$

定义一维拉普拉斯算子：

$$\nabla^2 = \frac{\partial^2}{\partial x^2}$$

则波动方程可以写作：

$$\frac{\partial^2 u}{\partial t^2} = v^2 \nabla^2 u$$

拉普拉斯算子可以推广到二维：

$$\nabla^2 = \frac{\partial^2}{\partial x^2} + \frac{\partial^2}{\partial y^2}$$

以及三维：

$$\nabla^2 = \frac{\partial^2}{\partial x^2} + \frac{\partial^2}{\partial y^2} + \frac{\partial^2}{\partial z^2}$$

波动方程的形式就可以保持不变，始终是：

$$\frac{\partial^2 u}{\partial t^2} = v^2 \nabla^2 u$$

波动的形式纷繁多样，却能被高度凝练的波动方程统一描述，而拉普拉斯算子让方程形式极简、又能囊括多维波动的丰富物理内涵，这正是物理学中形式与内容辩证统一的绝佳体现。

4.2 机械波的能量与传播

我们知道，运动的物体具有动能，存在保守力的物体之间具有势能。对于在水平绳子上传播的横波来说，虽然波是在向前传播的，但是绳子上的每一个质点都不会随波前行，只是在垂直于波传播的方向上做简谐运动。相邻的质点之间又连在一起，简谐运动的步调也是紧紧相连的。振动的质点带动尚未振动的质点开始振动，波就向前传播了。由此可见，机械波的传播离不开介质的存在和介质可以形变的性质。对于机械波传播的物质系统，每一个组成部分普遍存在的联系和相互作用是其传播的必要条件。

假设绳波沿着 x 轴正方向传播，则波函数：

$$u(x, t) = A \cos \left[\omega \left(t - \frac{x}{v} \right) + \varphi_0 \right]$$

在绳介质中取一微元，原长 dx ，横截面积 S ，密度 ρ ，其质量为

$$dm = \rho S dx$$

波传播时微元在平衡位置附近振动，振动速度为位移对时间的变化率

$$v_{\text{振}} = \frac{\partial u}{\partial t} = -A\omega \sin \left[\omega \left(t - \frac{x}{v} \right) + \varphi_0 \right]$$

微元的振动动能为

$$dE_k = \frac{1}{2} dm \cdot v_{\text{振}}^2$$

代入可以得到

$$dE_k = \frac{1}{2} \rho S dx \cdot A^2 \omega^2 \sin^2 \left[\omega \left(t - \frac{x}{v} \right) + \varphi_0 \right]$$

微元的形变由位移沿传播方向的空间变化率描述

$$\frac{\partial u}{\partial x} = \frac{A\omega}{v} \sin \left[\omega \left(t - \frac{x}{v} \right) + \varphi_0 \right]$$

微元因形变产生伸长，伸长量由几何关系得

$$\Delta(dx) \approx \frac{1}{2} \left(\frac{\partial u}{\partial x} \right)^2 dx$$

介质内部的张力对形变做功，对应弹性势能为

$$dE_p = T \Delta(dx) = \frac{1}{2} T dx \left(\frac{\partial u}{\partial x} \right)^2$$

将空间变化率代入得

$$dE_p = \frac{1}{2}Tdx \cdot \frac{A^2\omega^2}{v^2} \sin^2 \left[\omega \left(t - \frac{x}{v} \right) + \varphi_0 \right]$$

机械波在弦或固体中的传播速度满足关系 $v^2 = \frac{T}{\rho S}$

即 $\frac{T}{v^2} = \rho S$
代入势能表达式后

$$dE_p = \frac{1}{2}\rho Sdx \cdot A^2\omega^2 \sin^2 \left[\omega \left(t - \frac{x}{v} \right) + \varphi_0 \right]$$

对比动能与势能的表达式可知，同一微元的动能和势能大小始终相等，
则微元的总机械能为

$$dE = dE_k + dE_p = \rho Sdx \cdot A^2\omega^2 \sin^2 \left[\omega \left(t - \frac{x}{v} \right) + \varphi_0 \right]$$

单位体积内的波动能量即能量密度为

$$w = \frac{dE}{Sdx} = \rho A^2\omega^2 \sin^2 \left[\omega \left(t - \frac{x}{v} \right) + \varphi_0 \right]$$

对时间平均后得到平均能量密度

$$\bar{w} = \frac{1}{2}\rho A^2\omega^2$$

波动能量以波速 v 定向传递，单位时间内通过截面 S 的平均能量为平均能流

$$\bar{P} = \bar{w}vS$$

单位面积的平均能流称为波的强度

$$I = \frac{\bar{P}}{S} = \bar{w}v = \frac{1}{2}\rho v\omega^2 A^2$$

之前说了，机械波的传播离不开介质的形变。不难发现，如果考虑柱对称的柱状物体，形变包括沿柱子高方向的伸缩和掰柱子产生的剪切，这两种形变显然是不一样的。对于一般的介质，各个方向上的伸缩和剪切都可能不同，这就是各向异性的体现；也可能都相同，就是各向同性的体现。

我们先来分析伸缩应变。定义伸缩模量（又叫杨氏模量）

$$E = \frac{\sigma}{\varepsilon}$$

其中正应力 $\sigma = \frac{F}{S}$

正应变 $\varepsilon = \frac{\Delta L}{L}$

因此 $E = \frac{F/S}{\Delta L/L}$

取微元段长度 dx ，位移场为 $u(x, t)$ ，则微元的应变为

$$\varepsilon = \frac{\partial u}{\partial x}$$

应力为

$$\sigma = E \frac{\partial u}{\partial x}$$

微元所受合弹性力为

$$dF = Sd\sigma = SE \frac{\partial^2 u}{\partial x^2} dx$$

又有微元质量

$$dm = \rho S dx$$

由牛顿第二定律 $dF = dm \frac{\partial^2 u}{\partial t^2}$

代入得

$$SE \frac{\partial^2 u}{\partial x^2} dx = \rho S dx \frac{\partial^2 u}{\partial t^2}$$

约去后得到波动方程

$$\frac{\partial^2 u}{\partial t^2} = \frac{E}{\rho} \frac{\partial^2 u}{\partial x^2}$$

对比标准一维波动方程形式为

$$\frac{\partial^2 u}{\partial t^2} = v^2 \frac{\partial^2 u}{\partial x^2}$$

对比可得一维纵波传播速度

$$v_L = \sqrt{\frac{E}{\rho}}$$

接下来，我们分析剪切应变。定义剪切模量

$$G = \frac{\tau}{\gamma}$$

其中切应力 $\tau = \frac{F_{\text{切}}}{S}$ ，切应变 γ 为介质发生剪切时的相对形变角。取介质

微元，位移场为 $u(x, t)$ ，剪切应变可表示为 $\gamma = \frac{\partial u}{\partial x}$ ，对应的切应力为 $\tau = G \frac{\partial u}{\partial x}$ 。

微元所受合剪切弹性力为

$$dF = Sd\tau = SG \frac{\partial^2 u}{\partial x^2} dx$$

微元质量

$$dm = \rho S dx$$

由牛顿第二定律 $dF = dm \frac{\partial^2 u}{\partial t^2}$

代入得

$$SG \frac{\partial^2 u}{\partial x^2} dx = \rho S dx \frac{\partial^2 u}{\partial t^2}$$

约去后得到横波波动方程

$$\frac{\partial^2 u}{\partial t^2} = \frac{G}{\rho} \frac{\partial^2 u}{\partial x^2}$$

标准一维波动方程为

$$\frac{\partial^2 u}{\partial t^2} = v^2 \frac{\partial^2 u}{\partial x^2}$$

对比可得

$$v^2 = \frac{G}{\rho}$$

因此固体中一维横波传播速度为

$$v_s = \sqrt{\frac{G}{\rho}}$$

在一般的固体中，剪切模量 G 都小于伸缩模量 E 。这是因为剪切只需要微观粒子层面之间滑动，比较容易；而伸缩则要对抗粒子之间的多种相互作用力，比较困难。显然，这两个模量描述的都是形变的难易程度，值越大则形变越难。三维固体空间中，横波和纵波的波速虽有修正系数，但波速仍分别与 $\sqrt{\frac{G}{\rho}}$ 、 $\sqrt{\frac{E}{\rho}}$ 成正比。结合本节得出的波强度公式

$$I = \frac{1}{2} \rho v \omega^2 A^2$$

可知能流密度与波速直接相关，这就能够解释地震时纵波比横波更先到达地面的现象，提供了理论指导实践、保障生产生活安全的依据。

对于各向同性的材料而言，杨氏模量 E 与剪切模量 G 存在紧密的内在关联，二者并非独立的弹性常量，可通过应力应变关系与几何形变规律，推

导出三者的定量关系式 $G = \frac{E}{2(1+\nu)}$ 。首先明确泊松比 ν 表征材料纵向受力时横向形变的响应程度，定义为

$$\nu = -\frac{\varepsilon_{\perp}}{\varepsilon_{\parallel}}$$

即横向应变与纵向应变的比值。从应力状态分析，纯剪切应力状态可等效转化为与剪切方向呈 45° 的双向主应力状态，该方向上分别产生大小相等的拉应力

$$\sigma_1 = \tau$$

与压应力

$$\sigma_2 = -\tau$$

基于此对 45° 方向的线应变进行叠加计算，该方向的总应变由自身拉应力产生的应变

$$\varepsilon_1 = \frac{\sigma_1}{E} = \frac{\tau}{E}$$

以及垂直方向压应力通过泊松效应引发的附加应变

$$\varepsilon_2 = -\nu \frac{\sigma_2}{E} = \frac{\nu\tau}{E}$$

两部分组成，因此总线应变

$$\varepsilon = \varepsilon_1 + \varepsilon_2 = \frac{\tau(1+\nu)}{E}$$

在小形变前提下，剪切应变 γ 与 45° 方向线应变存在固定几何关系

$$\gamma = 2\varepsilon$$

将线应变表达式代入后可得切应变

$$\gamma = \frac{2\tau(1+\nu)}{E}$$

再将其代入剪切模量的定义式，约去切应力 τ 后，即可最终得到

$$G = \frac{E}{2(1+\nu)}$$

从该关系式可直观解释固体中 $G < E$ 的本质原因，绝大多数工程材料与天然固体的泊松比 ν 取值在 0.2 到 0.35 之间，取常见值 $\nu = 0.3$ 代入计算，

可得 $G = \frac{E}{2.6} \approx 0.38E$ ，即便取泊松比的极限值，剪切模量也始终小于杨氏模量。这也印证了我们刚才对于不同相互作用影响的形变难易程度的分析。

刚才我们反复在讲固体的剪切模量 G ，那么，流体有没有剪切模量呢？我们来想一想，一旦流体粒子层之间发生剪切错位运动，介质会直接发生流动，无法产生弹性剪切形变，也不存在剪切恢复力。因此，流体不存在剪切模量 G ，也就不能传播横波。因此，流体的弹性特性需单独分析，无法沿用固体的剪切形变理论。这就体现了对具体问题做具体分析的灵魂。

在各向同性流体中，定义体积模量

$$K = -V \frac{dP}{dV}$$

用于描述介质抵抗均匀体积压缩的弹性特性。

在纵波传播过程中，体积模量 K 提供体积压缩恢复力，其物理作用与固体中杨氏模量 E 提供的轴向伸缩恢复力完全等价。因此，将固体纵波速度表达式中的 E 替换为 K ，即可直接得到流体中的纵波传播速度：

$$c = \sqrt{\frac{K}{\rho}}$$

该式为严格相等关系，无附加修正项。由于不存在剪切恢复力，横波无法在流体中激发与传播，这也是地震横波不能穿透水体而纵波可以传播的根本原因。

有一点是一定要注意的：虽然水不传播横波，但是地震来临不能躲进小水体，因为整个地面都在震，会带动水一起振动，而且存在着岸边崩塌的风险。海岸边也不行，海底地震引发的海底地壳竖向晃动，会推动海水大幅抬升，能量传递至近岸后会形成巨大海啸，同样极具危险性。只有完全处于高空（高楼楼顶也很危险）和远离海岸的深海区域，由于空气和水体不传播横波，且不受地基晃动与边坡坍塌的直接影响，才相对安全。

总结一下，无论横波还是纵波，介质质点都只在各自平衡位置附近往复振动，并不会随着波一起向前持续移动；而振动和能量之所以能向外传递，正是依靠物质之间的相互作用。这正是物质运动与相互作用辩证统一的体现：没有相互作用，运动无法传递；没有运动，相互作用也无法显现。也就是说，机械波是物质运动与相互作用的辩证统一，能量传递则是这一统一过程的必然结果与量化表现。

4.3 机械波的干涉和衍射

我们在日常生活中经常会遇到这样的现象：向平静的水面同时投入两颗石子，两列圆形波纹会相互穿过，各自继续向前传播，在它们重叠的区域，水面的起伏会变得更加复杂，有些地方振动格外剧烈，有些地方则几乎静止不动；两个频率相同的音叉同时发声时，我们在房间里走动，会听到声音忽强忽弱；隔着一堵墙，我们能听到墙另一边人的说话声，却看不到墙那边的人。这些现象都是波所特有的运动形式——干涉和衍射的表现。这两类现象，是波动物质运动最具代表性的辩证表现。

当几列波在同一介质中传播相遇时，介质中任意质点的振动，都是每一列波单独作用所引发振动的共同叠加，这就是波的叠加原理。各列波相遇过后，不会改变自身原本的频率、波长、振动方向与传播状态，依旧独立向前传播，互不影响。

我们身处嘈杂环境依旧可以分辨不同声源的声音，正是源于波动的这种独立传播与叠加特性。一切物理规律都存在自身适用范围，当波的振幅过大，介质形变超出弹性作用的常规区间，质点间线性作用关系被打破，叠加原理不再成立，波形畸变、非线性效应便会随之出现。在生产实践中，多台机械同时运行产生的振动相互叠加，可能造成局部振动异常加剧，引发设备疲劳、结构损伤，这就需要合理控制振动源的排布与工况。这就体现了物质的运动规律始终被具体物质条件所制约；条件改变，运动的表现形式也会发生相应变化。

能够形成稳定干涉的波需要满足振动方向相同、频率一致、相位差恒定的条件，满足该条件的波称为相干波。设空间某一质点，分别受到两列相干波的作用，各自独立激发的振动表达式分别为

$$u_1 = A_1 \cos(\omega t + \varphi_1)$$

$$u_2 = A_2 \cos(\omega t + \varphi_2)$$

同一质点的振动遵从叠加关系，合振动为两分振动直接相加

$$u = A_1 \cos(\omega t + \varphi_1) + A_2 \cos(\omega t + \varphi_2)$$

两分振动频率相同，在相互叠加耦合之后，整体运动仍旧维持简谐振动的形式，经过振动的合成化简，最终得到合振幅的定量关系

$$A^2 = A_1^2 + A_2^2 + 2A_1A_2 \cos \Delta\varphi$$

式中 $\Delta\varphi$ 为两列波在该空间位置的相位差。波动能量与振幅平方直接相关，由此进一步叠加得到波的强度分布

$$I = I_1 + I_2 + 2\sqrt{I_1 I_2} \cos \Delta\varphi$$

空间中不同位置波程差不同，相位差呈现规律分布。当两列波相位同步协调时，振动相互加强，合振幅达到最大；当两列波相位完全相反时，振动彼此削弱、相互抵消，合振幅降到最低。若两列相干波振幅相等，抵消位置质点振动会完全消失。整个叠加区域内，加强区域与减弱区域固定分布、长期不变，形成稳定的干涉图样。振动强弱的有序分化，是相近运动形态彼此作用、相互制约的结果。

两列相干波在空间不同位置的相位差，是连续、渐进的量的积累过程，这种看似微小的相位差异，随着空间位置的变化不断叠加累积，最终引发了振动强度的根本性分化——形成加强与减弱截然分明的稳定干涉图样。也就是说渐进式的量变最终促成了运动状态的质变。

两列振幅相等、传播方向完全相反的相干行波相互叠加，会形成区别于行波的特殊波动形态，也就是驻波。沿 x 轴正方向与负方向传播的两列行波分别写作

$$u_1 = A \cos \left[\omega \left(t - \frac{x}{v} \right) \right]$$

$$u_2 = A \cos \left[\omega \left(t + \frac{x}{v} \right) \right]$$

两列反向行进的波动在同一介质空间内相互叠加，合振动为二者直接求和

$$u = A \cos \left[\omega \left(t - \frac{x}{v} \right) \right] + A \cos \left[\omega \left(t + \frac{x}{v} \right) \right]$$

经过波动合成与整理化简后，得到驻波的完整表达式

$$u = 2A \cos \left(\frac{\omega x}{v} \right) \cos \omega t$$

驻波形成之后，整体波形不再发生定向平移，不存在能量的持续定向输送。介质中所有质点仍以相同频率做简谐振动，只是振幅随空间位置周期性变化，振幅最大的位置形成波腹，振幅恒为零的固定位置形成波节。行波依靠波形迁移传递能量，驻波将运动束缚在有限空间之中，系统内部弹性势能与振动动能不断相互转化、动态平衡。生产中的长管道、长杆件、传动结构容易形成驻波，能量会在固定位置持续集中，长期运行易造成定点磨损、开裂，是工程实践中必须注意防范的问题。

机械波在不同介质分界面发生反射时，边界的约束条件与介质的弹性差异，会直接改变反射波的相位状态，产生半波损失。取介质分界面为坐标原点，入射波与反射波的表达式分别为

$$u_{\lambda} = A \cos \left[\omega \left(t - \frac{x}{v} \right) \right]$$

$$u_{\text{反}} = A' \cos \left[\omega \left(t + \frac{x}{v} \right) + \varphi \right]$$

界面处的总振动由入射波与反射波共同叠加而成。在固定刚性边界处，界面质点被严格约束，合位移必须恒等于零。依靠这一边界约束条件联立两波叠加关系，对比等式两侧的振动分量关系可以推得，反射波会产生大小为 π 的相位突变。这一相位变化等效于波额外多行进了半个波长的距离，因此被称作半波损失。

若是自由边界，界面不存在位移约束与强制弹性反作用，两波叠加无需满足静止条件，反射波相位不会发生改变，也就不存在半波损失。由此可见，相位的突变不是抽象的理论设定，而是不同物质之间相互作用、边界条件强约束的必然结果，物质的固有属性决定相互作用形式，相互作用又直接规定了波动的运动变化，物质与运动、作用与变化始终紧密联结、辩证统一。

波在传播过程中绕过障碍物边缘，进入几何阴影区域继续传播的现象，称为衍射，衍射是一切波动固有的运动特征。用以系统解释衍射机制的核心理论为惠更斯原理。该原理指出，波动传播过程中，任意时刻波前覆盖的所有介质质点，都能够视作独立的次级波源，每一个次级波源都会向外激发次波，下一时刻整个波动的传播轮廓，由所有次波共同形成的包络面共同决定。

惠更斯原理适用于一切机械波的传播过程，依靠次波的包络演化，能够统一解释波的直线传播、反射、折射等常规现象。当波动遭遇障碍物或狭缝时，大范围波前被遮挡阻断，只有边缘或狭缝处的局部波前可以持续激发次波，这些次级波源向四周全方位传播，自然覆盖障碍物后方的空间区域，宏观上就表现为波的衍射绕行。

从本质上来讲，衍射就是大量连续分布的次波源持续叠加的过程。从波动叠加的本质来看，干涉是有限列相干波的离散性叠加，衍射则是波前上无数次级子波的连续性叠加，二者虽在宏观表现、叠加形式上存在差异，却共同遵循波动叠加的核心物理机制。干涉作为波动叠加的特殊形式，衍射作为波动传播的普遍属性，二者相互依存、相互印证。这就是波动方程在不同边界条件下的具体解的关系。矛盾普遍性寓于特殊性之中，特殊性离不开普遍性。普遍规律支配各类特殊运动现象，特殊现象又具象化展现普遍规律的辩证关系。

衍射现象的显著程度，由障碍物、狭缝的几何尺寸和波长的相对大小决定。障碍物尺寸远大于波长时，边缘次波的侧向传播范围有限，整体波动近似沿直线传播，衍射效应微弱；当障碍物尺度与波长接近甚至更小的时候，次波的侧向传播占据主导，衍射现象会表现得十分突出。单纯几何尺度的量变，逐步改变波的传播范围与运动方式，最终引发传播形态的质变。

声波波长匹配日常建筑、山体等障碍物尺度，衍射能力极强，故而声音可以轻松穿墙绕物；短波波动波长极小，衍射效应微弱，传播方向性极强，现实中各类波动的传播差异，都可以通过这一客观规律得到合理解释。比如工地施工、机械作业时的噪声传播，正是因为声波波长与建筑构件、障碍物尺度匹配，衍射现象明显，噪声才会绕过施工围挡向外传播；而工业探伤用的短波声波，衍射弱、方向性强，能精准穿透构件检测缺陷，同样是尺度量变引发传播性质变的现实体现。

相较于从微观波动方程做严谨的数学推导，惠更斯原理以次波模型直观阐释衍射机制，避开了繁复的数学演算，却能精准把握波动传播的核心规律。这一研究范式的差异，恰恰说明在探索自然规律的过程中，不能陷入机械还原论的误区，不能试图用单一、绝对的微观规律生硬套用所有宏观运动现象。自然物质的运动是系统性、整体性的过程。只有立足具体物质条件，兼顾还原分析与整体辩证思维，才能全面、准确地把握客观物理规律。

机械波的全部运动变化，都建立在客观物质实在的基础之上，运动不能脱离物质，规律不能脱离条件。干涉与衍射统一构成了波动的核心运动特征。这两类现象的产生，完全依托于介质内部质点之间紧密的弹性联系与相互作用。孤立的质点无法形成波动运动，更无法产生振动叠加、绕射传播等复杂行为，正是物质系统内部普遍的相互作用，才让振动得以传递、叠加、重构，衍生出多样的波动现象。不同介质属性、不同边界条件、不同空间结构，会让波动的叠加形式产生差异，分化出干涉、驻波、衍射等不同运动形态，但所有特殊运动，都统一服从于波动传播与振动叠加的底层法则。

Part V

电磁学

5.1 库仑定律到静电场

人类对电的认识，最初来自摩擦起电这类朴素经验。但经验不会自动成为科学，只有当经验被纳入可测量、可重复、可推广的框架，感性认识深化为理性认识时，我们迈入科学大门第一步。电学才真正诞生。

18 世纪下半叶，远洋航海和地图测绘的扩展，对精密测量提出了更高要求。作为经过严格训练的军事工程师，库仑具备自制精密扭秤的能力。1785 年，库仑用扭秤实验测量了两个带电小球之间的作用力，总结出：

$$F = k \frac{q_1 q_2}{r^2}$$

在国际单位制中，改写 $k = \frac{1}{4\pi\epsilon_0}$ ，其中 ϵ_0 是真空介电常数。这就是库仑定律，电磁学的第一个坚实基础。

但库仑定律描述的是“电荷对电荷的力”，是两个质点之间的关系。空间中有多个电荷时，每个电荷都受到其他所有电荷的作用，虽然力的叠加原理成立，但计算起来相当繁琐。更关键的是，库仑定律暗示了一种“超距作用”：两个电荷相隔一段距离，中间没有任何东西，力却能瞬间传递。

这里要停下来想一想。超距作用意味着什么？它意味着空间是绝对的、空洞的容器，物质是占据位置的质点，相互作用不需要中间环节，直接从一个质点“跳跃”到另一个质点。这种世界观在牛顿力学中很成功，但它把空间降格为纯粹的几何背景，剥夺了空间的物理内容。辩证法讲事物是普遍联系的，联系需要中介；超距作用恰恰取消了中介，把联系变成了神秘的“即时跳跃”。这不是辩证法的观点，而是形而上学的残余——把整体割裂为孤立的质点，把过程压缩为瞬时的结果，把充满物理内容的空间抽空为几何框架。

要超越这种形而上学，必须重新理解空间。空间不是被动的容器，而是具有物理实在性的存在。电荷之间的作用不是直接完成的，而是通过空间本身的某种状态传递的。这种空间状态，就是电场。

我们定义电场强度 $\mathbf{E}$ 为单位正试探电荷在某点所受的力：

$$\mathbf{E} = \frac{\mathbf{F}}{q_0} = \frac{1}{4\pi\epsilon_0} \frac{q}{r^2} \hat{\mathbf{r}}$$

试探电荷要足够小，以免扰动原来的电荷分布。引入它，是为了把“空间的性质”和“被测电荷的属性”分离开来。电场强度 $\mathbf{E}$ 描述的是空间本身的状况，而不是某个特定电荷对的相互作用。这是一个关键的概念跃迁：从“电荷 A 对电荷 B 的力”到“空间某点的电场”。空间不再是空洞的背景，而是充满物理属性的能动实在。

多个点电荷产生的电场，叠加原理直接给出：

$$\mathbf{E} = \sum_i \frac{1}{4\pi\epsilon_0} \frac{q_i}{r_i^2} \hat{\mathbf{r}}_i$$

实际中电荷往往是连续分布的，比如一块带电金属板、一条带电塑料棒。用电荷密度 $\rho(\mathbf{r}')$ 描述，求和变成积分：

$$\mathbf{E}(\mathbf{r}) = \frac{1}{4\pi\epsilon_0} \int \frac{\rho(\mathbf{r}')(\mathbf{r} - \mathbf{r}')}{|\mathbf{r} - \mathbf{r}'|^3} dV'$$

这个积分式告诉我们，空间中每一点的电场是整个电荷分布“共同编织”的结果。但直接拿这个积分算电场，往往涉及复杂的矢量积分，计算量很大。比如一个带电圆环轴线上的电场，积分起来就很麻烦。该式为电荷分布的通用表达，后续对点电荷推导，统一将源点置于坐标原点简化分析。如果要获得更简洁、更具整体性的描述，还需要引入矢量分析的语言。

我们引入 nabla 算子：

$$\nabla = \left(\frac{\partial}{\partial x}, \frac{\partial}{\partial y}, \frac{\partial}{\partial z} \right)$$

关键的一步来了，注意到

$$\frac{\hat{\mathbf{r}}}{r^2} = -\nabla \left(\frac{1}{r} \right)$$

这个等式可以把库仑定律“分母有 r^2 ”的形式，转化成了“梯度”的形式。梯度是标量场变化最快的方向和速率。这样一来，点电荷的电场就可以写成：

$$\mathbf{E} = -\nabla \left(\frac{q}{4\pi\epsilon_0 r} \right)$$

这是一个梯度场！这意味着电场可以由一个标量函数生成。梯度的散度和旋度有简洁的数学性质，后续计算会大大简化。

先算散度。对 $r \neq 0$ 的区域，直接计算可得

$$\nabla \cdot \mathbf{E} = 0$$

这说明，在没有电荷的地方，电场线既不凭空产生，也不凭空消失。利用数学恒等式

$$\nabla^2 \left(\frac{1}{r} \right) = -4\pi\delta(\mathbf{r})$$

代入可得

$$\nabla \cdot \mathbf{E} = \frac{q}{\varepsilon_0} \delta(\mathbf{r})$$

对于一般电荷分布，叠加原理给出

$$\nabla \cdot \mathbf{E} = \frac{\rho}{\varepsilon_0}$$

这就是高斯定理的微分形式。它说：空间任意一点的电场的散度，正比于该点的电荷密度。有正电荷的地方，电场线向外发散；有负电荷的地方，电场线向内汇聚。也就是说，电荷是电场的“源”。

高斯定理还有积分形式。对任意闭合曲面 S ，电场穿过它的总通量等于曲面内包围的净电荷除以 ε_0 ：

$$\oint_S \mathbf{E} \cdot d\mathbf{S} = \frac{Q_{\text{内}}}{\varepsilon_0}$$

这个形式极为实用。计算点电荷、带电球壳、无限长直导线等对称情形的电场时，选取合适的高斯面，可以避开复杂的积分，直接得到结果。比如均匀带电球壳外部，电场等同于全部电荷集中在球心；内部电场则为零。这是球对称性的自然推论，也是高斯定理威力的体现。

更重要的是，积分形式揭示了一种整体与局部的统一：穿过闭合曲面的总通量只取决于曲面内部的净电荷，与外部电荷无关，也与曲面的具体形状无关。局部的源决定了全局的通量，全局的通量又反映了局部的源。这种关联不是偶然的，而是电场空间结构的必然规定。

再算旋度。既然 $\mathbf{E}$ 是某个标量函数的梯度，而梯度场的旋度恒为零：

$$\nabla \times \mathbf{E} = 0$$

静电场是无旋场，静电场的电场线不会自我闭合，从正电荷出发，终止于负电荷。这与磁场形成鲜明对比——磁感应线永远是闭合的，磁场是无源有旋场。这种结构差异不是数学游戏，而是深刻反映了自然界的根本事实：电荷可以单独存在，磁单极子迄今未被实验发现。场的数学结构对应着物质存在的根本方式。

旋度为零意味着静电场是保守场。沿任意闭合路径移动试探电荷，电场力做功为零：

$$\oint_C \mathbf{E} \cdot d\mathbf{l} = 0$$

因此可以定义电势 φ ，使得

$$\mathbf{E} = -\nabla\varphi$$

负号表示电场指向电势降低的方向——正电荷在电场力作用下，自然地由高电势“流向”低电势，就像水从高处流向低处。电势的引入完成了第二次概念跃迁：从矢量场到标量场，描述大大简化。只知道 φ ，还需通过梯度运算才能恢复 $\mathbf{E}$ 的方向。

把 $\mathbf{E} = -\nabla\varphi$ 代入高斯定理：

$$\nabla \cdot (-\nabla\varphi) = \frac{\rho}{\varepsilon_0}$$

即

$$\nabla^2\varphi = -\frac{\rho}{\varepsilon_0}$$

这就是泊松方程。在没有电荷的区域， $\rho = 0$ ，方程退化为拉普拉斯方程 $\nabla^2\varphi = 0$ 。

泊松方程把电荷分布与电势分布联系起来，同时通过拉普拉斯算子 ∇^2 将某点的电势与其周围邻域的电势关联起来。电荷不仅“决定”该点的电势，还通过微分运算将影响的“涟漪”传播到整个空间。给定边界条件后，泊松方程能唯一确定全空间的电势分布——这是决定论在场论中的体现，但这种决定论是局域与全局耦合的，不是经典力学中质点轨道那种简单的因果链条。

还要注意，传统认知中容易将“满足高斯定理”与“无旋保守场”绑定，本质是混淆了特例与一般规律，属于形而上学的片面认知。对于静电场而言，直接通过高斯定理计算电场强度的前提是静电场必定无旋，然后才能取对称高斯面简化计算。若对于其他的场，不满足无旋的，高斯定理虽然成立，也不能直接计算出电场强度。这就是二者矛盾的不同，需要具体分析。

超距作用的扬弃，不是对库仑定律的否定，而是对其“超距”表象的超越。电场概念承认空间是物理实在，承认相互作用需要中介，这正是辩证法普遍联系原理的科学体现。联系不是神秘的即时跳跃，而是通过场的局域结构逐步传递的。牛顿力学中的空间是绝对的、被动的、空洞的；场论中的空间是相对的、能动的、充满内容的。这种转变不是对牛顿的粗暴推翻，而是在新的实验层面上的扬弃：库仑定律在静电范围内仍然有效，但对其深层结构的追问，揭示了更丰富的物理图景。这就让旧理论的合理内核，转化为新理论体系中的有机组成部分。

还有一点要注意，库仑定律抓住了电荷相互作用的量的规定性，但没有揭示其空间结构；电场概念引入了空间的物理化，但仍是矢量描述的“原

始”形态；电势概念进一步抽象为标量场，实现了描述的简化，却又通过梯度运算与电场保持联系。高斯定理揭示源与场的整体关联，泊松方程则将这种关联表达为微分方程的约束。每一个新概念都不是对旧概念的抛弃，而是在保留合理内核的同时，增加新的认识维度。这正是辩证否定——扬弃——在科学概念发展中的具体体现。

还要看到，理论的数学形式与物理内容相互促进。 ∇ 算子不仅是数学工具，它本身就是对空间结构的抽象表达；散度和旋度不仅是微分运算，它们分别对应着场的“源”结构和“涡”结构。数学形式不是外加于物理内容的装饰，而是物理内容本身的结构化呈现。

最后要诚实面对理论的理想化。泊松方程要求电荷密度足够光滑，连续分布的电荷没有什么特别的；但点电荷要用 δ 函数描述；导体表面电荷是面分布；介质分界面上电场可能突变。这些“奇异”情形不是理论的失败，而是反映了物理实在的层次性：宏观上电荷可以理想化为点或面，微观上这种理想化失效，需要量子电动力学。知道一个理论的边界，比盲目相信它的普适性更接近真理。理论的有限性为进一步发展预留了空间，也为工程实践中的近似计算提供了合法性基础——工程师设计高压设备时，用泊松方程计算电场分布；遇到尖端放电时，知道在曲率极大处，导体表面电荷分布的理想化假设（如均匀面密度）不再成立，实际电场远高于理想边界条件下的计算值，因此需要引入电场集中修正或击穿判据。理论与实践在这种张力中共同前进，使得认识逐渐上升。

5.2 电流磁效应到静磁场

在思想界对“自然力统一”探索的背景和社会的广泛关注下，电学研究得以兴盛。

静电场描述的是静止电荷产生的效应。但电荷一旦运动起来，情况就变了。我们生活中最熟悉的运动电荷，就是导线中的电流——金属导线里大量的自由电子在电场驱动下定向漂移，形成持续的电荷流动。电流周围有什么特殊现象？

1820 年，奥斯特在课堂演示中发现，通电导线附近的小磁针会发生偏转。用铁屑撒在通电导线周围，可以直观地看到同心圆状的磁感线。这个看似偶然的观察，揭开了电磁学的新篇章：电与磁不是彼此独立的现象，而是相互关联、相互转化的统一体。

奥斯特的发现立刻引发了研究热潮。毕奥和萨伐尔通过精密的实验测量，总结出载流导线产生的磁场规律。对于一段电流元 $I d\mathbf{l}$ ，它在距离位矢 $\mathbf{r}$ 处产生的磁场为

$$d\mathbf{B} = \frac{\mu_0}{4\pi} \frac{I d\mathbf{l} \times \hat{\mathbf{r}}}{r^2}$$

其中 μ_0 是真空磁导率， $\times$ 表示矢量叉乘，所以磁场的方向垂直于电流元和位矢所构成的平面。这个定律的结构与库仑定律类似——都是平方反比、都与源成正比——但叉乘的出现带来了本质差异：磁场不是径向的，而是环绕电流的涡旋状分布。

实际中电流往往是连续分布的，比如一块通电的金属板、一团等离子体。我们需要用电流密度 $\mathbf{J}$ 来描述。电流密度定义为：单位时间内通过单位垂直截面的电荷量，方向为电荷运动的方向。对于定向运动的电荷，若电荷密度为 ρ ，平均漂移速度为 $\mathbf{v}$ ，则

$$\mathbf{J} = \rho \mathbf{v}$$

这个关系很直观：电荷越多、跑得越快，电流就越大。在金属导线中， ρ 是自由电子的电荷密度（负值）， $\mathbf{v}$ 是电子漂移速度（与电场反向），所以 $\mathbf{J}$ 的方向与电子运动方向相反，也就是与正电荷运动方向相同——这正是我们约定电流方向的习惯来源。

对于一根粗细均匀的导线，截面积为 S ，电流密度大小处处相同，则总电流 I 与电流密度的关系为

$$I = \mathbf{J} \cdot \mathbf{S}$$

若取截面为垂直横截面，则电流密度和截面法向量平行，可以化简得到 $I = JS$ 。用电流密度表示，毕奥-萨伐尔定律写成体积分形式：

$$\mathbf{B}(\mathbf{r}) = \frac{\mu_0}{4\pi} \int \frac{\mathbf{J}(\mathbf{r}') \times (\mathbf{r} - \mathbf{r}')}{|\mathbf{r} - \mathbf{r}'|^3} dV'$$

和静电场的情形一样，直接拿这个积分算磁场，往往很复杂。要获得更简洁、更具整体性的描述，需要引入 nabla 算子，寻找微分形式。

关键的一步，注意到

$$\frac{\mathbf{r} - \mathbf{r}'}{|\mathbf{r} - \mathbf{r}'|^3} = -\nabla \frac{1}{|\mathbf{r} - \mathbf{r}'|}$$

这里的梯度 ∇ 是对 $\mathbf{r}$ （场点）求的。代入毕奥-萨伐尔定律：

$$\mathbf{B}(\mathbf{r}) = -\frac{\mu_0}{4\pi} \int \mathbf{J}(\mathbf{r}') \times \nabla \frac{1}{|\mathbf{r} - \mathbf{r}'|} dV'$$

利用矢量恒等式

$$\nabla \times (\psi \mathbf{A}) = \nabla \psi \times \mathbf{A} + \psi (\nabla \times \mathbf{A})$$

取 $\psi = \frac{1}{|\mathbf{r} - \mathbf{r}'|}$ ， $\mathbf{A} = \mathbf{J}(\mathbf{r}')$ 。

注意 $\mathbf{J}(\mathbf{r}')$ 不依赖于 $\mathbf{r}$ ，因此 $\nabla \times \mathbf{J}(\mathbf{r}') = 0$ 。于是

$$\nabla \times \left(\frac{\mathbf{J}(\mathbf{r}')}{|\mathbf{r} - \mathbf{r}'|} \right) = \nabla \frac{1}{|\mathbf{r} - \mathbf{r}'|} \times \mathbf{J}(\mathbf{r}') = -\mathbf{J}(\mathbf{r}') \times \nabla \frac{1}{|\mathbf{r} - \mathbf{r}'|}$$

这正是被积函数中的叉乘。因此

$$\mathbf{B}(\mathbf{r}) = \frac{\mu_0}{4\pi} \int \nabla \times \left(\frac{\mathbf{J}(\mathbf{r}')}{|\mathbf{r} - \mathbf{r}'|} \right) dV'$$

由于旋度是对 $\mathbf{r}$ 的运算，可以提到积分号外

$$\mathbf{B}(\mathbf{r}) = \nabla \times \left[\frac{\mu_0}{4\pi} \int \frac{\mathbf{J}(\mathbf{r}')}{|\mathbf{r} - \mathbf{r}'|} dV' \right]$$

方括号内的量是一个矢量场，记为 $\mathbf{A}$ ，称为磁矢势：

$$\mathbf{A}(\mathbf{r}) = \frac{\mu_0}{4\pi} \int \frac{\mathbf{J}(\mathbf{r}')}{|\mathbf{r} - \mathbf{r}'|} dV'$$

因此磁场可以表示为磁矢势的旋度：

$$\mathbf{B} = \nabla \times \mathbf{A}$$

这个关系极为重要：磁场本身没有“标量势”，但它的“旋度源”可以由一个矢势函数生成。这与电场 $\mathbf{E} = -\nabla\varphi$ （梯度场）形成对偶：电场无旋有势，磁场无源有矢势。

现在计算磁场的散度。由 $\mathbf{B} = \nabla \times \mathbf{A}$ ，而旋度的散度恒为零，即

$$\nabla \cdot \mathbf{B} = 0$$

是一个普遍成立的数学恒等式。它的物理意义是：磁场没有“源”，磁感线永远是闭合的，不存在发出或终止磁感线的“磁荷”。这与电场形成根本对比——电场线从正电荷发出、向负电荷汇聚，有始有终；磁感线却永远转圈，找不到起点和终点。

再计算磁场的旋度。由 $\mathbf{B} = \nabla \times \mathbf{A}$ ，取旋度并利用矢量恒等式

$$\nabla \times (\nabla \times \mathbf{A}) = \nabla(\nabla \cdot \mathbf{A}) - \nabla^2 \mathbf{A}$$

为了简化，我们可以选择一种“规范”使得 $\nabla \cdot \mathbf{A} = 0$ 。在静磁场中，这是总是可行的，因为如果 $\nabla \cdot \mathbf{A} \neq 0$ ，我们可以重新定义 $\mathbf{A}' = \mathbf{A} + \nabla\chi$ ，选取合适的 χ 使散度为零，而 $\nabla \times \nabla\chi = 0$ ，因此不会改变磁场。这种选择称为库仑规范。于是

$$\nabla \times \mathbf{B} = -\nabla^2 \mathbf{A}$$

接下来计算 $\mathbf{A}$ 的拉普拉斯。由 $\mathbf{A}$ 的积分表达式，将拉普拉斯算子移入积分内，利用恒等式

$$\nabla^2 \frac{1}{|\mathbf{r} - \mathbf{r}'|} = -4\pi\delta(\mathbf{r} - \mathbf{r}')$$

（其中 δ 是三维狄拉克函数），得到

$$\nabla^2 \mathbf{A} = -\mu_0 \mathbf{J}$$

因此

$$\nabla \times \mathbf{B} = \mu_0 \mathbf{J}$$

这就是静磁场的旋度方程。它说：电流是磁场的涡旋源，磁场绕电流旋转，旋转的强度正比于电流密度。

在静磁学的框架内，我们已经得到了磁场的两个基本方程：

散度方程 $\nabla \cdot \mathbf{B} = 0$

旋度方程 $\nabla \times \mathbf{B} = \mu_0 \mathbf{J}$ 。

对于矢势 $\mathbf{A}$ ，我们还有 $\nabla^2 \mathbf{A} = -\mu_0 \mathbf{J}$ ，这与静电学中的泊松方程 $\nabla^2 \varphi = -\rho/\varepsilon_0$ 结构非常相似。这提示我们，在某些情形下，磁场问题也可以引入类似“势”的概念来简化。

但磁场本身是无源的，不能定义全局的标量势。不过，在电流密度 $\mathbf{J} = 0$ 的区域，旋度方程变为 $\nabla \times \mathbf{B} = 0$ ，这意味着磁场在该区域内是无旋的。无旋场可以表示为某个标量函数的梯度，我们定义磁标势 φ_m 满足：

$$\mathbf{B} = -\mu_0 \nabla \varphi_m$$

其中负号和 μ_0 的引入是为了与电磁学惯例协调。将上式代入散度方程 $\nabla \cdot \mathbf{B} = 0$

得到

$$\nabla^2 \varphi_m = 0$$

这就是磁标势的拉普拉斯方程。在电流为零的区域，磁标势满足与静电势在无电荷区域相同的方程。

如果区域内存在磁化物质，情况会更丰富。磁化强度 $\mathbf{M}$ 描述介质中微观磁矩的集体取向，它等效于一种束缚电流分布。引入磁场强度 $\mathbf{H}$ 满足

$$\mathbf{H} = \frac{\mathbf{B}}{\mu_0} - \mathbf{M}$$

则 $\mathbf{H}$ 的旋度方程简化为 $\nabla \times \mathbf{H} = \mathbf{J}_{\text{自由}}$

其中 $\mathbf{J}_{\text{自由}}$ 是自由电流密度。在自由电流为零的区域 $\nabla \times \mathbf{H} = 0$

可以定义 $\mathbf{H} = -\nabla \psi_m$

代入 $\nabla \cdot \mathbf{B} = 0$

利用 $\mathbf{B} = \mu_0(\mathbf{H} + \mathbf{M})$

得到

$$\nabla^2 \psi_m = -\nabla \cdot \mathbf{M}$$

定义磁荷密度 $\rho_m = -\nabla \cdot \mathbf{M}$ ，则

$$\nabla^2 \psi_m = -\rho_m$$

这就是磁标势的泊松方程。它与静电泊松方程 $\nabla^2 \psi = -\rho/\varepsilon_0$ 在数学形式上完全一致，只是将电荷换成了“磁荷”。

但要注意，这里的“磁荷”不是真实的磁单极子，而是磁化介质等效的束缚磁荷。它只出现在介质内部或表面，永远不会孤立存在。磁标势的引入是一种数学技巧，它把磁化介质的问题转化为类似于静电学的问题来求解，

大大简化了许多实际计算——比如永磁体的磁场分布、磁路的设计等。不过，对于磁单极子的磁荷，暂时没有实践证据证明其存在，究竟是否存在，本书成书之年尚无定论，有待后人探索。

磁标势的存在依赖于区域的选择。如果区域内存在自由电流，即 $\nabla \times \mathbf{H} \neq 0$ ，磁标势就不能全局定义。这与静电势可以全局定义形成对比：静电场是无旋的，电势差与路径无关；静磁场在有电流的区域是有旋的，磁标势与路径有关，是多值函数。这种“路径依赖性”反映了磁场涡旋结构的本质——你必须绕着电流转一圈，才能感受到场的完整面貌。

磁标势的引入体现了矛盾的普遍性与特殊性的统一。泊松方程是普遍的数学结构，它在静电学、静磁学、引力场乃至热传导中反复出现；但每一次出现，其物理内涵都是特殊的——静电势描述的是电荷的能量属性，磁标势描述的是磁化介质的等效属性，二者不能混为一谈。数学形式的统一掩盖不了物理内容的差异，而物理内容的差异又通过数学形式的统一获得了可比较、可迁移的表达方式。这正是理论与实践、普遍与特殊辩证关系的生动体现。

还要看到，磁场无源性的实验基础至今坚实：人类从未发现磁单极子。但这不等于磁单极子一定不存在。狄拉克从量子力学角度预言，如果磁单极子存在，电荷将是量子化的。这一预言把磁单极子问题与电荷量子化问题联系起来，至今仍是粒子物理学的重要探索方向。理论的开放性——承认现有规律有其适用范围，同时为超出范围的可能性预留空间——是科学健康发展的标志，也是辩证法反对形而上学绝对化的具体表现。

5.3 电磁感应到麦克斯韦方程组

库仑用扭秤称量了两个带电小球之间的力，奥斯特在课堂演示中看见通电导线旁的小磁针突然偏转。两个发现相隔三十五年，却各自开辟了一片天地。从库仑定律生长出高斯定理，电场的源结构被锁定：电荷发散电场线，正电荷是源，负电荷是汇。从奥斯的电流磁效应生长出毕奥-萨伐尔定律，再凝结为安培环路定理，磁场的涡旋结构也被锁定：电流是磁场的涡旋中心，磁感线永远绕着电流打转。到这一步，电有电的规律，磁有磁的规律，两套理论并行不悖，各自圆满。

但圆满里藏着一个前提：一切都不要动。电荷静止，电场才不随时间变化；电流恒定，磁场才不随时间变化。高斯定理说电场的散度正比于电荷密度，安培定理说磁场的旋度正比于电流密度，这两个关系都只适用于此时此刻的一张快照。如果拍下一张照片，电荷和电流都凝固在那一瞬，高斯定理和安培定理精确成立。可自然界从不为任何人凝固。电荷在移动，电流在变化，发电机在转动，变压器在嗡鸣，电磁波正从每一部手机的天线里向外奔涌。静止是实验室里人为维持的特例，运动才是世界的常态。

更关键的是，静与动的区别不只是快慢，而是质的跳跃。在静态世界里，电场和磁场各管各的：电荷产生电场，电流产生磁场，两种场互不干扰，像两条平行铁轨。一旦允许变化，铁轨就交叉了——变化的磁场能生出电场，变化的电场也能生出磁场。电与磁不再是两个独立王国，而是一个统一体的两面。这个统一不是谁把谁吞并，而是暴露了静态理论刻意压抑的内在联系。静态理论在其范围内依然有效，但它把电与磁的血缘关系隐藏了，仿佛它们是陌生人。只有让运动进入视野，血缘才会显现。

1820 年奥斯特发现电流能使磁针偏转，证明了电可以生磁。此后十二年里，法拉第试图寻找反向效应：磁能不能生电？他反复实验，把磁铁靠近线圈，把线圈套在磁铁上，检流计始终不动。直到 1831 年，他把磁铁猛地插进铜线圈——指针跳动了。拔出——反向跳动。静止——回到零位。关键不在磁铁，不在线圈，而在那个“插”和“拔”的动作，在磁通量的变化。磁铁不动，什么都没有；磁铁一动，电就涌现。

但这里冒出了一个令人不安的问题。线圈中没有电池，没有静电荷堆积，导线两端测不到稳定的电势差。按照前两节建立的框架，推动电荷需要电场，而电场是保守场，沿闭合回路做功为零。可现在电荷确实在流动，回路中确实有电流。是什么力在推动它们？

答案藏在电动势的定义里。电动势是单位正电荷沿闭合回路移动时非静电力所做的功：

$$\mathcal{E} = \oint_C \mathbf{E}_{\text{非静电}} \cdot d\mathbf{l}$$

在静电学中，这个积分恒为零，因为静电场无旋，没有非静电力。但法拉第的实验中，磁铁的运动提供了某种“推动”，使电荷持续流动。法拉第把这个推动量化为磁通量的变化率：

$$\mathcal{E} = -\frac{d\Phi_B}{dt}$$

负号是楞次定律。磁铁插入线圈，线圈中涌出的电流会产生一个磁场，方向恰好阻碍磁铁的插入。拔出时，感应磁场又挽留。这不是线圈有了意志，而是能量守恒的铁律。如果感应电流的方向反过来，加速磁通量的变化而不是阻碍它，能量就会无中生有，永动机就能运转。负号是能量守恒的数学表达，不是神秘的目的论。

把两个等式连起来：

$$\oint_C \mathbf{E}_{\text{非静电}} \cdot d\mathbf{l} = -\frac{d}{dt} \int_S \mathbf{B} \cdot d\mathbf{S}$$

左边是电场沿闭合路径的环流，右边是穿过该路径所围曲面的磁通量变化率。在静电世界里，左边恒为零，因为静电场无旋。现在磁场在变化，右边不再为零，左边也跟着不为零了。

这个等式值得多看几眼。它不仅仅是一个新发现，而是一个更一般规律的显现。当磁场不随时间变化时，右边为零，左边也回到零——恰好是静电场无旋的条件。这意味着静电场的保守性不是被“推翻”了，而是被包含在一个更大的框架里：它是“变化率为零”时的特例。就像一条河流，冻结时是冰，流动时是水，冰不是错了，只是水的一种静止形态。静电场的无旋性也不是错了，只是电场在“磁场不变”条件下的表现。当条件改变，同一种物质展现出新的面貌。

这意味着变化的磁场在空间激发了一种全新的电场——不是由电荷产生的电场，而是一种非静电的电场，它的电场线自我闭合，不始于任何正电荷，不终于任何负电荷。静电场的电场线从高电势走向低电势，像水从高处流向低处；感应电场的电场线却绕成闭合的环，像漩涡，没有起点也没有终点。这种电场正是我们在前两节中从未遇到过的东西。

法拉第定律不是实验室里的古董。今天，电磁炉的线圈中通入高频交变电流，产生快速变化的磁场，变化的磁场在金属锅底激发涡旋电场——正是我们刚才分析的、电场线自我闭合的非静电场。涡旋电场在金属内部驱动涡流，涡流因电阻发热，把食物煮熟。这里值得注意：很多人以为电磁炉是“磁直接加热”，实际上磁只是中介，真正做功的是电场。磁变生电，电再变

热，两步转化，缺一不可。如果锅底是非金属，涡旋电场无法驱动电流，热量就无从产生。

但涡流不总是受欢迎的。变压器铁芯处在交变磁场中，整块硅钢里会激起涡流，绕着磁通打转，把电能变成废热。工程师的做法是把铁芯切成一片片薄的硅钢片，每片表面涂绝缘漆，再叠压在一起。涡流被限制在每一片狭窄的截面里打转，路径短、电阻大、电流小，发热就降下来了。电机铁芯、电抗器磁路，凡是交变磁场中的金属结构，都得这么处理——切碎、隔离、阻断通路，不是与规律对抗，而是顺着规律找缝隙。

但这引出了一个更深层的问题。电场和磁场的结构差异不是偶然的，而是根植于自然界的基本不对称。电荷可以单独存在，正电荷和负电荷可以分离，所以电场有源有汇，可以无旋的；磁单极子迄今未被实验发现，磁感线永远闭合，磁场必然有旋。这种不对称在静态中被当作“电和磁是两种东西”的证据，在动态中却显示出另一种意义：正因为电场可以无旋，它才获得了被“打破”的余地——变化的磁场给它注入了旋度，而磁场自身始终有旋，只是旋度的来源从电流扩展到了变化的电场。

运动不是抹平了电与磁的差异，而是让各自的特殊性在相互作用中重新显现。电场在静态中可以无旋的，在动态中被迫获得旋度；磁场在静态中只能由电流激发，在动态中还能被变化的电场激发。每一种场都保留了自身的结构性特征，却在新的条件下展现出新的可能。这不是对称性的恢复，而是各自的特殊性在更广阔的舞台上展开。

法拉第定律完成了磁变生电。但对称性在追问：电变能否生磁？静态理论中，安培环路定理给出了答案：

$$\oint_C \mathbf{B} \cdot d\mathbf{l} = \mu_0 I$$

电流是磁场的涡旋源，只有电荷的定向运动才能激发磁场。这个结论在恒定电流中牢不可破。

19 世纪中叶，电报工程的大规模展开，使信号传输成为了亟待解决的时代课题，这为电磁学统一的研究提供了丰厚的土壤。

让我们考虑一个正在充电的电容器：导线中有电流流向极板，极板之间却没有电荷移动——那里是真空或者电介质，传导电流中断了。如果取一个回路包围极板，按照安培定理，回路内部没有传导电流，因此磁场环流应该为零。可电荷正在极板上堆积，极板间电场正在增强，这个变化过程难道不产生磁场吗？

如果严格执行安培定理，电容器极板之间的磁场就是零。但这与电荷守恒矛盾：电流在导线里流动，到了极板处突然“断掉”，电荷却在极板上持续积累。电流不是稳恒的，安培定理的静态形式在这里裂开了。

麦克斯韦盯着这个裂缝。他意识到，极板间虽然没有传导电流，但有一样东西在变化——电场。电通量随时间增长，这种增长本身应该等效于一种“电流”，填补传导电流中断造成的空白。他把这个假设写下来：

$$\mathbf{J}_d = \varepsilon_0 \frac{\partial \mathbf{E}}{\partial t}$$

这不是真正的电荷流动，没有粒子在极板间奔跑。但它在数学上完成了电流的连续性：导线里的传导电流，加上极板间的位移电流，总和保持不间断。修正后的安培-麦克斯韦定律：

$$\oint_C \mathbf{B} \cdot d\mathbf{l} = \mu_0 \left(I + \varepsilon_0 \frac{d\Phi_E}{dt} \right)$$

微分形式更简洁：

$$\nabla \times \mathbf{B} = \mu_0 \mathbf{J} + \mu_0 \varepsilon_0 \frac{\partial \mathbf{E}}{\partial t}$$

这个假设在 1865 年没有实验支持。它不是从现象中归纳出来的，也不是从更基本的公理中演绎出来的。它是理论自洽性的逼迫——电荷守恒必须成立，安培定理必须推广，电场变化必须获得与电流同等的地位。麦克斯韦不是在记录自然，而是在修补理论的裂缝，裂缝却指向了自然的新维度。

这里需要停下来想一想。在实验证实之前，没有人能够肯定位移电流确实存在，也没有人能否定它。它处于一种奇特的认识论地位：基于理性认识的合理预测，基于数学结构自洽性的判断，却悬置在经验验证之外。这不是盲目的猜测，而是理论思维的能动性——当实验尚未到达的地方，理性可以凭借内部的一致性要求，为未知画出地图。当然，地图不等于领土。位移电流后来在一系列电磁实验中被间接证实，但那是后话。在 1865 年，它只是一个假设，一个由理论裂缝逼出的必然性推断。这种推断的风险在于，它可能指向真实，也可能指向数学的虚构。科学的发展正是在这种风险中前行：理性走到经验前面，为实验照亮方向，同时也为自身留下被证伪的可能。

四个方程现在齐了。把它们写出来，不是为了堆砌公式，而是为了看清它们如何咬合在一起。

第一个方程，高斯定理：

$$\nabla \cdot \mathbf{E} = \frac{\rho}{\varepsilon_0}$$

它说电荷是电场的源。正电荷向外发散电场线，负电荷向内汇聚。电场有源有汇，始于正电荷，终于负电荷。这是电场最原始的“面孔”，从库仑定律一路继承下来，从未改变。

第二个方程，磁场的高斯定理：

$$\nabla \cdot \mathbf{B} = 0$$

它说磁场没有源。磁感线永远闭合，找不到起点和终点。这不是数学游戏，而是自然界的基本事实：磁单极子不存在，至少我们从未找到。磁场只能以涡旋的形式存在，不能孤立地“发出”或“终止”。

第三个方程，法拉第定律：

$$\nabla \times \mathbf{E} = -\frac{\partial \mathbf{B}}{\partial t}$$

它说变化的磁场激发电场的涡旋。电场不再只是电荷的附庸，它可以从磁场的变化中涌现出来。这个方程是电磁统一的第一个纽带：磁场的变化“生”出了电场的旋度。负号保留了楞次定律的能量守恒内核。

第四个方程，安培-麦克斯韦定律：

$$\nabla \times \mathbf{B} = \mu_0 \mathbf{J} + \mu_0 \epsilon_0 \frac{\partial \mathbf{E}}{\partial t}$$

它说电流和变化的电场共同激发磁场的涡旋。这是电磁统一的第二个纽带：电场的变化“生”出了磁场的旋度。位移电流的加入，让这个方程在电流中断的地方依然连续。

四个方程不是四块孤立的拼图，而是一个系统的四个侧面，彼此咬合，缺一不可。第一个和第二个方程描述“源”的结构：电场有源，磁场无源。第三个和第四个方程描述“涡”的结构：变化磁场生电场涡旋，变化电场和电流生磁场涡旋。源与涡、电与磁、静与动，在这个系统中被编织在一起。

电磁场不是粒子，不是经典意义上的东西。你不能把它握在手里，不能装进容器。但它的实在性不容否认：它携带能量，传递动量，施加力，以有限速度传播扰动。场的核心特征是关系性。

空间中每一点的场值不是独立的，而是通过微分方程与邻近点、与源、与整个空间的边界条件耦合在一起。高斯定理把局部电荷与全局通量关联；法拉第定律把空间某处的电场涡旋与别处的磁场变化关联；安培-麦克斯韦定律把电流和电场变化与磁场涡旋关联。不是先有独立的东西，然后才发生相互作用；而是关系本身构成了实在的基本形态。电荷和电流是场的源，但场一旦产生，就获得相对独立的动力学，以光速传播，带着能量远离源而去，这就形成了电磁波。源可以消失，场继续存在——电磁波在宇宙中传播数十亿年，携带远古星系的信息。这不是说物质消失了，而是说物质的形态比质点和刚体更丰富。场是一种物质形态，关系性是这种形态的存在方式。

理解这一点，是理解现代物理学的关键一步——也是理解为什么二十世纪的物理学必须走向相对论和量子力学的关键一步。库仑定律、毕奥-萨伐

尔定律、安培定律、法拉第定律，都在麦克斯韦方程组中找到了自己的位置：作为特定条件下的近似，作为整体结构的局部表现。电磁场理论的建立，标志着经典物理学的一座高峰。

但高峰之上还有迷雾。我们讲电与磁是统一体的两面，讲它们相互转化、相互依存，但这个统一仍然是不对称的。电荷可以单独存在，磁单极子至今未被发现；电场可以无旋，磁场必然有旋。这种不对称不是偶然的缺陷，而是暗示着更深层的结构尚未被触及。

如果在未来的某一天，人们找到了磁单极子，那么麦克斯韦方程组将会被改写。高斯定理中磁场的散度不再为零，而是正比于磁荷密度：

$$\nabla \cdot \mathbf{E} = \frac{\rho_e}{\varepsilon_0}$$

$$\nabla \cdot \mathbf{B} = \mu_0 \rho_m$$

法拉第定律和安培-麦克斯韦定律也会加入磁流项，形成完美的对称：

$$\nabla \times \mathbf{E} = -\mu_0 \mathbf{J}_m - \frac{\partial \mathbf{B}}{\partial t}$$

$$\nabla \times \mathbf{B} = \mu_0 \mathbf{J}_e + \mu_0 \varepsilon_0 \frac{\partial \mathbf{E}}{\partial t}$$

四个方程两两配对：电的高斯定理与磁的高斯定理，电的涡旋方程与磁的涡旋方程。 ρ_e 和 $\mathbf{J}_e$ 是电荷密度和电流密度， ρ_m 和 $\mathbf{J}_m$ 是磁荷密度和磁流密度。电与磁在源与涡、静止与运动的每一个维度上都获得平等的地位。到了那一步，电与磁将不再是“一个产生另一个”的层级关系，而是互为对方的相对论效应——运动中的电荷产生磁场，运动中的磁荷产生电场，在洛伦兹变换下相互渗透、相互生成。

这说明，真正的统一不是差异的抹平，而是差异在更高层次上的相互生成。但我们必须诚实：在今天，磁单极子仍然只是一个理论预言，一个尚未被实验证实的猜想。我们写下的四个方程，我们讲述的统一故事，都建立在“磁单极子不存在”这一经验事实之上。这不是理论的失败，而是时代的局限——每一代人都只能在自己的经验边界内建立理论，同时把边界之外的问题留给后人。麦克斯韦在 1865 年无法预见相对论，正如我们在今天无法确知磁单极子的命运。科学的火炬正是在这种局限与超越的交替中传递的。也许，正在阅读这本书的某一位读者，将在未来的某一天，在实验室的深处，在宇宙射线的痕迹中，在粒子对撞的碎片里，找到那个改变一切的证据。如果那一天到来，本书的这一页将成为历史；如果那一天迟迟不来，这一页将

继续等待——等待被超越，被改写，被重新理解。这正是科学最诚实、也最激动人心的姿态。

5.4 电磁波与电磁场的能量

手机放在无线充电桌上，没有导线连接，屏幕却亮了。微波炉里的转盘慢悠悠转着，腔体里没有火焰，食物却从内部发烫。太阳隔着一亿五千万公里的真空，把地球晒得暖洋洋。这些再平常不过的现象，背后有一个共同的问题：能量是怎么过去的？

在静电学和静磁学里，能量似乎附着在电荷和电流上。点电荷在电场中受力，导线在磁场中受力，能量通过力做功传递。但电磁波不一样——它穿越真空，那里没有电荷，没有导线，没有任何可供攀附的介质。能量必须自己走过去，靠场本身。

麦克斯韦方程组已经给出了场的动力学。真空中没有自由电荷，也没有传导电流，四个方程退化为：

$$\begin{aligned}\nabla \cdot \mathbf{E} &= 0 \\ \nabla \cdot \mathbf{B} &= 0 \\ \nabla \times \mathbf{E} &= -\frac{\partial \mathbf{B}}{\partial t} \\ \nabla \times \mathbf{B} &= \mu_0 \varepsilon_0 \frac{\partial \mathbf{E}}{\partial t}\end{aligned}$$

前两式说，电场和磁场在真空中都没有源，磁感线闭合，电场线也闭合——至少在这个框架内，找不到发端和终点。后两式说，变化的磁场生出电场的涡旋，变化的电场也生出磁场的涡旋。

现在我们要问：如果电场和磁场相互催生，它们能不能脱离电荷和电流，独自在空间中传播？

先看电场。取电场的旋度方程，再取一次旋度：

$$\nabla \times (\nabla \times \mathbf{E}) = \nabla \times \left(-\frac{\partial \mathbf{B}}{\partial t} \right) = -\frac{\partial}{\partial t} (\nabla \times \mathbf{B})$$

左边用矢量恒等式展开： $\nabla \times (\nabla \times \mathbf{E}) = \nabla(\nabla \cdot \mathbf{E}) - \nabla^2 \mathbf{E}$ 。

真空中 $\nabla \cdot \mathbf{E} = 0$ ，所以只剩 $-\nabla^2 \mathbf{E}$ 。右边代入磁场的旋度方程：

$$-\nabla^2 \mathbf{E} = -\frac{\partial}{\partial t} \left(\mu_0 \varepsilon_0 \frac{\partial \mathbf{E}}{\partial t} \right) = -\mu_0 \varepsilon_0 \frac{\partial^2 \mathbf{E}}{\partial t^2}$$

负号抵消，得到：

$$\nabla^2 \mathbf{E} = \mu_0 \varepsilon_0 \frac{\partial^2 \mathbf{E}}{\partial t^2}$$

这是电场满足的波动方程。空间中每一点的电场，随时间按二次导数变化，同时在空间中以拉普拉斯算子扩散。

再看磁场。取磁场的旋度方程，再取一次旋度：

$$\nabla \times (\nabla \times \mathbf{B}) = \nabla \times \left(\mu_0 \varepsilon_0 \frac{\partial \mathbf{E}}{\partial t} \right) = \mu_0 \varepsilon_0 \frac{\partial}{\partial t} (\nabla \times \mathbf{E})$$

左边展开： $\nabla \times (\nabla \times \mathbf{B}) = \nabla(\nabla \cdot \mathbf{B}) - \nabla^2 \mathbf{B}$ 。

真空中 $\nabla \cdot \mathbf{B} = 0$ ，只剩 $-\nabla^2 \mathbf{B}$ 。

右边代入法拉第定律：

$$-\nabla^2 \mathbf{B} = \mu_0 \varepsilon_0 \frac{\partial}{\partial t} \left(-\frac{\partial \mathbf{B}}{\partial t} \right) = -\mu_0 \varepsilon_0 \frac{\partial^2 \mathbf{B}}{\partial t^2}$$

负号同样抵消，得到：

$$\nabla^2 \mathbf{B} = \mu_0 \varepsilon_0 \frac{\partial^2 \mathbf{B}}{\partial t^2}$$

电场和磁场满足完全相同的波动方程。它们不是各自独立的振动，而是同一波动过程的两个投影。电场波动时磁场被迫波动，磁场波动时电场被迫波动，谁也不能丢下谁单独存在。

波动方程有一个特征速度。对比标准波动方程 $\nabla^2 \psi = \frac{1}{v^2} \frac{\partial^2 \psi}{\partial t^2}$ ，立刻读出：

$$v = \frac{1}{\sqrt{\mu_0 \varepsilon_0}}$$

这里要停下来想一想。真空介电常数 ε_0 来自库仑扭秤实验，真空磁导率 μ_0 来自电流磁效应的精密测量。两个数分别从电学和磁学的独立实验中得来，谁也不依赖谁。可它们的组合，却给出了一个速度——而且这个速度恰好就是光速。

这不是巧合。麦克斯韦在 1865 年算出这个数值时，手边已经有斐索和傅科测得的光速数据。两个数字吻合得惊人。这意味着，光不是某种独立于电磁现象的神秘存在。光就是电磁波！电、磁、光，三个看似独立的领域，在麦克斯韦方程组中汇成一条河流。

光速 $c = 1/\sqrt{\mu_0 \varepsilon_0}$ 的出现，还带来了一个更深层的问题。在牛顿力学中，速度是相对的——你追我赶，速度相加。但 c 不是从任何力学实验中拼凑出来的，它是电磁场方程自身的结构常数。它不需要参照系来定义自己，它定义了电磁扰动在空间中的传播速率。这个“不需要参照系”的特征，后来成为相对论的出发点。但在 1865 年，它只是方程中的一个数，安静地躺在那里，等待后人发现它的革命性。

现在看平面波解。设电场沿 x 方向振动，沿 z 方向传播：

$$\mathbf{E} = E_0 \cos(kz - \omega t) \hat{\mathbf{x}}$$

代入波动方程，得到 $\omega/k = c$ 。磁场由法拉第定律给出：

$$\nabla \times \mathbf{E} = -\frac{\partial \mathbf{B}}{\partial t}$$

计算旋度：

$$\nabla \times \mathbf{E} = \frac{\partial E_x}{\partial z} \hat{\mathbf{y}} = -kE_0 \sin(kz - \omega t) \hat{\mathbf{y}}$$

对时间积分：

$$\mathbf{B} = \frac{k}{\omega} E_0 \cos(kz - \omega t) \hat{\mathbf{y}} = \frac{1}{c} E_0 \cos(kz - \omega t) \hat{\mathbf{y}}$$

于是 $B = E/c$ ，磁场垂直于电场，也垂直于传播方向。电场、磁场、传播方向，三者两两正交，像一把相互垂直的坐标轴，在空间中以共同的速度平移。

这揭示了一个惊人的事实：电磁波是横波。声波是纵波，空气分子沿传播方向前后振动；水波是混合的，水面质点做椭圆运动。但电磁波不同——它的振动方向完全垂直于传播方向，在真空中没有纵向分量。这意味着电磁场不是“介质中的扰动”，而是空间本身在振动。电场和磁场不是某种物质的位移，它们是空间状态的周期性变化。

既然场在空间中传播，它必然携带能量。静电场中有能量密度，我们早已熟悉： $u_E = \frac{1}{2} \varepsilon_0 E^2$ 。静磁场中也有能量密度： $u_B = \frac{1}{2\mu_0} B^2$ 。在电磁波中，电场和磁场同时存在，总能量密度应该是两者之和：

$$u = \frac{1}{2} \varepsilon_0 E^2 + \frac{1}{2\mu_0} B^2$$

对于平面波， $B = E/c$ ，且 $c = 1/\sqrt{\mu_0 \varepsilon_0}$ ，所以：

$$\frac{1}{2\mu_0} B^2 = \frac{1}{2\mu_0} \frac{E^2}{c^2} = \frac{1}{2} \varepsilon_0 E^2$$

磁场贡献的能量密度，恰好等于电场贡献的能量密度。两者平分秋色，谁也不多占。这不是数学巧合，而是电磁对称性的体现：在真空中，电和磁在能量层面获得了完全平等的地位。静态时电场有源、磁场无源的不对称，在动态传播中被一种更高层次的对称所平衡。

但能量密度只回答了“这里有多少能量”，没有回答“能量往哪儿走”。一池静水有能量，但没有流动；一条河流有能量，也有方向。电磁波是河流，不是池塘。

为了描述能量流，我们需要一个矢量——大小表示单位时间通过单位面积的能量，方向表示能量传播的方向。这个量被称为坡印廷矢量：

$$\mathbf{S} = \frac{1}{\mu_0} \mathbf{E} \times \mathbf{B}$$

叉乘的方向恰好垂直于 $\mathbf{E}$ 和 $\mathbf{B}$ 所在的平面，指向波的传播方向。大小为 $S = EB/\mu_0 = E^2/(\mu_0 c) = \varepsilon_0 c E^2$ 。对于平面波，平均能流密度（对时间平均）为：

$$\langle S \rangle = \frac{1}{2} \varepsilon_0 c E_0^2$$

这正是光强的表达式。光强不是“有多少光”，而是“有多少能量正朝你涌来”。

现在考虑一个更一般的情形：空间中有电荷和电流，电磁场与物质相互作用。能量守恒必须被满足，但形式需要修正。场对电荷做功的功率密度是 $\mathbf{J} \cdot \mathbf{E}$ ——电流在电场中受力，单位体积内电荷漂移获得的功率。这些能量从哪里来？从电磁场中来。

通过计算可以得到：

$$\frac{\partial u}{\partial t} + \nabla \cdot \mathbf{S} = -\mathbf{J} \cdot \mathbf{E}$$

这就是电磁能量守恒的局域形式。左边第一项是能量密度的变化率，第二项是能量流的散度——表示能量从该点流出或流入。右边是场对物质做功的功率，取负号意味着能量从场转移到电荷。

这个方程的结构与电荷守恒 $\partial \rho / \partial t + \nabla \cdot \mathbf{J} = 0$ 惊人地相似。电荷守恒说，电荷不能凭空产生，只能流走；能量守恒说，电磁能量不能凭空产生，只能流走或转化为物质的动能。但电磁场的能量有一个独特之处：它可以在真空中流动，不需要物质载体。电荷守恒中的电流 $\mathbf{J}$ 必须依附于电荷，但坡印廷矢量 $\mathbf{S}$ 可以在 $\mathbf{J} = 0$ 的区域独立存在。

这意味着，电磁场不仅仅是描述力的工具，它本身就是一种物理实在——携带能量、传递动量、施加力，以有限速度传播扰动。电磁波在宇宙中穿行数十亿年，不需要任何介质支撑，把远古星系的信息带到我们的望远镜里。这不是比喻，是能量守恒方程允许的事实：源可以消失，场继续存在，带着能量远去。

但这里有一个边界需要诚实面对。坡印廷矢量给出了能量流的方向和大小，但在某些静态情形下，它的解释会变得微妙。比如一个静止的带电粒子附近放置一个磁偶极子，电场和磁场都不为零，坡印廷矢量也不为零，似乎有能量在“打转”。但没有能量实际流动，系统处于静态平衡。这说明 $\mathbf{S}$ 作为“能量流”的物理意义，在动态传播中最清晰，在静态配置中需要谨慎解读。

更深层的问题在于：能量究竟是什么？在力学中，能量是物体运动的度量；在电磁学中，能量是场的属性，分布在空间中，可以脱离物质独立流动。“能量”概念的扩展，都不是对旧定义的否定，而是在新的物理情境中揭示其更丰富的内涵。能量的本质不是某种神秘的流体，而是物理系统做功能力的度量——这个度量在不同的理论层次上呈现出不同的形态，但守恒的要求始终不变。

从库仑定律的质点相互作用，到静电场的能量定域化，再到电磁波的独立能量传播，认识经历了一次又一次的跃迁。能量从“物体之间的交易品”，变成了“空间本身的属性”，最终变成了“可以脱离源而传播的实在”。这不是唯心主义的“能量崇拜”，而是物理实在性的扩展：物质的存在方式比质点和刚体更丰富，场也是一种物质形态，能量在场中的流动是这种形态的存在方式。

麦克斯韦方程组因此标志着一个转折点。它不仅统一了电、磁、光，而且第一次给出了场的独立动力学——场不再是被动的背景，而是能动的实体，遵循自己的方程，携带自己的能量，以光速传播自己的扰动。这为相对论准备了舞台：如果电磁场有独立的速度常数 c ，那么伽利略变换下的速度叠加就必须被修正。而且我们不禁要问：如果场携带能量，那么能量是否也是量子化的？这就为量子力学预留了入口。

电与磁在波动中相互生成，场与能量在传播中相互转化，局部变化与全局守恒相互约束。电磁波的能量规律告诉我们，物理学的统一不是把不同的现象塞进同一个公式，而是揭示它们共享的深层结构。

5.5 光也是一种电磁波

阳光穿过窗棂，在地板上投下条纹。肥皂泡飘着，表面流转着彩虹。眼镜片后的世界，边缘泛着紫蓝的晕。这些再平常不过的光现象，背后有一个曾经困扰物理学两百年的问题：光究竟是什么？

牛顿说光是微粒，像子弹一样直线飞行，碰到镜面反弹，进入棱镜折射。惠更斯说光是波动，像水波一样扩散，遇到障碍物绕弯，穿过小孔散开。两派争论不休，微粒说解释直线传播和反射折射很顺手，波动说解释干涉和衍射更漂亮。但谁也没有决定性的证据——直到麦克斯韦。

麦克斯韦方程组预言了电磁波，速度恰好是光速。这不是巧合，而是同一枚硬币的两面：光不是独立于电磁现象的神秘实体，光就是电磁波。电场和磁场在空间中相互催生、以光速传播的波动，当它的频率落入人眼可见的范围，我们就称之为光。

这个统一不是把光“降级”为电磁波，而是把电磁波“升级”为光的本质。牛顿的微粒和惠更斯的波动，在麦克斯韦的框架中找到了各自的位置：光的直线传播是波动在短波长极限下的近似，反射折射是电磁边界条件的结果，干涉衍射是波动相干叠加的表现。每一种光现象，都是电磁波在特定条件下的面貌。

但统一不是抹平差异。光作为电磁波，有其独特的规定性：它是横波，电场和磁场的振动方向垂直于传播方向；它在真空中以恒定速度 c 传播，不需要任何介质；它的频率范围极宽，从射电波的低频到伽马射线的高频，可见光只是其中窄窄的一小段。这些规定性不是“光的特权”，而是电磁波普遍结构的特殊显现。

让我们从偏振开始。电磁波是横波，意味着电场矢量在垂直于传播方向的平面内振动。如果振动始终沿同一方向，称为线偏振；如果方向旋转而大小不变，称为圆偏振；如果方向旋转同时大小变化，称为椭圆偏振。偏振片只允许特定方向的电场通过——这不是光“选择”了方向，而是电磁场与物质相互作用各向异性的表现。偏振的存在直接证明了光的横波性。纵波没有偏振，因为振动方向与传播方向重合，不存在“垂直平面内的方向选择”。声波是纵波，你无法给声波“偏振”。光的偏振因此是电磁波结构的最直接证据：电场和磁场有方向性，这种方向性赋予了光一种“结构性”，区别于无方向的纵波。

这种结构性在反射和折射中表现得淋漓尽致。光从空气射入玻璃，一部分反射，一部分折射。电磁场的边界条件——电场切向分量连续，磁场切向分量连续——迫使光在界面处改变方向。菲涅尔公式给出了反射系数和透射系数，它们依赖于入射角、偏振方向，以及两种介质的折射率。折射

率 $n = c/v$ 是光在介质中的速度与真空中速度的比值。从麦克斯韦方程组可以导出 $n = \sqrt{\epsilon_r \mu_r}$ ，即介质的相对介电常数和相对磁导率的组合。这意味着，光在玻璃中变慢，不是因为玻璃“阻碍”了光，而是因为电磁场与介质中束缚电荷的相互作用改变了场的有效传播速度。光不是穿过空无一物的空间，而是在物质的电磁响应中重新组织自己。

全反射是一个极端情形。当光从光密介质射向光疏介质，入射角超过临界角时，没有折射光，全部能量反射回光密介质。但电磁场的边界条件仍然要求：在光疏介质一侧，存在一种“倏逝波”——振幅随深度指数衰减，不向介质内部传播净能量，却维持了场的连续性。倏逝波不是“泄漏”的光，而是边界条件强迫产生的场结构。它提醒我们：电磁场不是“要么在、要么不在”的，而是可以在边界处以过渡形态存在。

干涉是波动最鲜明的指纹。杨氏双缝实验中，光通过两条狭缝，在屏幕上形成明暗相间的条纹。明纹处两束光同相叠加，电场振幅加倍，光强变为四倍；暗纹处反相抵消，电场为零，光强为零。这不是光的“自我干涉”，而是电磁场的相干叠加：两束光的电场在空间每一点代数相加，遵循波动方程的线性。干涉的关键是相干性——两束光必须有稳定的相位关系。普通光源发出的光，相位随机跳跃，不同原子发出的光不相干。激光的出现改变了这一点：受激辐射使大量原子同步发光，相位高度一致，干涉变得容易。相干性不是光的本质属性，而是光源组织方式的产物。这再次说明：光的现象是电磁波在特定条件下的显现，条件变了，现象就变。

光的传播还存在衍射的现象。光遇到障碍物或小孔，不沿直线传播，而是弯进几何阴影区。单缝衍射中，缝宽与波长可比时，光强分布呈现中央亮纹、两侧次级亮纹的图样。

要解释干涉和衍射，需要一个更基本的原理——惠更斯原理。惠更斯提出：波前上的每一点都可以看作一个新的次级波源，这些次级波源发出的子波在空间中相干叠加，形成新的波前。这个原理的直观意义在于：波的传播不是波前“整体平移”，而是波前上每一点都向四面八方“发射”子波，这些子波的包络面构成了下一时刻的波前。惠更斯原理不是从麦克斯韦方程组推导出来的，而是波动现象的一个基本构造。它的威力在于：给定某一时刻的波前，就可以通过几何作图预测下一时刻的波前；它的局限在于，原始版本无法解释为什么波只向前传播、不向后传播（后来的菲涅尔补上了倾斜因子，修正了这一点）。但惠更斯原理的核心洞见——波前上的每一点都是次级波源——是理解衍射的钥匙。

按照惠更斯原理：缝面上每一点都是次级波源，这些子波在空间中相干叠加，某些方向增强，某些方向抵消。衍射不是光“绕弯”，而是波动方程在边界条件下的自然解。惠更斯原理给出了衍射的定性图像，菲涅尔-基尔

霍夫衍射积分给出了定量的计算。

衍射的极限值得深思。当缝宽远大于波长，衍射效应消失，光恢复直线传播——几何光学的近似成立。当缝宽与波长可比，衍射图样清晰。当缝宽远小于波长，光几乎被完全阻挡，只有极少量穿透。三种极限，三种行为，对应着波动在不同尺度下的面貌。几何光学不是“错了”，而是波动光学在短波长极限下的近似。

光谱是光的指纹。不同元素发出的光，具有特定的波长组合，像条形码一样标识着原子的内部结构。牛顿用棱镜把白光分解成彩虹，夫琅禾费用光栅把太阳光分解成暗线光谱。这些谱线不是光的“装饰”，而是原子中电子运动的电磁印记。光作为电磁波，其频率与原子内部运动的频率共振，吸收或发射特定波长的能量。

从麦克斯韦方程组到光的现象，认识经历了一次完整的螺旋。光从神秘的“自然之光”，被还原为电磁波动；电磁波动又在与物质的相互作用中，展现出偏振、反射、干涉、衍射、光谱等丰富面貌。每一次还原都不是对现象的否定，而是在更深层次上把握现象的统一性。还原与丰富，不是对立的，而是辩证的：越深入本质，越能解释多样性；越把握多样性，越能验证本质的普遍性。

光的故事告诉我们：物理学的统一不是把万物塞进同一个公式，而是揭示不同层次上的相互关联。光是电磁波，电磁波是场的波动，场是空间的物理状态——这个链条的每一环，都既依赖于下一环的支撑，又拥有上一环无法还原的独特性。统一不是消除差异，而是让差异在更高层次上获得意义。

经典电磁学至此建立。从库仑定律的静电场，到毕奥-萨伐尔的静磁场，到电磁感应的动力学，到麦克斯韦方程组的统一，再到电磁波与光的本质——这是一个完整的建筑。但建筑有边界，理论有适用范围。经典电磁学在其边界内精确成立，在边界外需要新的框架。知道边界，才知道什么时候该换工具。

Part VI

几何光学

6.1 光的几何性质

激光笔射出一道红线，笔直地穿过烟雾，在墙上留下一个亮斑。日食时，月亮的影子精准地落在地球上，边缘锐利得像刀切。这些现象背后有一个朴素的信念：光沿直线传播。这个信念如此根深蒂固，以至于古人用“光线”来定义直线——两点之间，光走得最快的那条路径。

但光真的沿直线传播吗？

前面我们看到，光遇到小孔会衍射，绕过障碍物会弯曲。波动光学告诉我们，直线传播只是短波长极限下的近似。那么，在什么条件下，这个近似足够好？好到工程师可以放心地用它设计望远镜、显微镜、眼镜片呢？

答案藏在波长与系统尺度的比值里。可见光波长约五百纳米，眼镜片的曲率半径以厘米计，望远镜的口径以米计。波长比特征尺度小五个数量级以上，衍射效应可以忽略，光的行为就像沿直线飞行的微粒。这不是光的本质变了，而是我们的观察尺度变了。在合适的尺度上，复杂的波动可以被粗糙的射线替代，而不失实用性。

几何光学就是建立在这个近似上的。它不关心电场和磁场的振动，不关心波动方程的解，只关心一条抽象的几何对象——光线。光线没有宽度，没有波长，只有方向和路径。它从光源出发，在镜面反射，在界面折射，在透镜汇聚或发散。

这种简化是认识论的跃迁：从物理实在（电磁波）到数学抽象（射线），从波动方程的偏微分方程到几何路径的常微分方程。简化不是退步，而是在特定条件下对复杂性的合理压制。知道什么时候可以简化，比拒绝简化更接近智慧。

让我们从反射定律开始。光射向镜面，入射角等于反射角。这个定律在欧几里得时代就已经知道，但直到麦克斯韦方程组建立，人们才理解它的电磁根源：边界条件要求电场切向分量连续，磁场切向分量连续，这些连续性条件在宏观尺度上表现为反射定律。几何光学不追问边界条件，它直接接受反射定律作为公理，然后推导光线的路径。

平面镜是最简单的情形。物体发出的光线经镜面反射进入眼睛，眼睛逆着光线回溯，认为光线来自镜后的某一点——虚像。虚像不是真实光线的汇聚点，而是人脑对光线方向的反推。平面镜的像与物体等大、等距、左右互换。左右互换是一个有趣的现象：不是上下颠倒，而是左右互换。这是因为镜面垂直于水平面放置，水平方向被翻转，垂直方向保持不变。如果镜面水平放置（如水面），上下也会颠倒。

球面镜稍微复杂。凹面镜汇聚平行光于焦点，凸面镜发散平行光，焦点在镜后。

球面镜的成像公式 $\frac{1}{u} + \frac{1}{v} = \frac{1}{f}$ 可以从反射定律和小角度近似导出。这个公式是几何光学的基本工具，但它有一个隐藏的前提：光线必须近轴，即与光轴的夹角足够小。大角度入射时，球面像差出现——平行光不再汇聚于一点，而是形成一个模糊的斑。像差不是反射定律错了，而是球面几何与理想聚焦之间的张力。抛物面镜可以消除球面像差，因为抛物线的几何性质恰好使平行光汇聚于焦点。这就是为什么望远镜的主镜用抛物面，而不是球面。

折射比反射更富戏剧性。光从空气进入水，方向突然弯折。折射定律 $n_1 \sin \theta_1 = n_2 \sin \theta_2$ 给出了弯折的角度，但为什么光要弯折？费马原理提供了一个统一的视角：光从一点到另一点，走的是耗时最短的路径。在均匀介质中，直线最短，所以光沿直线传播；在不同介质的界面上，弯折可以缩短总时间，所以光弯折。

费马原理的表述是：光程 $\int n ds$ 取极值。光程是几何路径长度乘以折射率，它把不同介质中的路径折算为等效的真空路径。光不走距离最短的路，而走光程最短的路——在折射率高的介质中，光速慢，光不愿意多走，所以尽量“借道”折射率低的介质。这个“不愿意”不是光有意志，而是波动方程在短波长极限下的必然结果：不同路径的相位叠加，光程最短的路径附近相位变化最慢，贡献最大，其他路径因相位快速振荡而相互抵消。

费马原理把反射定律和折射定律统一在一个框架下。反射是折射的特例——两种介质的折射率相同，光程极值要求入射角等于反射角。折射是费马原理的直接推论——光程对路径参数的变分为零，导出斯涅尔定律。统一的代价是抽象：费马原理不直接涉及光线在界面上的行为，而是全局地优化整条路径。从局部定律到全局原理，认识上升了一个层次。

但费马原理的野心不止于此。它说光程取“极值”，不一定是极小值，也可能是极大值，甚至是稳定值。凹面镜的焦点附近，光程取极小；某些复杂光学系统中，光程取极大。这种“极值”而非“极小”的表述，释放了费马原理的普遍性。它不再是一个关于光的特殊原理，而是一个关于“路径选择”的普遍数学结构。

透镜是折射的集大成者。凸透镜中间厚、边缘薄，平行光汇聚于焦点；凹透镜中间薄、边缘厚，平行光发散，焦点在镜前。透镜的成像公式 $1/u + 1/v = 1/f$ 与球面镜形式相同，但物理内容不同：透镜利用两次折射（空气到玻璃，玻璃到空气）改变光的传播方向，而球面镜利用一次反射。

透镜也有像差。球面像差：边缘光线和近轴光线聚焦在不同位置。色差：不同波长的光折射率不同，白光通过透镜后色散成彩虹。彗差：轴外点光源的像拖出尾巴，像彗星。这些像差不是透镜“错了”，而是几何光学理想化假设的破裂。消色差透镜用两种不同玻璃组合，让一种玻璃的色散抵消另一种的色散；非球面透镜用更复杂的面形消除球面像差。每一次修正都不是对

几何光学的否定，而是在其框架内逼近理想。

我们的眼睛本身就是一个精密的光学系统。角膜和晶状体共同作用，把外界光线聚焦在视网膜上。晶状体可以调节曲率，改变焦距，使不同距离的物体都能清晰成像——调节能力。随着年龄增长，晶状体硬化，调节能力下降，老花眼出现。近视是眼球过长，远处物体的像成在视网膜前；远视是眼球过短，近处物体的像成在视网膜后。眼镜片就是辅助透镜：凹透镜发散光线，矫正近视；凸透镜汇聚光线，矫正远视。隐形眼镜直接贴在角膜上，消除了眼镜片与眼睛之间的距离，视野更自然。

望远镜和显微镜是几何光学的工程巅峰。望远镜看远，物镜口径大、焦距长，收集尽可能多的光，汇聚于焦点；目镜再把这个焦点放大，供眼睛观察。放大率是物镜焦距与目镜焦距之比。但放大率不是唯一指标：口径决定集光能力和分辨极限。口径越大，能收集的光越多，能看到越暗的天体；口径越大，衍射极限越小，能分辨的细节越精细。这就是为什么天文学家不断建造更大的望远镜——从伽利略的口径几厘米，到凯克的口径十米，再到正在建设的三十米望远镜。

显微镜看近，物镜焦距极短，工作距离极小，把微小物体放大成实像；目镜再放大这个实像。放大率是物镜横向放大率与目镜角放大率的乘积。油浸物镜在物镜与标本之间填充高折射率油液，减少折射损失，提高数值孔径，从而突破空气介质的极限。电子显微镜走得更远：不用光，用电子波，波长比可见光短五个数量级，分辨率达到原子尺度。但电子显微镜已经不是几何光学的领地，它属于量子力学。

几何光学的边界由波长划定。当波长与系统尺度可比，衍射效应凸显，光线模型失效，必须回到波动方程。但这个边界不是突然的断裂，而是渐变的过渡。望远镜口径远大于波长，几何光学极好；单缝宽度与波长可比，衍射图样清晰；针尖尺度接近波长，几何光学完全崩溃。每一次过渡，都是量变引起质变的辩证实例。

几何光学的故事告诉我们：简化是认识的有力工具，但简化必须知道自己是简化。光线不是光的本质，而是光在特定条件下的有效描述。用光线设计望远镜，可以；用光线解释衍射，不行。理论的适用范围不是缺陷，而是理论的具体性。任何理论都在自己的尺度上为真，在更大的尺度上被修正。修正不是推翻，而是纳入更广阔的框架。

Part VII

热力学

7.1 分子动理论、理想气体定律和修正

烧水时壶盖噗噗跳动，夏天自行车胎莫名其妙地鼓胀，高压锅哧哧喷着白汽——这些再平常不过的热闹里，藏着物理学最漂亮的一场认识变革。它的核心只有一句话：热这东西，研究的不是单个质点，而是成群结队的分子，数量级动辄 10^{23} 。力学能算清一颗炮弹的抛物线，却算不清一杯水里 10^{25} 个水分子下一秒往哪儿跑。可当数量大到这个份上，奇迹发生了：单个分子的胡冲乱撞完全没法预料，整体却乖乖服从稳定的规律。偶然里硬生长出了必然，这就是统计规律最迷人的地方。偶然性背后始终藏着隐蔽的规律，布朗运动的故事把这层窗户纸捅了个透亮。

1827年，植物学家布朗在显微镜下发现，水里悬浮的花粉颗粒像着了魔似的抖个不停。没人推它，它也不是活物，可就是停不下来。这现象悬了近八十年，直到1905年爱因斯坦出手：花粉的抖动不是别的，正是周围水分子热运动随机碰撞的累积效应。1908年佩兰做实验验证，不仅测准了阿伏伽德罗常数，还实锤了原子分子的存在。你看，花粉动是现象，水分子撞是本质；现象从不遮蔽本质，反而把本质演给你看。工厂管道上那块温度表，读数背后站着 10^{23} 个分子的平均动能；医院护士给病人量体温，关心的也不是某个分子跑多快，而是这支“分子大军”的平均士气是否还撑得住生命的代谢。科学的本事，就在于教人穿透热闹，摸到底下的门道。

在前面的内容中，我们早已经得出：世界是物质的；运动是绝对的；矛盾是普遍存在的。分子动理论的底子其实就对应这三条：物质由大量分子组成；分子永不停息地乱动；分子之间有相互作用，大量分子的胡闹服从统计规律。从这儿出发，“热”不再是神秘的“热质”流来流去，而是分子机械运动的统计表现。一杯热水变凉，不过是水分子把动能撞给了空气分子；机械运动变成热，热再推回机械运动，电变热，热变电，不同层次的运动在特定条件下相互贯通。否认这种贯通，就会掉进“热质说”的形而上学泥潭；承认它，才算摸到了自然界的统一性。

我们不妨钻进一只边长为 L 的立方盒子，看看压强到底从哪儿来。盒里有 N 个质量为 m 的分子，挑一个看，它 x 方向的速度分量叫 v_x 。撞向器壁，弹性反弹，动量变化 $\Delta p = 2mv_x$ 。它在 x 方向来回跑，一趟 $2L$ ，耗时 $2L/v_x$ ，所以单位时间内撞同一面墙 $v_x/(2L)$ 次。这分子给墙的平均力就是 $f = mv_x^2/L$ 。 N 个分子一起撞，总力 $F = (m/L) \sum v_{ix}^2$ 。引入 x 方向速度平方的平均值 $\overline{v_x^2} = (1/N) \sum v_{ix}^2$ ，得 $F = Nm\overline{v_x^2}/L$ 。压强是单位面积的力，器壁面积 L^2 ，所以 $P = F/L^2 = Nm\overline{v_x^2}/V$ ，其中 $V = L^3$ 。分子运动各向同性，三个方向一样快， $\overline{v^2} = 3\overline{v_x^2}$ ，于是：

$$P = \frac{1}{3} \frac{Nm\overline{v^2}}{V} = \frac{2}{3} \frac{N}{V} \left(\frac{1}{2} m\overline{v^2} \right)$$

令 $n = N/V$ 叫分子数密度, $\bar{\varepsilon}_k = \frac{1}{2} m\overline{v^2}$ 叫分子平均平动动能, 就得到理想气体的压强公式:

$$P = \frac{2}{3} n \bar{\varepsilon}_k$$

这式子把宏观压强和微观动能拴在了一起。直觉里我们总觉得容器“具有”压强, 好像压强是器壁的静态属性; 可推导明明白白地告诉你, 压强是分子持续撞墙撞出来的动态结果。分子一停, 压强归零。运动是物质的根本属性, 这个式子就是一个例证——里头没有一项是静态的, n 是数密度, $\bar{\varepsilon}_k$ 是运动的度量。压强不是“热质”挤墙, 而是运动的物质跟运动的物质相互作用。

当然, 推导时我们要了个滑头: 假设器壁光滑、弹性碰撞、分子间没作用力、分子自己没体积。真实世界哪有这么干净? 但高温低压下, 分子间距大、动能高, 热运动是主要矛盾, 分子间力和分子体积暂时是次要矛盾。先抓住主要矛盾, 把数学骨架搭起来, 再回头填血肉, 这是物理学最老实的聪明。设计天然气管道, 工程师先用理想气体定律估算流量压降, 快速摸准数量级; 到了高压低温环节, 才请实际气体修正出场。一开始就堆砌全部因素, 复杂计算会淹没物理直觉, 反而寸步难行。

这公式解释起生活琐事来格外顺手。夏天气温一高, 汽车轮胎里的分子平均动能往上蹿, 体积变化不大, 压强自然跟着涨, 所以高速跑完夏天更容易触发胎压报警——轮胎厂做测试时, 必须按不同温度留足安全余量。高压锅更直观: 密闭加热, 分子动能增, 压强升, 水的沸点跟着往上走, 食物在更高温度下烹煮, 蛋白质变性、淀粉糊化都快得多。家里厨房天天上演的, 其实是最朴素的统计物理。潜水气瓶在常温下压强能到 200 个大气压, 单位体积分子数密度极高, 碰撞频率和总冲量巨大, 瓶身材料得扛住这种持续的高频冲击; 任何微观裂纹在高压下都可能扩展成灾难, 所以气瓶必须定期水压测试, 还严禁混充别种气体——不同气体分子质量 m 不同, 同样动能下产生的压强效应也不同。

把压强公式和实验确立的理想气体状态方程并排放, 就能摸到温度的底。分子动理论给出 $P = \frac{2}{3} n \bar{\varepsilon}_k$, 实验又告诉我们 $P = nkT$, 其中 $k = 1.38 \times 10^{-23}$ J/K 是玻尔兹曼常数, T 是热力学温度。两式一联立:

$$\bar{\varepsilon}_k = \frac{3}{2} kT$$

宏观的“冷热”, 说穿了就是微观的“快慢”。室温 300 K, 等价于空

气分子平均平动动能约 $6.2 \times 10^{-21} \text{ J}$ 。温度不再是独立的神秘量，而是分子机械运动强度的统计度量。 k 的数值极小，恰恰提醒咱们：宏观测量是海量微观事件的平均，单个分子的行为早被淹没在统计海洋里。但这桥是有条件的，它搭在理想气体假设上；到了真实液体或固体里，分子间势能不可忽略，温度与平均动能的关系就不再这么简单。这说明任何物理认识都有适用范围，不是放之四海而皆准的绝对命令，而是特定条件下长出来的相对真理。

这认识直接管着现代生产。半导体光刻车间要求恒温到 $\pm 0.1^\circ\text{C}$ ，因为温度波动就是分子平均动能的波动，光刻胶分子的热运动幅度一变，曝光图形的边缘精度就跟着跑偏——控温本质上是控分子的统计秩序。冷链物流里，冷冻食品坚持 -18°C 以下，因为这个温度对应的水分子平均动能已足够低，微生物体内的生化反应被摁到极慢，整条冷链都在用宏观温度参数遥控微观分子的运动分布。

不过得留个心眼： $\varepsilon_k = \frac{3}{2}kT$ 里的动能只算平动。多原子分子还会转、还会振，这些能量并不直接进温度公式。温度的定义本身，就已经是对运动形式的一次“选择”。水银温度计测热胀冷缩，热电偶测电势差，归根结底都只响应分子平动动能的统计平均；转动和振动得靠光谱分析另请高明。没有哪种测量能穷尽对象的全部属性，每种测量都是从特定角度对实在的抽象。化工厂算反应釜能量平衡，工程师必须分清“显热”（平动动能变化）和“潜热”（相变或化学反应中分子间势能、转动振动能量的重新分配）；若一股脑全按温度处理，工艺设计准出大错。

人类对气体的系统认识，本来就是生产逼出来的——矿井通风、蒸汽机改进、气球上天，全在催着人给“空气弹性”定量。1662 年波义耳用 J 形玻璃管压空气，发现温度不变时压强与体积成反比。1787 年查理发现体积不变时压强与温度成正比。1802 年盖-吕萨克精测了等压下体积与温度的正比关系。1811 年阿伏伽德罗补上了关键一环：同温同压同体积，任何气体分子数相同。1834 年工程师克拉珀龙把这四条经验规律拧成一股：

$$PV = nRT$$

这就是理想气体状态方程，其中 $R = 8.314 \text{ J}/(\text{mol} \cdot \text{K})$ 是普适气体常数。每一条经验规律都是片面的：波义耳只盯着等温，查理只盯着等容，盖-吕萨克只盯着等压。它们各自正确，但不完整。理想气体状态方程正是一种综合——不是四条定律的简单拼凑，而是在更高层次上揭示压强、体积、温度、物质的量之间的内在联系。

但这“具体”仍是理想化的。它是真理，可只在低压高温的舒适区里真。天然气管道设计先用 $PV = nRT$ 做第一近似，再请实际气体修正；没有这第一近似，后续精确修正就丢了参照系。家用液化气罐里，丙烷丁烷常温下

若全保持气态，体积大得吓人；压缩或降温打破平衡，气体液化，钢瓶承压设计必须算准夏天高温时的最大压强，还得留足气相空间防液体热胀超压。气象探空气球升上三万米，外界压强暴跌，气球体积膨胀，若材料弹性不够就炸在半空，设计时必须按状态方程算准各高度的体积变化。汽车电喷发动机每循环吸多少空气，直接决定喷油量和燃烧效率，工程师靠进气歧管的 P 、 T 、 V 算准物质的量 n ，才能精确控制喷油嘴——这式子是现代发动机的核心逻辑之一。医院氧气瓶标着“40 升”，不是瓶身真 40 升，而是标准状态下的气体体积；在 15 MPa 下，一瓶能存常压下 6000 升氧气，护士按状态方程换算，才能算准供氧时间和流量。

可一进入低温高压，实际气体就“造反”了。分子动能小，分子间力不再能忽略；分子间距小，自身体积也冒了出来。1873 年范德瓦尔斯在博士论文里给出修正。设 1 摩尔分子固有体积 b_0 ，两个直径 d 的硬球分子靠近，中心距小于 d 就撞，等效于每个分子周围有半径 d 的禁区；一个禁区体积是分子自身体积的 8 倍，但两分子共享，各摊一半，所以排除体积是 $4b_0$ 。理想气体里的 V 该换成 $V - nb$ 。器壁附近的分子还被内部分子往里拽，撞墙时动量减小，实际压强比理想值低；修正量与内部分子数密度成正比，也与器壁附近受影响的碰撞次数成正比，两者都正比于 n/V ，所以修正量正比于 $(n/V)^2$ ，即 $P_{\text{实际}} = P_{\text{理想}} - a(n/V)^2$ 。合起来：

$$\left(P + \frac{an^2}{V^2}\right)(V - nb) = nRT$$

这方程打开了真实气体的大门，可很快又碰上新天花板。它对临界点预测偏软，液相密度算得偏低，碰上水、氨这类极性分子就力不从心，低温下的氢、氦等轻分子更完全不买账——量子效应开始捣蛋了。工程热力学于是兵分两路继续推进。一路在范德瓦尔斯骨架上动手术：1949 年雷德利希-邝引入温度依赖的吸引力项，给出 RK 方程；1972 年索阿韦加进偏心因子，升级为 SRK 方程；1976 年彭-罗宾逊调整引力斥力的数学形式，提出 PR 方程。它们保留了“自由体积修正”和“内压修正”的辩证结构，但用更灵活的函数取代粗糙常数。偏心因子描述分子形状偏离球形的程度，温度函数反映分子间力随热运动强度的变化——这不是对范德瓦尔斯的否定，而是扬弃，承认分子世界比两个常数丰富得多。

另一路走向更精细的数值拟合。1940 年本尼迪克特-韦布-鲁宾提出 BWR 方程，加入密度高次项和指数衰减项，用八个经验常数覆盖宽范围 P-V-T 数据。后来的 BWRS、Lee-Kesler 等多参数方程，甚至动用十几个参数，能在计算机上精确复现从气相到液相、从三相点到临界区的完整相图。这些方程已经很难再用“分子体积”或“分子间力”做直观解释，它们更像用数学语言对实验数据做高保真映射。这本身也是认识论的跃迁：当

对象复杂到超出直观物理图像的承载力，认识就以数学结构的形式继续向具体逼近。

可参数再多，这些方程仍是经验性的修正。为甲烷精心调参的模型，套到二氧化碳身上就可能失真；中压区表现优异的方程，推到超高压区也许给出荒谬预测。这恰恰印证：任何理论模型都是真理长河中的一个河段，既超越前一阶段，又将被后一阶段超越。从理想气体到范德瓦尔斯，再到 PR 和 BWR，认识经历了否定之否定的螺旋——从混沌具体上升到抽象理想气体，再上升到较具体的范德瓦尔斯气体，继而上升到多参数方程刻画的高度具体化模型。每一次都不是退回混沌，而是在更高层次把握更丰富的规定性。

这种逼近在工业中直接转化为物质力量。天然气液化厂的设计者不会止步于范德瓦尔斯，甲烷在 -162°C 和 5 MPa 附近的相平衡需要 PR 方程甚至多参数方程才能保证液化回收率的精度；一座年产千万吨级的 LNG 接收站，相平衡计算偏差 1%，就是每年数百万吨天然气的计量误差；超临界二氧化碳萃取设备里的压力容器，设计压力精确到 0.1 MPa，全依赖对二氧化碳在 31.1°C 附近非理想行为的精确建模；超临界 CO_2 萃出的咖啡脱因、植物精油和精密器件清洗，优势就在于降压后 CO_2 自动气化分离，不留溶剂残留——这套绿色化工技术的核心，正是对实际气体相图的深度掌握。空调压缩机里的 R410A 制冷剂，在冷凝温度 50°C 、约 3 MPa 下，比容偏离理想气体行为超 20%，不用实际气体焓熵图做循环计算，能效比就是纸上谈兵。氢能源汽车的 70 MPa 储氢罐若按理想气体算储氢密度，会虚高近 40%，续航里程注水不说，还有超压风险；碳纤维缠绕层必须按实际气体方程给出的真实密度和压缩因子设计爆破安全系数。

回头看，理想气体忽略了分子间力和分子体积，这不是疏忽，而是在高温低压下抓住了主要矛盾。到了低温高压，原本次要的矛盾上升为主要矛盾，认识形态就得跟着跃迁。天然气管道常温低压段用理想气体快速估算，加压站、液化厂和储罐环节切到实际气体模型——方法的选择取决于条件，而不是教条。理想气体“错”了吗？没错，只是不够具体。范德瓦尔斯也没错，只是面对更苛刻的工业条件时显得粗糙。每个方程都在自己的尺度上为真，又在更大的尺度上被修正。这就是相对真理与绝对真理的辩证关系：绝对真理不是某个一经发现就永恒不变的终极公式，而是存在于无数相对真理的总和与过程中。相对真理之所以“相对”，不是因为它虚假，而是因为它有条件、有边界、有待展开；正是通过无数相对真理的积累、修正和扬弃，认识才无限地趋向那个作为总体性的绝对真理。工程上的状态方程越修越繁，参数越加越多，表面看是认识的复杂化，实质是认识向物质世界更深层次的回归——从稀薄气体的简单抽象，回到高密度、多组分、强相互作用的真实物质形态。

理想气体模型是科学抽象最精彩的案例之一。它不脱离实际，而是更深刻地把握实际：没有对理想气体的理解，就不可能有对真实气体的理解；没有对分子无规则运动的抽象，就不可能理解统计规律的实在性。分子动理论开启了统计物理的范式，它告诉我们宏观秩序可以从微观混沌中涌现，稳定规律可以从偶然碰撞中生成。这种思维方式不仅改变了物理学，也改变了我们对社会、经济和历史的理解——在那些领域里，大量个体行为的统计结果同样产生出个体意图之外的宏观规律。而工程上不断修正的状态方程则提醒我们：任何抽象都必须回到具体中接受检验，任何真理都在实践中获得自己的边界，也只有在实践中才能突破自己的边界，向更具体的真理形态迈进。烧水时壶盖那噗噗一跳，跳出的不只是蒸汽的力道，更是人类认识从抽象走向具体、从相对走向绝对的漫长而活泼的旅程。

7.2 分子分布律和统计规律

我们已经知道，温度是分子平均动能的度量。但“平均”二字藏着一个问题：是不是所有分子都以同样的速率运动？如果打开一盒气体，每个分子的动能都恰好等于 $\frac{3}{2}kT$ ，那这个世界未免太整齐了。事实是，分子们各跑各的，有的快，有的慢，有的刚刚被撞得停下来，有的刚获得一次猛烈的撞击正加速飞奔。温度只描述“平均士气”，不描述“个体差异”。要真正理解热现象，必须追问：这些分子按速率是怎么分布的？

这个问题不是凭空想出来的，而是实验逼出来的。1920 年，斯特恩做了一个精巧的实验。他把金属银加热到高温，银原子从炉壁的小孔中逸出，形成一束原子射线。这束射线穿过一个旋转的圆柱体，圆柱侧面刻有螺旋形狭缝。只有特定速率的原子才能在狭缝转过的瞬间恰好穿过，到达对面的探测器。改变圆柱转速，就能筛选出不同速率的原子。实验结果画出来，不是一条竖线（所有原子同速率），而是一条钟形曲线：大多数原子集中在某个中等速率附近，极快和极慢的都很少。这就是分子速率分布的实验证据——微观世界不是整齐划一的，而是有涨落、有弥散的。

麦克斯韦在 1859 年从理论上预言了这条曲线。他的思路很清晰：气体分子在热平衡时，三个方向的运动相互独立，且分布只依赖于速率的平方。设分子在 x 方向的速度分量落在 v_x 到 $v_x + dv_x$ 之间的概率为 $f(v_x)dv_x$ 。由于各向同性，三个方向的分布函数形式相同。分子速率在 v 到 $v + dv$ 之间的概率，是三个方向概率的乘积，再考虑速率空间中的体积元 $4\pi v^2 dv$ 。

关键的一步是确定 $f(v_x)$ 的具体形式。麦克斯韦假设分布函数只依赖于 v_x^2 ，且三个方向独立。这意味着 $\ln f(v^2) = \ln f(v_x^2) + \ln f(v_y^2) + \ln f(v_z^2)$ 。唯一满足这个条件的函数是指数函数： $f(v_x) \propto \exp(-\alpha v_x^2)$ 。于是速率分布为 $f(v) = Cv^2 \exp(-\alpha v^2)$ 。

C 和 α 由两个条件确定。第一个是归一化：所有概率之和必须等于 1，即 $\int_0^\infty f(v)dv = 1$ 。第二个条件并不预先假定能量均分，而是通过压强的统计表达式与理想气体状态方程来定出 α 。具体地，由分布算出平均平方速率 $\overline{v^2} = 3/(2\alpha)$ ，代入压强公式 $P = \frac{1}{3}nm\overline{v^2}$ ，得 $P = nm/(2\alpha)$ ，再与 $P = nkT$ 比较，即得 $\alpha = m/(2kT)$ 。这两个积分都是高斯积分的变体，形式简洁，结果漂亮。于是，归一化条件给出 $C = 4\pi(\frac{m}{2\pi kT})^{3/2}$ ，至此得到麦克斯韦速率分布律：

$$f(v) = 4\pi \left(\frac{m}{2\pi kT} \right)^{3/2} v^2 \exp \left(-\frac{mv^2}{2kT} \right)$$

分布律既得，平均动能即可直接算出：

$$\overline{\varepsilon_k} = \int_0^\infty \frac{1}{2}mv^2 f(v)dv = \frac{3}{2}kT$$

这个结果不是推导的前提，而是分布律的自然推论。它表明：每个平动自由度贡献 $\frac{1}{2}kT$ 的平均能量。后人将这一模式概括为能量均分定理——麦克斯韦分布在前，能量均分在后，前者是后者的基础，而非相反。

这个式子结构清晰：前面的系数保证概率归一； v^2 反映三维空间中速率的几何权重——速率大的分子“方向选择”更多；指数项 $\exp(-mv^2/2kT)$ 是玻尔兹曼因子的雏形，分子动能越大，出现的概率越低，按指数衰减。温度越高，衰减越慢，曲线向高速方向展宽；质量越大，衰减越快，曲线向低速方向收缩。

画出来看， $f(v)$ 是一条不对称的钟形曲线，从零开始上升，达到峰值后下降，拖着一个长长的尾巴。峰值对应的速率叫最概然速率 $v_p = \sqrt{2kT/m}$ ，是出现概率最大的速率。但“最概然”不等于“平均”——曲线不对称，高速尾巴把平均值拉大了。平均速率 $\bar{v} = \sqrt{8kT/\pi m}$ 比最概然速率大，方均根速率 $v_{rms} = \sqrt{3kT/m}$ 又比平均速率大。这三个速率各不相同，各自有用：最概然速率描述分布的峰值位置，平均速率用于计算平均自由程，方均根速率与平均动能直接挂钩。它们提醒我们：“典型值”不是一个，而是取决于你怎么问。同一个分布，不同的侧面。

这里冒出了一个根本性的问题。力学规律是确定的：给定一个分子的位置和速度，牛顿定律唯一确定它下一刻的状态。但统计规律是概率的：我们无法预言某个分子下一秒的速率，只能预言大量分子中有多大比例落在某个速率区间。这不是因为我们“知道得不够”，而是因为规律本身的形态变了。单个分子的运动仍然服从牛顿定律，但当我们把目光从“一个分子”转向“十的二十三次方个分子”，规律就从确定性的力学方程，转变为概率性的分布函数。这不是认识的退步，而是认识的跃迁——从个体层面上升到集体层面，涌现出全新的规律性。

这种跃迁揭示了一个事实：决定论没有被“不确定性”推翻，而是被“复杂系统的涌现规律”所超越。面对单个分子，牛顿定律仍然精确；面对十的二十三次方个分子，我们关心的不再是每个分子的轨迹，而是分布函数。分布函数有自己的稳定性、自己的演化方式、自己的可预测性。这不是因为“我们算不过来”，而是因为规律本身换了形态——从个体轨道的确定，转变为集体形态的统计必然。

涌现不是简单的数量叠加。两个分子的碰撞可以精确计算，二十三个分子的碰撞就超出任何计算机的能力，十的二十三次方个分子的集体行为却反而呈现出简洁的数学规律。复杂性到了极致，反而生出简单性。这不是悖论，而是自然界最深刻的结构之一：混沌中孕育着秩序，无序中生长出规律。

单个分子的轨迹是混沌的，但混沌的统计平均却给出稳定的分布；单个事件是偶然的，但偶然的集合却服从必然的规律。

量变引起质变，在这里体现得格外鲜明。粒子数从几个增加到几十个，规律仍然是力学的，确定性主导；增加到几千个，系统开始显现新的行为；增加到十的二十三次方个，统计规律稳定涌现。这不仅是数量的渐变，而是质的跃迁——在某一临界尺度之上，系统的行为突然从“力学行为”转变为“统计行为”，从“个体确定性”转变为“集体概率性”。

物态变化是涌现最直观的例子。一杯水，温度从二十度升到九十九度，分子平均动能逐渐增加，这是量变；到达一百度，突然沸腾，液态变成气态，这是质变。温度继续升高，气态分子的动能继续增加，但系统仍然是气态——量变在质变的框架内继续。直到温度高到分子被电离，气态又变成等离子态，再次发生质变。每一个物态都是大量分子集体行为的涌现：固态中分子在晶格位置上振动，集体涌现出固定的形状和体积；液态中分子可以相对滑动，集体涌现出固定的体积但没有固定的形状；气态中分子自由运动，集体涌现出既无固定形状也无固定体积的状态。单个分子的运动规律没有变，变的只是集体行为的组织方式——而组织方式的改变，就是涌现。

但涌现是有条件的，这个条件就是“足够多”。粒子数不够大时，统计规律就会“抖动”——这就是涨落。一杯水里十的二十三次方个分子，压强稳定得像是刻在石头上；但如果只有一百个分子，压强就会时高时低，忽大忽小。布朗运动就是涨落的典型表现：花粉颗粒足够小，周围水分子撞击的涨落不能被平均掉，颗粒就抖个不停。涨落不是误差，不是测量不准，而是统计规律在有限粒子数下的真实面貌。它提醒我们：统计规律不是“近似真理”，而是有适用条件的真理——条件就是粒子数足够大，让涨落被淹没在平均之中。

涨落在物态变化中扮演着关键角色。过冷水可以降到零度以下仍然保持液态，不是因为温度不够低，而是因为缺乏“成核中心”——涨落没有大到足以触发相变的程度。投入一粒灰尘，或者摇晃一下，提供一个局部的扰动，水就瞬间结冰。这个扰动就是涨落的“种子”，它打破了亚稳态的平衡，让系统跃迁到更稳定的相。沸腾也需要成核：光滑的容器底部，水可能被加热到一百度以上还不沸腾，形成“过热液体”；一旦底部出现微小的气泡或者划痕，沸腾就猛烈发生。涨落不是破坏秩序的噪声，而是相变的催化剂——没有涨落，系统就永远卡在亚稳态，无法完成质变。

涨落和涌现就像是同一枚硬币的两面，是量变在不同阶段的表现。大量粒子时，涨落被压制，涌现占主导，宏观规律稳定可预测；少量粒子时，涨落凸显，涌现被削弱，规律变得模糊。这不是两种规律，而是同一种统计规律在不同尺度上的显现。天气预报最能说明这一点：大尺度上，大气环流服

从流体力学规律，可以预测未来几天的温度走势；小尺度上，局部阵雨、突发雷暴，是涨落主导的不可预测区域。气象台预报“明天有雨”，说的是大尺度统计规律；预报“下午三点你所在的小区有雨”，就超出了统计规律的有效范围，进入了涨落区。

更深一层看，涨落和涌现的辩证关系揭示了自然界的一种普遍结构：稳定性本身就是不稳定性的产物。宏观状态的稳定，不是因为没有变化，而是因为变化太快、太多，相互抵消了。十的二十三次方个分子各自胡冲乱撞，每一次碰撞都改变动量，但碰撞如此频繁、方向如此随机，总动量的涨落被压缩到可以忽略。稳定不是静止，而是动态平衡；秩序不是设计，而是混沌的统计结果。这颠覆了传统的目的论思维，得到了新的规律：最可能的状态，恰恰是最稳定的状态。

麦克斯韦分布还有一个深刻的特征：它是“最无序”的分布。给定总能量和总分子数，什么样的速率分布出现的概率最大？数学上可以证明，答案是麦克斯韦分布。这意味着热平衡态不是某种特殊的“有序排列”，而是最大概率的状态，是微观上最多可能方式实现的状态。系统从非平衡态趋向平衡态，不是趋向某种“设计好的秩序”，而是趋向“最可能的无序”。混乱与秩序的二分，在这里失去了意义——最大概率的状态，恰恰是最稳定的宏观状态。

玻尔兹曼把麦克斯韦的速率分布推广到了更一般的情形。如果分子不仅具有动能，还在外力场中具有势能，比如重力场中的大气分子，那么分布不仅取决于速率，还取决于位置。玻尔兹曼分布律给出：

$$n = n_0 \exp\left(-\frac{E}{kT}\right)$$

其中 $E = \epsilon_k + \epsilon_p$ 是分子的总能量， n_0 是参考位置的数密度。这个式子把麦克斯韦分布的指数结构推广到了任意能量形式。在重力场中，大气密度随高度按指数衰减；在电场中，带电粒子的分布服从类似的规律。指数因子 $\exp(-E/kT)$ 是统计物理的核心结构，它告诉我们：能量越高的状态，出现的概率越低，降低的速率由温度决定。温度越高，热运动越剧烈，高能量状态越容易被“访问”；温度越低，系统被“冻结”在低能量状态。

玻尔兹曼分布揭示了一个更普遍的辩证关系：微观状态的概率与宏观约束条件之间的张力。给定温度（宏观约束），微观状态按能量分配概率；反过来，微观状态的统计平均又定义了温度。宏观与微观不是单向的决定关系，而是相互定义、相互生成的。温度约束了分布，分布又产生了温度——这种循环不是逻辑悖论，而是统计系统的自洽结构。

统计规律的这种自洽性，在工程中有直接的应用。半导体掺杂工艺中，工程师利用玻尔兹曼分布控制载流子浓度：温度升高，更多电子从价带跃迁

到导带，导电性增强；温度降低，载流子被“冻结”，器件进入截止状态。这不是对单个电子的操控，而是对统计分布的调控——通过控制温度，改变整个电子系统的概率分布，从而实现对宏观电学性质的精确控制。激光器的工作原理也依赖类似的统计思想：通过泵浦使粒子数反转，让高能态的粒子数超过低能态，打破热平衡下的玻尔兹曼分布，从而产生受激辐射。统计分布不仅是描述自然的工具，也是改造自然的杠杆。

但统计规律也有它的边界。麦克斯韦分布和玻尔兹曼分布都建立在经典力学的假设上：分子是可区分的，能量是连续的，量子效应可以忽略。当温度极低或密度极高时，这些假设失效。量子统计在微观层面修正了经典统计。这不是对统计规律的否定，而是统计规律在更深层结构上的展开。经典统计是量子统计在高温低密度下的近似，正如理想气体是实际气体在低压高温下的近似。每一次修正都不是推翻，而是纳入更广阔的框架。

从分子动理论到分布律，认识经历了一次重要的跃迁。从平均值到分布函数，从单一数字到整个曲线，这是从抽象到具体的深化。平均值抹平了个体差异，分布函数却保留了个体差异的结构。知道平均动能，只能估算压强和温度；知道速率分布，才能理解扩散、输运、化学反应速率等更精细的现象。分布函数是统计物理的核心概念，它让“大量粒子的集体行为”从一句口号，变成可以精确计算的工具。

这种从平均到分布的跃迁，也体现在认识论层面。力学规律描述的是“必然”：给定条件，结果确定。统计规律描述的是“可能”：给定条件，结果有概率分布。但“可能”不是“任意”——麦克斯韦分布告诉我们，虽然单个分子的速率不可预言，但速率的概率分布却是严格确定的。统计规律是一种新型的必然性：不是个体事件的必然，而是分布形态的必然；不是单次测量的必然，而是大量测量的必然。这种必然性不依赖于对个体细节的掌握，而依赖于对集体结构的把握。它告诉我们：认识世界不必穷尽每一个粒子的轨迹，把握统计结构同样可以获得确定性。

这正是统计物理对辩证法的最重要贡献之一。偶然与必然、无序与有序、个体与集体，在统计规律中获得了新的统一形式。偶然不是必然的敌人，而是必然的土壤；无序不是秩序的反面，而是秩序的温床；个体不是集体的附庸，而是集体的砖石。没有单个分子的随机碰撞，就没有压强的稳定；没有微观状态的混乱分布，就没有宏观热力学量的精确可预测。统计规律让辩证法从哲学思辨，变成了可以计算、可以验证、可以应用的科学工具。

工程实践中的大量问题，本质上都是统计问题。材料强度取决于晶体缺陷的统计分布；通信系统的噪声来源于电子热运动的随机涨落。工程师不必追踪每一个分子的运动，但必须理解分布函数的形状、尾巴的衰减、涨落的幅度。统计规律不是“近似”，而是精确的另一种形态——它精确地描述

的不是个体，而是集体；不是单次事件，而是重复事件；不是瞬时状态，而是平衡状态。在这种精确性中，人类获得了驾驭复杂系统的能力，也深化了对自然界的理解：规律不仅存在于简单的、可分离的个体中，也存在于复杂的、相互作用的集体中；不仅存在于确定性的事件中，也存在于概率性的事件中。这就是统计物理教给我们的，关于世界多样性和统一性的最深刻的一课。

7.3 热力学定律

人类对热的感知，最初来自火焰和冰水的触碰。但皮肤不一定可靠——同样温度的铁块比木头更凉，因为铁导热更快。温度计的发明，不是为了测量“冷热”，而是为了找到一种与人体无关的标记方式。

伽利略的气体温度计是最早的尝试。玻璃泡里的空气受热膨胀，推动液柱上升。但不同气体的膨胀系数是不同的，同一盆热水，用空气测和用酒精测，液柱高度并不一致。更麻烦的是，温标依赖于测温物质的特定性质，而物理学寻求的是普适的、不依赖某种特定物质的规定。显然伽利略的这种方式不能完全满足我们的需要。

来想一想，如果温度只是“热的程度”，为什么不同物质对同一盆热水给出不同读数？如果温度是物质的内在属性，为什么两种物质接触后最终会达到同一个“中间状态”？

第零定律提供了一个出口。如果系统 A 与系统 C 达到热平衡，系统 B 也与系统 C 达到热平衡，那么 A 与 B 无需直接接触，也必然处于热平衡。热平衡的可传递性，使温度成为一个状态标记——不是“系统里有多少热”，而是“能否与谁平衡”。

温度由此获得了操作定义：它是热平衡关系的等价类标记。两个系统温度相同，意味着它们之间不会发生净热流；温度不同，热流方向由高温指向低温。这个定义不预设热的本质，不依赖测温物质的具体性质，只依赖平衡关系的逻辑结构。

但这里藏着一个循环。我们用温度计测量温度，而温度计的校准又依赖于已知的温度点——水的冰点、沸点。这些固定点本身需要热平衡来确认。第零定律打破了循环：它保证平衡关系的可传递性，使温度成为一个良定义的物理量，而非特定仪器的读数。

这与电场概念的发展同构。电场强度是空间的状态，但试探电荷所受的力还依赖于试探电荷的电量 q_0 。为了分离“空间的性质”和“被测对象的属性”，我们定义电场强度等于试探电荷所受的力和所带电荷的比值。同样，为了分离“系统的温度”和“测温物质的属性”，第零定律通过平衡关系的抽象，使温度成为独立于特定物质的物理量。

从人体的感觉，到仪器的读数，再到关系的抽象。温度不是感觉，不是物质的内在属性，而是系统间关系的标记。

但第零定律只给出了温度的定义，没有给出温度的本质。理想气体温标在低压极限下趋近于一个共同的标准，这个标准被称为热力学温标，用开尔文度量。绝对零度的概念由此浮现：它是理想气体在定容条件下压强趋于零的温度，是温度的下限。但这个下限能否达到？第零定律对此表示沉默。

从感觉到关系，从关系到极限，热力学在现象层面建立了一套自足的操作体系。但这套体系内部有一个裂缝：温度标记了热流的方向，却没有解释热流为什么有方向。高温到低温是经验事实，低温到高温从未自发发生。这不是温度本身的性质，而是涉及另一个更基本的概念——能量。

能量守恒的观念在力学中早已成熟：动能与势能相互转化，总量不变。但热是否也是一种能量？焦耳在 1840 年代的实验给出了肯定的答案。他用桨叶搅拌水，测量水温的升高；他用电流通过电阻丝，观察热量的产生。经过分析比较，最终得到：机械功、电能、热能——它们可以相互转化，总量守恒。

焦耳的实验设计值得多看几眼。他不是简单地“发现”热功当量，而是构造了一个封闭系统：绝热容器、精确测温、已知质量的液体。热量被限制在系统内部，功的输入被精确测量，温度的变化被转化为热量的等效值。这个实验的哲学意义在于，它把热从一种神秘流体重新定义为能量的一种形式，同时把能量守恒从力学推广到热现象。

第一定律由此诞生。对于一个热力学系统，内能的变化等于系统吸收的热量减去对外做的功：

$$dU = \delta Q - \delta W$$

这里有两个符号需要解释： d 和 δ ，看起来只差一笔，背后却是概念的巨大跃迁。

dU 中的 d 是全微分，或者说恰当微分。它意味着 U 是态函数，只取决于系统的当前状态——温度、压强、体积的某个组合。从状态 A 到状态 B ， ΔU 是确定的，与路径无关。你可以先加热再膨胀，也可以先膨胀再加热，还可以随便怎么变化，只要初末状态相同，内能的变化就相同。 U 是系统的内在属性，像一个人的身高，不取决于他是站着、坐着还是躺着。

δQ 和 δW 中的 δ 是过程量，或者说非恰当微分。 Q 和 W 不是系统的属性，而是交换的媒介。同样的初末状态，不同的路径，传递的热量不同，做的功也不同。 δ 提醒我们：这些量不能积分出路径无关的函数。你不能说“系统有多少热量”或“系统有多少功”，你只能问“这次过程中传递了多少热量”或“做了多少功”。热量和功是过程的印记，不是状态的肖像。

这个区分不是数学游戏，而是物理内容的结构化呈现。第一定律把两种不同性质的量放在同一个等式里：左边是态函数的变化，右边是过程量的差额。 $\delta Q - \delta W$ 的差额，恰好等于 dU 的全微分。这意味着，尽管热量和功各自依赖于路径，它们的差额却奇迹般地路径无关。

这与静电场的保守性同构。沿任意闭合路径，电场力做功为零，因此可以定义电势差。同样，尽管热和功的路径千变万化，它们的组合 $\delta Q - \delta W$ 却

像保守场一样，只取决于初末状态。第一定律的深刻性不在于守恒本身，而在于它从路径依赖的过程中，提炼出了路径无关的状态属性。

但 δ 符号也有局限。它暗示 Q 和 W 是无限小的过程量，可以形式上积分。实际上，热和功的传递涉及具体的物理机制：热传导需要温差，做功需要体积变化或电场位移。 δ 的抽象掩盖了这些机制的差异，把不同的物理过程统一为“能量交换”的数学形式。这种抽象是理论的力量，也是理论的盲点——知道 δ 代表过程量，不等于理解了热量如何从高温流向低温，功如何通过活塞的位移转化为机械运动。

设计锅炉的人们必须回到具体的 δQ 和 δW 。锅炉里的燃烧释放热量，汽缸里的蒸汽膨胀推动活塞，冷凝器里的废热排向环境。每一个 δQ 和 δW 都有具体的设备、具体的介质、具体的损失。理论给出能量平衡的计算框架，但具体的热量传递系数、膨胀功的机械效率、散热损失的比例，必须通过实验测定。算错了，锅炉爆炸；算对了，效率达标。第一定律的预测能力，是其真理性的最诚实判据——不是哲学论证，是工程成败。

我们要诚实面对一个困难。 δQ 和 δW 的差额等于 dU ，但这个等式只适用于封闭系统。打开锅炉的进料阀，煤粉不断进入；打开蒸汽管道的阀门，能量不断流出。这时候 $dU = \delta Q - \delta W$ 不够用了，需要扩展为焓或更一般的开放系统方程。第一定律的简洁形式是平衡态热力学的产物，它的边界在开放系统、在远离平衡的过程、在快速变化的条件下逐渐模糊。知道边界，才知道什么时候该换工具。

但第一定律不能揭示过程的方向性。一个系统可以吸收热量对外做功，也可以被压缩同时放热，能量守恒并不偏好任何一种方向。经验告诉我们，热自发从高温流向低温，但从未观察到反向的自发过程。影片可以倒放，真实世界不会倒放。这种不可逆性不是能量守恒的推论，而是独立于第一定律的新事实。

卡诺在 1824 年的论文中触及了这个边界。他研究的是蒸汽机——当时工业革命的核心动力装置。瓦特改良了蒸汽机，但卡诺追问的是更根本的问题：热机效率有没有上限？这个上限取决于什么？

卡诺的理想热机是一个思维实验：两个热源，一个高温 T_h ，一个低温 T_c ，之间运转着一台可逆热机。工质在高温处吸热，在低温处放热，对外做功。卡诺证明了一个惊人的结论：这台理想热机的效率只取决于两个热源的温度，与工质的具体性质无关：

$$\eta = 1 - \frac{T_c}{T_h}$$

这个公式看似简单，却蕴含着深刻的革命性。它说，热转化为功有一个绝对的上限，这个上限由温度的比值决定，不是由人的意志或技术的高低决

定。你可以改进锅炉，你可以优化活塞，你可以让过程更接近可逆，但你永远无法突破这个上限。

卡诺的论证基于热质说，这个前提后来被证明是错误的。但他的结论超越了前提。效率公式在能量守恒的框架下依然成立，成为热机设计的铁律。建造发电厂的工程师，卡诺效率是硬约束；提高蒸汽温度、降低冷凝温度，是提升效率的唯一途径。但真实发电厂的实际效率只有 30%-40%，差距来自摩擦、散热、不可逆膨胀——这些不是理论能自动包含的，必须通过实验测定、逐项优化。理论给出方向，实验填出数字。

但效率公式仍然没有解释方向性。它只是说，如果存在两个热源，效率有上限。它没有说，为什么热不能从单一热源吸热全部做功，为什么热不能自发从低温流向高温。

对于这个问题，开尔文在 1851 年给出了第一种表述：不可能从单一热源吸收热量，使之完全变为有用功而不产生其他影响。这意味着，即使有一个巨大的热源，你也不能把它当作无限的能源库。热量转化为功的过程必然伴随着向低温热库的排热。

克劳修斯在 1850 年给出了第二种表述：不可能把热量从低温物体传到高温物体而不引起其他变化。这意味着，冰箱需要消耗电能，热泵需要外界做功。热流的自发方向是高温到低温，反向流动需要代价。

两种表述的等价性可以通过反证法证明。假设开尔文表述不成立，即存在一台从单一热源吸热全部做功的机器；那么可以用这台机器驱动一台制冷机，把热量从低温泵到高温，而不需要外界做功——这就违反了克劳修斯表述。反之亦然。两种表述是同一物理事实的不同侧面：能量转化有方向，热流有方向，这两个方向性本质上是同一约束。

这就是热力学第二定律。它不是从第一定律推导出来的，也不是从卡诺定理推导出来的，它是独立的经验规律。它说“不可能”，却没有给出“不可能”的数学度量。卡诺定理给出了效率上限，但这个上限为什么与工质无关？效率的损失去了哪里？不可逆过程的共同特征是什么？经典热力学在此停步。这些问题的答案，藏在微观粒子的无规则运动中——不是单个粒子的轨迹，而是大量粒子的统计规律。那个世界，需要另一套语言。

在第二定律的定性框架内，我们可以讨论一个极限问题。卡诺效率公式中出现了一个温度 T_c ，当 T_c 趋近于零时，效率趋近于 1。这意味着，如果存在一个绝对零度的热源，热机就可以达到 100% 效率。但绝对零度能否达到？

能斯特在 1906 年提出了热定理：当温度趋近于绝对零度时，凝聚系统的熵变趋近于零。这个表述后来被强化为热力学第三定律：不可能通过任何有限的过程，使一个物体冷却到绝对零度。

第三定律不是能量守恒的推论，不是第二定律的延伸，而是一个独立的极限原理。绝对零度是温度的下限，但这个下限渐进可达而极限不可达。你可以无限接近，但永远无法触及。这与数学中的渐近线类似：曲线可以无限逼近直线，但永远不会相交。

这种“可达而不可即”的结构在物理学中反复出现。光速是运动速度的上限，粒子可以无限接近但无法达到；黑洞视界是观测的边界，信息可以无限接近但无法逃逸。绝对零度是热运动的基态，但量子力学告诉我们，即使在基态，零点涨落依然存在。运动不会完全停止，只是被冻结在最低的量子态。

第三定律为温度的操作定义提供了终极边界。第零定律定义了温度的比较，第一定律定义了能量的守恒，第二定律定义了过程的方向，第三定律定义了温度的极限。四个定律不是并列的经验规则，而是层层递进的概念建构：从关系的抽象，到能量的量化，到方向的约束，再到极限的不可逾越。

但第三定律也暴露了经典热力学的边界。绝对零度不可达，不仅是一个操作性的限制，更是量子效应的暗示。当温度趋近于零时，经典的气体定律失效，量子统计取代玻尔兹曼分布。费米子形成简并压，玻色子发生凝聚，热运动的冻结不是简单的静止，而是量子态的重新组织。经典热力学在其极限处指向了自身的超越，为统计力学和量子力学预留了入口。

还要看到，热力学四定律的建立伴随着工业革命的实践需求。蒸汽机的效率、制冷机的原理、热机的极限——这些不是纯粹的学术好奇，而是生产实践的直接需求。能量守恒使燃料消耗可计算，第二定律使效率优化有目标，第三定律使低温技术有边界。热力学规律不是抽象的游戏，是设计锅炉、制造冰箱、建造发电厂的硬约束。违反这些规律，设备就不工作；尊重这些规律，才能从给定条件下榨取最大的有用功。

但这并不意味着热力学是无所不能的。能量守恒是实验事实，不可逆性是经验规律，绝对零度的不可达是统计结论。设计锅炉的人算错能量平衡，锅炉爆炸；算对了，蒸汽推动汽轮机发电。第一定律不是哲学命题，是生死线。优化热机效率时，卡诺极限是天花板；制备液氮冷却超导磁体时，第三定律是地板。每个定律都有它的地盘，出了地盘，就得换更一般的框架。

7.4 熵的规律

冰块丢进温水，它只会融化，从不见温水结冰。一滴墨汁落进清水，缓缓晕开，从不见墨滴自动缩回笔尖。碎在地上的镜子，任你怎么等，也不会自己拼回完整。这些再平常不过的现象，背后藏着物理学最深邃的一条规律。

第一定律管的是能量有多少，却不问能量往哪儿走。第二定律说过程有方向，却没给方向一个度量。克劳修斯在 1865 年引入了一个新的物理量——熵。它标记过程的方向，度量不可逆的程度。

让我们回到卡诺的理想热机。设想一个可逆循环：工质从高温热源 T_h 吸收热量 Q_h ，向低温热源 T_c 放出热量 Q_c ，对外做功 $W = Q_h - Q_c$ 。效率 $\eta = W/Q_h = 1 - Q_c/Q_h$ 。问题在于： Q_c/Q_h 能有多小？或者说，效率有没有上限？

卡诺设计了一个由两个等温过程和两个绝热过程组成的循环——后来被称为卡诺循环。为便于计算，用理想气体作为工质。

等温膨胀：气体体积从 V_1 到 V_2 ，温度 T_h 不变。内能不变，吸收的热量全部用于对外做功：

$$Q_h = \int_{V_1}^{V_2} P dV = nRT_h \ln \frac{V_2}{V_1}$$

绝热膨胀：体积从 V_2 到 V_3 ，温度降至 T_c ，无热交换。

等温压缩：体积从 V_3 到 V_4 ，温度 T_c 不变，气体对外放热（大小取正值）：

$$Q_c = nRT_c \ln \frac{V_3}{V_4}$$

绝热压缩：体积从 V_4 回到 V_1 ，温度回升至 T_h 。

对于绝热过程，理想气体满足 $TV^{\gamma-1} = \text{常数}$ 。因此：

$$T_h V_2^{\gamma-1} = T_c V_3^{\gamma-1}$$

$$T_h V_1^{\gamma-1} = T_c V_4^{\gamma-1}$$

两式相除得 $\frac{V_2}{V_1} = \frac{V_3}{V_4}$

于是

$$\frac{Q_c}{Q_h} = \frac{T_c \ln(V_3/V_4)}{T_h \ln(V_2/V_1)} = \frac{T_c}{T_h}$$

代入效率公式：

$$\eta = 1 - \frac{Q_c}{Q_h} = 1 - \frac{T_c}{T_h}$$

卡诺由此得出结论：可逆热机的效率只取决于两个热源的温度，与工质无关。并且，任何不可逆热机的效率都不可能超过这个值——否则就可以构造出违反第二定律的装置。

由此可得 $Q_h/T_h = Q_c/T_c$ 。克劳修斯注意到 Q/T 这个比值在可逆循环中具有特殊性。对于任意可逆循环，有 $\oint \delta Q_{rev}/T = 0$ 。这意味着 $\delta Q_{rev}/T$ 是某个态函数的全微分。他把这个态函数定义为熵： $dS = \delta Q_{rev}/T$ 。熵变由可逆路径计算： $\Delta S = \int_A^B \delta Q_{rev}/T$ 。

熵是态函数，只取决于系统的状态，与路径无关。但热量 Q 不是态函数。我们只能“借道”可逆过程来计算熵变。这是一个巧妙的辩证装置：用理想化的可逆过程作为参照系，来度量真实过程的不可逆程度。

考虑理想气体的自由膨胀。隔板抽掉，气体从体积 V_1 涌向真空 V_2 。此过程 $Q = 0$ ， $W = 0$ ，内能不变，温度不变。但它不可逆。为了计算熵变，我们设计一条可逆的等温膨胀路径连接相同的初末状态：

$$\Delta S = \int \frac{\delta Q_{rev}}{T} = nR \ln(V_2/V_1) = Nk \ln(V_2/V_1)$$

其中 N 是分子数， k 是玻尔兹曼常数。

这个宏观定义回答了“怎么算”，但没有回答“为什么”。对于这个问题，玻尔兹曼给出了微观解释。任何一个宏观状态都对应着大量微观状态。定义热力学概率 W 为该宏观状态所对应的微观状态数。玻尔兹曼公式：

$$S = k \ln W$$

熵越大，实现该宏观状态的方式越多。孤立系统自发趋向微观状态数最多的宏观状态——即熵最大的状态。自由膨胀中，体积增大，每个分子可及的位置增加， W 增大，熵增加。

克劳修斯熵是宏观的、操作性的；玻尔兹曼熵是微观的、统计性的。两者的统一标志着物理学从现象描述深入到本质理解。这本身就是一种认识论上的跃迁：从个体确定性（牛顿力学）到集体统计性（热力学）——量变引起了质变。

这里冒出了一个深刻的哲学问题。单个分子的弹性碰撞遵守牛顿定律，牛顿方程对时间反演对称。如果拍一部电影记录两个分子的弹性碰撞，倒放也完全符合物理规律。单个过程没有方向。可 10^{23} 个分子的集体行为，却表现出明确的时间箭头：熵只增不减。

方向从哪儿来？不是计算精度的问题。即便有无限算力，追踪每一个分子的轨迹，看到的仍是一系列可逆的碰撞。但当你问“系统处于哪个宏观状态”时，你放弃了对个体轨迹的追踪，转而统计微观状态的分布。这个“放弃”不是无奈，而是认识层次的跃迁——从个体上升到集体，涌现出全新的规律性。不可逆性不是力学定律的失效，而是统计描述的新属性。偶然的碰撞，在大量重复中生长出必然的规律。

将熵增原理写成一般形式。对于任意过程：

$$dS \geq \frac{\delta Q}{T}$$

等号对应可逆过程，不等号对应不可逆过程。对于绝热系统（ $\delta Q = 0$ ）， $dS \geq 0$ 。孤立系统的熵永不减少——这就是熵增原理。

不可逆意味着“有势未用”。高温向低温直接传热，是温度势差的耗散；气体自由膨胀不推动活塞，是压力势差的耗散；摩擦生热，是机械运动有序能向热无序能的退化。每一次不可逆，都是做功能力的损失，都是熵的增加。

熵增原理在工程中的含义是直接的。发电厂、制冷机、热泵——所有热功转换设备都受卡诺效率上限的约束。真实的不可逆过程使效率进一步降低。工程师的目标不是消除不可逆（那需要无限缓慢的过程，意味着零功率），而是在功率与效率之间寻找最优权衡。

如果将宇宙视为一个孤立系统，熵将不断增加，直到达到最大值。那时所有温差消失，所有势差抹平，宇宙陷入均匀的热平衡——“热寂”。这是克劳修斯在 1865 年提出的推论。

但这个推论依赖于一个前提：宇宙是孤立系统。我们不知道宇宙的整体边界，也不知道宇宙之外是否存在什么。更重要的是，引力系统不服从普通热力学——在引力作用下，均匀分布不是最可能的状态，凝聚成团才是。热寂预言提醒我们：任何物理定律都有适用范围。把热力学第二定律外推到整个宇宙，可能超出了它的有效边界。这与前文“理想气体状态方程只在低压高温下成立”是同一个认识论教训：真理是具体的，不是抽象的。

从克劳修斯到玻尔兹曼，熵从一个工程计算量成长为理解时间、概率和宇宙基本问题的钥匙。这一历程本身就是认识运动的缩影：从具体到抽象，再到更具体；从操作定义到微观机制，再到宏观边界的反思。它告诉我们：方向性不是幻觉，可能性可以度量，而宇宙是否终将走向热寂——这个问题本身，可能已经超出了物理学能够回答的范围。

Part VIII

分析力学

8.1 虚功原理

你站在建筑工地上，抬头看脚手架。钢管一根根竖起来，横杆一层层搭上去，扣件把交叉处锁死。工人踩着跳板往上走，水泥袋堆在某一层。这玩意儿稳不稳？哪根杆在受拉，哪根在受压？如果工人再往上走一层，或者风突然大了，哪根杆会先弯？

这是结构工程师的日常问题，也是工人的生死问题。脚手架塌了，人掉下来，不是理论错误，是命。

用牛顿力学分析？每个节点写三个平衡方程——水平、竖直、垂直于墙面。几百个节点，几百组方程，几千个未知数。杆件内力是矢量，但方向被钢管几何锁定——只能沿杆轴向，拉或压。所以每个内力只剩一个数：大小，正为拉，负为压。节点上的力平衡拆成三个分量，未知数和内力的耦合极其繁琐。

更麻烦的是：扣件是约束，维持着“钢管在节点处交汇、角度固定”的几何关系。扣件的反力、摩擦力、锁紧力——这些力你解出来，只是为了验证扣件会不会滑脱。它们是维持约束的幕后工作者，不是你关心的核心规律。你真正关心的是：整体稳不稳，哪根杆先失效。

但牛顿力学逼着你把这些幕后工作者请上台，逐一介绍，算完再让它们退场。改一处设计，加一根斜撑，方程全变，从头再算。

能不能从一开始就不请它们上台？

我们先从能严格计算的情形入手。

四根钢管，两根斜的，两根竖的，在四个节点处扣接，搭成一个最简单的空间框架。两个竖杆下端固定在地上，上端用横杆连接，中间再斜撑一根。一个节点上站着工人，荷载向下。

牛顿力学让你拆成节点，写平衡方程，解杆件内力。但换个思路：假设站工人的节点往下移动了一小段——不是真的动，是扣件允许的、几何变分。在这个变分下，哪些杆伸长、哪些缩短？这是几何，不是力学。几何关系由框架的空间构型决定，与材料、荷载无关。

现在算功。外力——工人的重力——在节点下移时做正功。杆件内力呢？

我们先处理理想约束情形——假设钢管是刚性的，长度严格固定，节点位移在杆件方向上的分量为零，内力不做功。实际钢管有弹性，会伸缩，那时内力做功转化为弹性势能，需要通过势能纳入。理想约束是第一步，弹性修正后一步。

为什么理想约束下内力不做功？看一个扣件。四根钢管交汇，内力沿各自轴向。节点虚位移时，各杆端点位移由节点位移决定。但扣件锁死了相对位置，杆件长度不变——轴向力在轴向变形上做功为零，就像两个人拔河，

绳子长度不变，张力对两个人做的功一正一负，总和抵消。

这不是巧合，是约束的定义。约束之所以能维持，正是因为约束力在允许的运动方向上不耗散能量，否则约束就被破坏了——扣件滑脱，钢管错位，脚手架塌了。

所以总虚功里只有主动力出现。平衡条件很简单：所有主动力在任意虚位移上做的总功为零。

$$\delta W = \sum_i \mathbf{F}_i^{(\pm)} \cdot \delta \mathbf{r}_i = 0$$

这就是虚功原理。约束力被约束条件本身消掉了——不是算完才发现不重要，是事前就知道它们不会出现。几何结构替你做了受力分析的活。

这里有个更深层的事实。“扣件锁死钢管”这个关系不是物质实体，扣件是实体，钢管是实体，但“它们被锁在一起”这个关系不是实体。然而这个不是实体的关系，却实实在在地改变了物质系统的运动状态——没有扣件，钢管各自独立；有了扣件，钢管成为一个整体，共同承担荷载。虚功原理之所以成立，正是因为约束力——维持关系的那些力——在允许的方向上不做功。这意味着关系直接进入了运动方程的形式结构，不需要通过力的中介。你不需要知道扣件给了钢管多大的力，你只需要知道“它们被扣在一起”，约束力就自动退场了。

但这里有个关键问题。上面的四杆框架是静定结构，能解。如果脚手架更复杂呢？比如多了一层，多了一根斜撑，变成超静定，牛顿力学的方程数不够，解不出来了。或者实际脚手架有几十层，几百根杆，方程组膨胀到让人绝望。

虚功原理的优势在这里显现。它不依赖于静定或超静定，不依赖于方程是否封闭。它只问一个整体问题：主动力在约束允许的变分上是否平衡？这个问题不逐个节点求解，直接从能量结构回答。超静定结构之所以“超”，是因为杆件数多于静定所需，多余杆件的变形必须与其他杆件协调——伸长多少、弯曲多少，不是自由的，受几何关系约束。这些协调条件在牛顿力学中表现为额外的方程，在虚功原理中直接纳入广义坐标的定义：多余的位移不是独立的，是其他位移的函数。

我们把这套东西精确化。

三维空间中， N 个节点原本有 $3N$ 个坐标。受约束后，独立参数减少。四杆框架有四个节点，12 个坐标；两个节点固定在地上，6 个约束；杆件连接和扣件锁死若干约束；自由度有限。这些独立参数 $q_1, q_2, \dots, q_n$ 叫做广义坐标。选择的唯一标准是方便——可以是节点位移，可以是杆件转角，可以是任何能唯一确定系统位形的量。但不管怎么选，系统的物理实在不变。

虚位移是约束允许的、无限小的变分,用广义坐标表示为 $\delta q_1, \delta q_2, \dots, \delta q_n$ 。主动力做的功写成:

$$\delta W = \sum_{j=1}^n Q_j \delta q_j$$

Q_j 是广义力——如果 q_j 是长度, Q_j 是力; 如果 q_j 是角度, Q_j 是力矩。它是主动力对广义坐标变化的响应强度。

虚功原理说: 对所有独立的 δq_j , 广义力 Q_j 为零。

$$Q_j = 0, \quad j = 1, \dots, n$$

这就是平衡条件。

如果主动力都是保守力, 存在势能 $V(q_1, \dots, q_n)$, 则广义力是势能的负梯度:

$$Q_j = -\frac{\partial V}{\partial q_j}$$

平衡条件变成势能取极值:

$$\frac{\partial V}{\partial q_j} = 0$$

稳定平衡对应极小值, 不稳定对应极大值。脚手架搭得正, 势能极小, 扰动后回来; 搭歪了, 势能极大, 扰动后塌掉。

回到那座脚手架。几十层, 几百根杆件, 用牛顿力学要解几千个方程。用虚功原理呢? 选择关键节点的位移作为广义坐标, 工人荷载和风荷载是主动力, 杆件内力是约束力。理想约束下, 内力不做功, 只剩下主动力的虚功。平衡条件是一个能量极值问题, 不是几千个力的平衡问题。计算量从几千阶降到几十阶, 而且改设计时只需调整能量函数, 不必重解方程组。

从牛顿力学的逐点受力分析, 到虚功原理的整体功平衡, 再到势能极值——认识层层跃迁。牛顿力学让你问“每个节点受了什么力”, 虚功原理让你问“系统在什么位形下能量最低”, 势能极值让你直接回答。每一步都抛掉了不必要的细节, 更接近本质。

但这都是静力学。系统不动, 加速度为零。如果系统在动呢?

回到那座脚手架。工人不是站着不动, 是在往上爬; 风不是恒定的, 是脉动的; 塔吊在吊重物, 脚手架在晃。这时候“平衡”二字不够用了, 需要处理运动。

但运动不是与静止割裂的。我们在 3.1 已经看到, 非惯性系中的牛顿方程可以写成含惯性力的形式: 真实力加惯性力等于零, 形式上就是“平衡”。

惯性力 $-m_i \mathbf{a}_i$ 不是真实的力，没有施力物体，是加速度的影子。但这个影子让虚功原理的框架可以直接套用。

运动系统的虚功原理：所有主动力和惯性力在任意虚位移上的总功为零。

$$\sum_i \left(\mathbf{F}_i^{(\pm)} - m_i \mathbf{a}_i \right) \cdot \delta \mathbf{r}_i = 0$$

约束力仍然不出现——理想约束在虚位移上不做功，无论系统静止还是运动。

静止是这个方程的特例：加速度为零，惯性力消失，退化为静力学的虚功原理。运动是一般情况，惯性力参与了功的平衡。

牛顿力学把运动和平衡割裂开：平衡是力的抵消，运动是力的不平衡。虚功原理的推广把它们统一了：运动是“在惯性力参与下的平衡”。静止是惯性力为零的特殊情况，运动是惯性力不为零的一般情况。这种统一不是抹平差异——静止保留了“加速度为零”的特殊规定，运动获得了“惯性力参与”的新内涵。二者通过虚功这个共同形式联系起来，形成了从静力学通往动力学的桥梁。矛盾的两个方面——静止和运动——不是互相排斥的，而是在更普遍的框架中既对立又统一。

但这个推广也有局限。惯性力依赖于加速度，加速度又依赖于运动状态，循环定义。我们只是把动力学问题重新包装进了静力学的形式，没有从根本上解决“如何从能量结构直接导出运动方程”的问题。

那个问题需要更深刻的框架。不是给运动系统加上惯性力再套虚功，是重新定义“作用量”这个整体泛函，让运动方程从作用量的变分条件中自然生长出来。静力学的势能极值是这个框架的静态极限，运动系统的作用量变分是它的动力学展开。

这就是下一节的内容。

8.2 拉格朗日方程和作用量变分为零原理

我们从单摆说起。

一根细绳，上端固定，下端系一个小球。你把它拉开一个角度，松手，小球来回摆动。用牛顿力学分析，你得写小球的位置 (x, y) ，然后处理绳的约束——绳长固定， $x^2 + y^2 = l^2$ ，还有一个未知的张力在拉着它。三个未知数 (x, y, T) ，三个方程，解起来不困难，但繁琐。张力是什么？它是约束力的体现，不做功，只起限制作用。你真正关心的只是摆角 θ 怎么随时间变化，却被迫和 x 、 y 、 T 纠缠在一起。

这只是一个单摆。如果是双摆——一根绳下端再挂一根绳，两个小球各自摆动——你要处理六个坐标、两个约束、两个张力，方程组膨胀到让人头疼。如果是链条、滑轮组、刚体转动，自由度越多，牛顿力学的负担越重。每个质点都要写受力分析，每个约束都要引入未知力，这些力往往不是你关心的，却不得不解。

这就是我们面临的问题：能不能绕过这些繁琐的受力细节，直接抓住系统的核心运动规律？

几何光学给了我们一个可能的方向。光从空气射入水中，弯折了；从镜子反射，入射角等于反射角。费马原理说，光走的路径满足光程取极值的条件。光不是“选择”了最短路径——光没有意志。惠更斯原理指出，波前上每一点都是次级波源，子波向四面八方传播。不同路径的相位不同；光程极值路径附近的相位变化最慢，相邻路径的相位近似同相，叠加后振幅最大；远离极值的路径，相位快速振荡，相互抵消。结果上看，能量集中在光程极值路径附近——这不是光“选择”的，而是波动干涉的客观结果。在均匀介质中，直线最短，光沿直线传播；在两种介质的界面上，弯折可以缩短总的光程时间，所以光弯折。结果上看，光满足了光程极值的条件。

力学中会不会有类似的原理？能不能也从某种“极值”出发，直接得到运动方程，绕过逐个分析受力的繁琐？

我们从牛顿第二定律出发试试看。一个质点在保守力场中运动：

$$m\ddot{\mathbf{r}} = -\nabla V$$

左边是质量乘加速度，右边是势能的负梯度。现在做一个变形：把左边写成某个量对时间的导数。注意到 $m\dot{\mathbf{r}}$ 是动量，而 $m\dot{\mathbf{r}} = \nabla_{\dot{\mathbf{r}}} T$ ，其中 $T = \frac{1}{2}m\dot{\mathbf{r}}^2$ 是动能。于是：

$$\frac{d}{dt}(\nabla_{\dot{\mathbf{r}}} T) = -\nabla V$$

把右边移到左边：

$$\frac{d}{dt}(\nabla_{\dot{\mathbf{r}}}T) + \nabla V = 0$$

势能 V 不依赖于速度，所以 $\nabla_{\dot{\mathbf{r}}}V = 0$ ，可以把方程写成：

$$\frac{d}{dt}(\nabla_{\dot{\mathbf{r}}}(T - V)) - \nabla(T - V) = 0$$

令 $L = T - V$ ，就得到了：

$$\frac{d}{dt}(\nabla_{\dot{\mathbf{r}}}L) - \nabla L = 0$$

这个 $L = T - V$ ，在牛顿力学原有的框架里没有独立地位。牛顿的体系中有力、质量、加速度、动量——但没有一个叫“动能减势能”的标量函数。力是什么？力是我们为了描述相互作用而构造出来的概念。推一本书，书往前走，手感到挤压——我们把这个经验抽象为“力”，然后用它来描述物体之间的相互作用。力不是自然界的基本实体，它是相互作用在特定描述框架中的表示方式，是矢量，依赖于坐标系，换一个坐标系力的分量就全变了。但相互作用本身不依赖于坐标系——手推书这个客观事实，不管你在直角坐标还是极坐标里看，它都是同一个事实。力携带着描述工具的痕迹，它不是那个事实本身。

L 则不同。它是标量，不依赖于坐标系的选择。而且它直接由动能和势能构成——动能是运动状态的内在度量，势能是相互作用双方整体关系的内在度量。能量不是对相互作用的描述，而是对相互作用双方整体状态的规定。一个系统有什么样的能量结构，它就有怎样的相互作用方式，而不是反过来。所以能量比力更根本。这不是说在牛顿力学里用能量算题比用力算题更方便——这是说，能量在认识论上比力更接近物质运动的本来面目。力是投影，能量是结构。

我们已经知道，直角坐标系不是描述运动的唯一方式。一个质点在平面上运动，用极坐标 (ρ, θ) 更自然；一个刚体绕固定轴转动，用转角 ϕ 更简洁。牛顿第二定律换到别的坐标系，加速度的表达式会变得极其复杂。我们在推导极坐标下的加速度时已经尝到了这个苦头—— ρ 方向和 θ 方向的加速度都同时含有 ρ 和 θ 的项，推导繁琐，容易出错。

拉格朗日方程的价值在于：无论用什么坐标系，方程的形式始终不变。

我们不事先规定用什么坐标，而是把描述系统位形所需的最少独立参数统称为广义坐标，记作 $q_1, q_2, \dots, q_n$ 。单摆的摆角 θ 就是一个广义坐标，它比 (x, y) 更直接地描述系统的核心运动。三维空间中的一个自由质点， $n = 3$ ， q 可以是 (x, y, z) ，也可以是 (ρ, θ, z) ，或者球坐标 (r, θ, ϕ) 。两个质点用刚性轻杆连接，六个直角坐标受三个约束，独立参数只剩三个。

广义坐标与直角坐标之间的变换是 $\mathbf{r}_i = \mathbf{r}_i(q_1, \dots, q_n, t)$ 。通过链式法则把动能和势能都写成 q 和 $\dot{q}$ 的函数。动能 T 原来是 $\dot{\mathbf{r}}$ 的二次齐次函数，变换后一般变成 $\dot{q}$ 的二次函数，但系数可能依赖于 q ；势能 V 通过坐标变换成为 q 的函数。然后对牛顿方程做坐标变换——纯粹的数学操作，没有任何新的物理假设——就得到：

$$\frac{d}{dt} \left(\frac{\partial L}{\partial \dot{q}_k} \right) - \frac{\partial L}{\partial q_k} = 0, \quad k = 1, 2, \dots, n$$

其中 $L(q, \dot{q}, t) = T(q, \dot{q}, t) - V(q, t)$ 。这就是广义坐标下的拉格朗日方程。运动规律本身不依赖于描述它的坐标系。坐标系是人类为了方便而选择的工具。同一个物理实在，在不同的描述方式中呈现出不同的面貌，而拉格朗日方程的形式不变性恰恰揭示了那个独立于描述方式的实在本身——不是力在某个特定坐标系里的分量，而是一个标量函数 L 的数学结构。一个物理系统的全部运动信息，被压缩在 L 这个单一的标量函数中。这不是方便的缩写，这是对实在的更直接的把握——因为它不再经过力和加速度的中介，不再依赖坐标系的任意选择。

更深一层，拉格朗日方程把“力”这个概念藏了起来。方程里不出现 F ，只出现动能 T 和势能 V ——两个标量，两个能量函数。力是人为构造的概念，是相互作用在特定描述框架中的表示方式。认识推进到拉格朗日方程的层次，我们就不再需要通过力这个中介去理解运动了。运动的全部信息已经被编码在能量的结构里：动能编码了运动的状态，势能编码了相互作用的整体约束，拉格朗日量将二者统一在一个标量函数中。认识的焦点从“谁推了谁”转移到了“系统整体处于什么样的能量结构”。

现在，拉格朗日方程已经建立起来了。我们问一个反向的问题：这个方程能不能被理解为某种“极值条件”？如果能，那么费马原理在力学中就有了对应物——一条路径因为某个量取极值而被实际发生，而不是因为每个瞬间都服从力的平衡。

定义作用量：

$$S = \int_{t_1}^{t_2} L(q, \dot{q}, t) dt$$

这是拉格朗日量沿实际路径对时间的积分。现在考虑另一条路径：它和实际路径有同样的端点，但中间略有偏离。这种偏离不是物理上真实发生的，而是数学上为了寻找极值条件而引入的变分—— $\delta q_k(t)$ 表示对实际路径的微小扰动。端点固定： $\delta q_k(t_1) = \delta q_k(t_2) = 0$ 。作用量的变化是：

$$\delta S = \int_{t_1}^{t_2} \sum_k \left(\frac{\partial L}{\partial q_k} \delta q_k + \frac{\partial L}{\partial \dot{q}_k} \delta \dot{q}_k \right) dt$$

对第二项分部积分：

$$\int_{t_1}^{t_2} \frac{\partial L}{\partial \dot{q}_k} \delta \dot{q}_k dt = \left[\frac{\partial L}{\partial \dot{q}_k} \delta q_k \right]_{t_1}^{t_2} - \int_{t_1}^{t_2} \frac{d}{dt} \left(\frac{\partial L}{\partial \dot{q}_k} \right) \delta q_k dt$$

端点固定，边界项为零。于是：

$$\delta S = \int_{t_1}^{t_2} \sum_k \left[\frac{\partial L}{\partial q_k} - \frac{d}{dt} \left(\frac{\partial L}{\partial \dot{q}_k} \right) \right] \delta q_k dt$$

方括号里正是拉格朗日方程的左边。如果实际路径满足拉格朗日方程，方括号为零， $\delta S = 0$ 。反过来，如果对所有满足端点固定的变分都有 $\delta S = 0$ ，则方括号必须处处为零——正是拉格朗日方程。

所以，拉格朗日方程等价于作用量变分为零： $\delta S = 0$ 。实际发生的路径，满足作用量变分为零的条件。这不是“选中”——自然界没有意志。变分为零是一个数学筛选条件：在无穷多条满足端点约束的数学路径中，只有实际路径满足这个条件。它是实际路径的判别式，不是自然的目的。这就是作用量变分为零原理。它不是拉格朗日方程之外另搞一套的新假设，而是拉格朗日方程的整体等价形式——从牛顿力学的内部逻辑中生长出来的全局表述。

牛顿方程是微分方程，告诉你每一瞬间的局部关系：这一点的加速度由这一点的力决定。作用量变分为零原理是积分原理，看的是整条路径的全局性质：这条路径之所以被实际发生，不是因为每个局部都“听话”，而是因为整条路径的某个积分量变分为零。局部决定论和全局约束，在这里获得了统一的表达。二者不是互相排斥的——从牛顿方程可以推出作用量变分为零原理，从作用量变分为零原理也可以推出牛顿方程，数学上等价。但等价的形式有不同的启发价值：牛顿方程让你计算下一时刻的状态，作用量变分为零原理让你思考“为什么是这个路径而不是别的”。

费马原理说光满足光程极值的条件，作用量变分为零原理说质点满足作用量变分为零的条件。光程是几何量，只涉及空间；作用量是动力学量，涉及时间演化。这个差异不是次要的——空间和时间在力学中以这种方式耦合在一起，暗示着更深层的结构尚未被触及。但在经典力学的框架内，我们只需要承认这种耦合的存在。

还有一个问题必须诚实面对。作用量本身不是直接可测量的物理量——你能测量位置、速度、力，但无法直接测量一条路径的“作用量”。它是一个数学构造，一个从运动方程反推出来的泛函。这就提出了一个认识论问题：作用量变分为零原理是物理规律，还是仅仅是数学技巧？

历史给出了一个牛顿无法预见的回答。作用量变分为零原理比牛顿第二定律走得更远。它不仅适用于经典力学，还适用于电磁学、广义相对论、量子力学，甚至量子场论。在量子力学的路径积分表述中，传播振幅是所有

可能路径的贡献叠加，每条路径贡献一个相位 $e^{iS/\hbar}$ 。经典路径对应于相位变化最慢的点，即 $\delta S = 0$ 的条件。这不是说粒子“真的”同时走了所有路径，而是说量子振幅的计算需要遍历所有数学上的可能路径。路径积分是计算方法，不是物理图像。作用量通过量子力学的路径积分获得了物理后果，它的实在性不在于它本身能否被直接看到，而在于它参与了物质的运动方式，产生了可观测的效应。这是一种结构实在——它不直接出现在测量仪器的读数中，但它是使读数之间产生规律性关联的那个不变骨架。就像象棋的规则——你不能在棋盘上找到“规则”这颗棋子，但没有规则，每一步棋的移动就失去了意义。作用量就是物质运动的规则骨架，它不是物理世界之外的抽象物，而是物质世界自身运动的整体约束形式。

现在，我们从哲学的角度倒过来看刚才完成的全部推导。这种倒过来的看法，不是重复我们已经说过的东西，而是要揭示作用量变分为零原理自身蕴含的哲学结论。推导的顺序是从牛顿方程到拉格朗日量再到作用量变分条件。这个顺序本身就是认识运动的真实过程——从局部到整体，从微分到积分，从力的表述到能量的表述。但牛顿方程不是终极的。变分原理是比牛顿方程更根本的表述：它是积分形式的全局约束，不依赖于坐标系的选择；牛顿方程只是变分原理在特定坐标下的局部展开。前者是普遍的形式，后者是特殊的具体实现。

因为世界是物质的，物质世界的运动是有规律的，规律是可以被认识的。认识首先表现为方程——建立量与量之间的关系。这是可知性的最基本保证：任何物质系统，其运动可以被至少一个方程所描述。

但对于某些系统——其运动由内在结构完全决定，能量关系清晰，边界完整——其规律就可以表现为一个函数。这个函数就是作用量 S ：

$$S[q(t)] = \int_{t_1}^{t_2} L(q, \dot{q}, t) dt$$

L 是 S 的局部密度，不是独立于 S 存在的函数。输入一条路径，输出一个数。

对于这类函数，变分是成立的。实际路径为什么恰好使 S 的变分为零？这不是数学游戏。物质运动的规律性意味着确定性——给定初态和边界条件，运动只能如此、不能别样。在无数条可能路径中，实际路径必须被唯一地确定。变分为零恰好提供了这种确定的数学表达：它把实际路径从无穷多条可能路径中区分出来。不是数学定理强迫物质如此运动，而是物质运动的确定性要求一个把实际路径与可能路径区分开的数学条件，而变分为零恰好满足这个要求。

于是：实际路径是特殊的——在无穷多条可能路径中只有它实际发生。但实际发生的条件——变分为零——是普遍的。不管系统是什么，不管 S 的

具体形式如何，实际路径永远满足这个条件。路径不同，机制相同。这就是矛盾的特殊性寓于普遍性之中：每一个系统的运动规律是特殊的、不可替代的，但所有这些特殊规律都服从同一个形式条件——作用量的变分为零。普遍性不在特殊性之外，而是通过特殊性来实现自己。

变分为零的条件本身是空洞的——它只说变分必须为零，不说变分为零的路径长什么样。路径长什么样，由 S 的具体形式决定，而 S 的具体形式又由系统的具体物理条件决定。普遍性给出了形式，特殊性构成了内容。形式不能脱离内容而存在，内容也不能脱离形式而被认识。

前面从牛顿方程出发，得到 $L = T - V$ ， $S = \int L dt$ ，证明了 $\delta S = 0$ 等价于运动方程。这是上述普遍结构在牛顿力学中的具体实现。在牛顿力学中， S 的局部密度是拉格朗日量 L 。 L 不是先于 S 存在的独立实体，而是 S 的局部表现。牛顿力学不是这个结构的来源，而是它的一个实例。力是局部投影，能量是局部结构， S 是整体结构。从方程到函数，从局部到全局，这不是技术升级，而是认识层次的根本跃迁。

最后需要说明一个历史名词的问题。这个原理在历史上被称为“最小作用量原理”，但这个名称是不准确的。“最小”这个叫法来源于早期物理学家在特定例子中发现作用量确实取极小值，于是习惯性地推广了。但是数学上只要求变分为零（ $\delta S = 0$ ），并不要求作用量取极小值。实际路径对应的可能是极小值、极大值，甚至是鞍点。更重要的是，“最小”这个名称携带了目的论的残余。“最小”暗示自然有“优化”的倾向，有“经济”的偏好——这是把人的价值判断投射到自然界。自然界没有“偏好”，没有“目的”，只有规律。变分为零是一个数学条件，不是自然界的“选择标准”。所以我将其改名为“作用量变分为零原理”。我们在哲学讨论中使用的是变分为零的条件，不是“最小”这个额外的物理要求。

8.3 诺特定理

我们在 §3.2 节得到了三条守恒定律：动量守恒、角动量守恒、能量守恒。当时我们说，这三条定律不是牛顿定律的推论——它们比牛顿定律更普遍。我们还说，诺特定理会揭示它们的真正来源。

现在，我们终于走到了这一步。

我们先回顾一下三条守恒定律在什么条件下成立。动量守恒要求系统不受外力，或者合外力为零——这意味着系统具有空间平移对称性。角动量守恒要求系统不受外力矩——这意味着系统具有空间旋转对称性。能量守恒要求系统不受时间依赖的外力——这意味着系统具有时间平移对称性。

三条守恒律，三种对称性，一一对应。但这三个例子是孤立的巧合吗？如果只是巧合，物理学就太粗糙了。巧合可以被记住，但不能被理解。巧合可以被背诵，但不能被推演。如果守恒律仅仅是实验现象的归纳，那么每发现一个新的守恒量，物理学就得多记一条新规则。可物理学的历史告诉我们，守恒律不是越来越多，而是越来越少——三个不同的守恒量，被三个不同的对称性收进同一个结构。这个结构就是诺特定理。

我们先从拉格朗日量本身出发，看看它能告诉我们什么。考虑一个一般系统，广义坐标 $q_1, \dots, q_n$ ，拉格朗日量 $L(q, \dot{q}, t)$ 。已知欧拉-拉格朗日方程

$$\frac{d}{dt} \frac{\partial L}{\partial \dot{q}_i} - \frac{\partial L}{\partial q_i} = 0 \quad (i = 1, 2, \dots, n).$$

定义广义动量 $p_i = \frac{\partial L}{\partial \dot{q}_i}$ ，则方程可写为 $\dot{p}_i = \frac{\partial L}{\partial q_i}$ 。

对 $L(q, \dot{q}, t)$ 求全导数：

$$\frac{dL}{dt} = \sum_k \left(\frac{\partial L}{\partial q_k} \dot{q}_k + \frac{\partial L}{\partial \dot{q}_k} \ddot{q}_k \right) + \frac{\partial L}{\partial t}.$$

利用欧拉-拉格朗日方程 $\frac{\partial L}{\partial q_k} = \frac{d}{dt} \frac{\partial L}{\partial \dot{q}_k} = \dot{p}_k$ ，代入得

$$\frac{dL}{dt} = \sum_k (\dot{p}_k \dot{q}_k + p_k \ddot{q}_k) + \frac{\partial L}{\partial t}.$$

注意到 $\dot{p}_k \dot{q}_k + p_k \ddot{q}_k = \frac{d}{dt}(p_k \dot{q}_k)$ ，因此

$$\frac{dL}{dt} = \frac{d}{dt} \sum_k p_k \dot{q}_k + \frac{\partial L}{\partial t}.$$

整理得

$$-\frac{\partial L}{\partial t} = \frac{d}{dt} \left(\sum_k p_k \dot{q}_k - L \right).$$

定义哈密顿量 $H = \sum_k p_k \dot{q}_k - L$, 则

$$\frac{dH}{dt} = -\frac{\partial L}{\partial t}.$$

若 $\frac{\partial L}{\partial t} = 0$, 即拉格朗日量不显含时间, 则 $\frac{dH}{dt} = 0$, H 为常量。对于封闭系统 $L = T - V$, 其中 T 为广义动能, V 为广义势能。动能是广义速度的二次齐次函数, 由欧拉齐次函数定理, $\sum_k \frac{\partial T}{\partial \dot{q}_k} \dot{q}_k = 2T$, 而 $p_k = \frac{\partial L}{\partial \dot{q}_k} = \frac{\partial T}{\partial \dot{q}_k}$, 因此

$$H = \sum_k p_k \dot{q}_k - L = 2T - (T - V) = T + V = E,$$

即总能量守恒。这就是能量守恒的拉格朗日表述。

再看动量。由欧拉-拉格朗日方程直接可得

$$\frac{\partial L}{\partial q_i} = \frac{d}{dt} \frac{\partial L}{\partial \dot{q}_i} = \dot{p}_i.$$

若 $\frac{\partial L}{\partial q_i} = 0$, 即拉格朗日量不显含某个广义坐标 q_i (该坐标称为循环坐标), 则 $\dot{p}_i = 0$, p_i 为常量。对所有这样的坐标, 向量

$$\vec{p} = \left(\frac{\partial L}{\partial \dot{q}_1}, \frac{\partial L}{\partial \dot{q}_2}, \dots, \frac{\partial L}{\partial \dot{q}_n} \right)$$

的对应分量为常量, 这就是动量守恒。

最后看角动量。若某个广义坐标是角度量 θ_α , 且 $\frac{\partial L}{\partial \theta_\alpha} = 0$, 即拉格朗日量不显含该角度坐标, 则

$$\frac{\partial L}{\partial \dot{\theta}_\alpha} = L_\alpha$$

为常量。向量 $\vec{L}_\alpha$ 为常向量, 这就是角动量守恒。

三个守恒律, 各自从拉格朗日量的对称性中独立推导出来。但它们共享同一个结构——每一个都对应着拉格朗日量对某种坐标变换的不变性。这个共性需要被提取出来。

现在我们把它们收进同一个框架。假设存在一个连续变换, 依赖于一个连续参数 ϵ :

$$q_k \rightarrow q_k + \epsilon \psi_k$$

其中 ψ_k 是变换的生成元, ϵ 是无穷小参数。在此变换下, $\delta q_k = \epsilon \psi_k$, $\delta \dot{q}_k = \epsilon \dot{\psi}_k$ 。假设作用量 $S = \int_{t_1}^{t_2} L dt$ 在此变换下不变——允许拉格朗日量改变一个全导数项 $\epsilon \frac{dF}{dt}$ 。

对作用量直接变分:

$$\delta S = \int_{t_1}^{t_2} \delta L dt = \int_{t_1}^{t_2} \sum_k \left(\frac{\partial L}{\partial q_k} \delta q_k + \frac{\partial L}{\partial \dot{q}_k} \delta \dot{q}_k \right) dt = \int_{t_1}^{t_2} \epsilon \sum_k \left(\frac{\partial L}{\partial q_k} \psi_k + \frac{\partial L}{\partial \dot{q}_k} \dot{\psi}_k \right) dt.$$

利用欧拉-拉格朗日方程 $\frac{\partial L}{\partial q_k} = \dot{p}_k$, 代入得

$$\delta S = \epsilon \int_{t_1}^{t_2} \sum_k (\dot{p}_k \psi_k + p_k \dot{\psi}_k) dt = \epsilon \int_{t_1}^{t_2} \frac{d}{dt} \left(\sum_k p_k \psi_k \right) dt = \epsilon \left[\sum_k p_k \psi_k \right]_{t_1}^{t_2}.$$

另一方面, 由作用量不变条件 $\delta L = \epsilon \frac{dF}{dt}$, 有

$$\delta S = \int_{t_1}^{t_2} \epsilon \frac{dF}{dt} dt = \epsilon [F]_{t_1}^{t_2} = \epsilon (F|_{t_2} - F|_{t_1}).$$

由 $\delta S = 0$ 知

$$\sum_k p_k \psi_k \Big|_{t_1} = \sum_k p_k \psi_k \Big|_{t_2}.$$

要使 $\delta S = 0$ 在任意时刻恒成立, 令 $t_2 \rightarrow t_1$, 则被积函数必须为零:

$$\frac{d}{dt} \left(\sum_k p_k \psi_k \right) = \epsilon \frac{dF}{dt},$$

即

$$\frac{d}{dt} \left(\sum_k p_k \psi_k - F \right) = 0.$$

方括号里的量不随时间变化——它就是对称性对应的守恒量。这就是诺特定理的整体形式: 每一个连续对称性, 都对应一个守恒量。

现在用整体形式验证三个特例。

时间平移: $t \rightarrow t + \epsilon$, 坐标被动变化, $\psi_k = -\dot{q}_k$, $F = L$ 。守恒量为

$$\sum_k p_k (-\dot{q}_k) - L = - \left(\sum_k p_k \dot{q}_k - L \right) = -H,$$

即哈密顿量 H 守恒, 对封闭系统就是总能量 E 。

空间平移: $x \rightarrow x + \epsilon$, $\psi_x = 1$, 其余 $\psi_k = 0$, $F = 0$ 。守恒量为

$$\sum_k p_k \psi_k = p_x,$$

即动量守恒。

绕 z 轴转动: $\theta \rightarrow \theta + \epsilon$, $\psi_\theta = 1$, 其余为零, $F = 0$ 。守恒量为

$$p_\theta = \frac{\partial L}{\partial \dot{\theta}} = mr^2 \dot{\theta} = L_z,$$

即角动量守恒。

三个例子, 同一个公式, 全部收进来。时间对称性 $\Leftrightarrow$ 能量守恒; 空间对称性 $\Leftrightarrow$ 动量守恒; 旋转对称性 $\Leftrightarrow$ 角动量守恒。

现在回答那个一直悬而未决的问题: 为什么偏偏是动量、角动量、能量守恒? 为什么不是“某个其他量”?

因为对称性的结构只允许这些量存在。平移变换的参数是位移, 与它耦合的守恒量只能是广义动量。旋转变换的参数是角度, 与它耦合的守恒量只能是角动量。时间平移的参数是时间间隔, 与它耦合的守恒量只能是能量。

这不是“碰巧”。动量、角动量、能量不是我们先验定义好的概念, 然后发现它们碰巧守恒。它们是诺特定理从对称性中构造出来的概念。没有空间平移对称性, 就没有动量这个量; 没有旋转对称性, 就没有角动量这个量; 没有时间平移对称性, 就没有能量这个量。

诺特定理不是一条关于物质世界必然具有什么对称性的定理。它不保证任何系统都具有空间平移对称性, 也不保证任何系统都具有时间平移对称性。它所陈述的关系是条件性的: 如果作用量具有某种连续对称性, 那么就必然对应一个守恒量。至于这个“如果”是否成立, 由具体的物质系统决定, 不由诺特定理决定。

有没有对称性, 物质世界说了算。

Part IX

哈密顿力学

9.1 从拉格朗日到哈密顿

拉格朗日方程给出了广义坐标下的运动规律，但它仍然是在位形空间中描述运动——系统的状态由 n 个广义坐标和 n 个广义速度共同确定。在拉格朗日力学中， q 和 $\dot{q}$ 在形式上是彼此独立的变量，偏导数 $\partial L/\partial q$ 和 $\partial L/\partial \dot{q}$ 正是在这个意义上取的。但拉格朗日量对二者的依赖方式不同：动能依赖于 $\dot{q}$ ，势能依赖于 q 。运动方程是二阶微分方程，坐标和速度以不对称的方式出现在方程中。

但如果我们换一个角度看问题，这种不对称性可能只是描述方式造成的，而不是运动状态本身的结构。一个质点的运动状态，真的需要“位置”和“速度”这两个不同性质的量来描述吗？还是说，它们只是同一个实在的两个侧面，只是我们选择了不同的坐标基来展开？

现在，我们来考虑一个具体的力学系统。一个质点在保守力场中运动，动能是速度的二次函数，势能是位置的函数。拉格朗日量 $L = T - V$ 把这两种能量组合在一起，但它对坐标的依赖是通过势能，对速度的依赖是通过动能。这种组合方式在数学上很有效，但它掩盖了一个事实：位置和速度在描述运动状态时，本质上应该是等价的。

为了看清这种等价性，我们尝试一个不同的数学操作。拉格朗日量是广义坐标、广义速度和时间的函数，即 $L(q, \dot{q}, t)$ 。它的全微分可以写成：

$$dL = \sum_k \frac{\partial L}{\partial q_k} dq_k + \sum_k \frac{\partial L}{\partial \dot{q}_k} d\dot{q}_k + \frac{\partial L}{\partial t} dt.$$

我们已经定义了广义动量 $p_k = \frac{\partial L}{\partial \dot{q}_k}$ ，而拉格朗日方程

$$\frac{d}{dt} \frac{\partial L}{\partial \dot{q}_k} - \frac{\partial L}{\partial q_k} = 0$$

告诉我们 $\dot{p}_k = \frac{\partial L}{\partial q_k}$ 。代入后得到：

$$dL = \sum_k \dot{p}_k dq_k + \sum_k p_k d\dot{q}_k + \frac{\partial L}{\partial t} dt.$$

现在，我们想把描述的重点从“坐标和速度”转移到“坐标和动量”上来。为此，我们对右边的第二项做一个数学处理。 $p_k d\dot{q}_k$ 可以写成 $d(p_k \dot{q}_k) - \dot{q}_k dp_k$ ，这是微分乘积法则的反向运用。代入后：

$$dL = \sum_k \dot{p}_k dq_k + \sum_k d(p_k \dot{q}_k) - \sum_k \dot{q}_k dp_k + \frac{\partial L}{\partial t} dt.$$

把全微分项移到左边：

$$d \left(\sum_k p_k \dot{q}_k - L \right) = - \sum_k \dot{p}_k dq_k + \sum_k \dot{q}_k dp_k - \frac{\partial L}{\partial t} dt.$$

左边可以合并成一个全微分：

$$d\left(\sum_k p_k \dot{q}_k - L\right) = dH.$$

定义一个新的函数 $H(q, p, t) = \sum_k p_k \dot{q}_k - L$ ，那么：

$$dH = -\sum_k \dot{p}_k dq_k + \sum_k \dot{q}_k dp_k - \frac{\partial L}{\partial t} dt.$$

这个式子的右边是 H 作为 q, p, t 的函数的全微分展开：

$$dH = \sum_k \frac{\partial H}{\partial q_k} dq_k + \sum_k \frac{\partial H}{\partial p_k} dp_k + \frac{\partial H}{\partial t} dt.$$

由于 dq_k 、 dp_k 、 dt 是相空间中的独立变量，比较两边的系数，我们直接得到：

$$\dot{q}_k = \frac{\partial H}{\partial p_k}, \quad \dot{p}_k = -\frac{\partial H}{\partial q_k}, \quad \frac{\partial H}{\partial t} = -\frac{\partial L}{\partial t}.$$

前两个方程就是哈密顿正则方程。它们与拉格朗日方程完全等价，但描述方式发生了根本转变：现在坐标和动量处于完全对称的地位，它们通过哈密顿量 H 相互联系、相互规定。坐标不再是主导，动量也不再是派生；它们是一对平行的变量，共同构成对运动状态的完整描述。

这种对称性不是数学游戏。速度和动量在牛顿力学中通过 $p = mv$ 联系起来，但这种联系只是特定条件下的表现。一方面，在拉格朗日力学中，动量 $p = \partial L / \partial \dot{q}$ 的定义本身就不依赖 $p = mv$ 这个特殊关系，因此“动量”在拉格朗日框架中已经是比“速度”更一般的概念。另一方面，相空间的辛结构只涉及 q 和 p ，不涉及 $\dot{q}$ ；如果把描述建立在 $(q, \dot{q})$ 上，辛结构就不自然。在更一般的情形下——比如相对论力学，或者带电粒子在电磁场中的运动——动量和速度的关系会变得更加复杂，但“坐标和动量”的描述方式依然成立。这反映了物理实在的一个深层结构：运动状态本身不是“位置和速度”，而是“位置和动量”。哈密顿力学提前揭示了这种普遍性，它为后来物理学的发展预留了空间。（在量子力学中，位置和动量通过正则对易关系 $[q, p] = i\hbar$ 联系，而速度和位置的关系依赖于哈密顿量的具体形式，这进一步说明了 q 和 p 的配对在更深层的理论中占据了核心地位。）

正则方程的右边是 H 的偏导数，这提示我们 H 可能具有能量的意义。对于一个封闭系统，如果约束不显含时间，动能是广义速度的二次齐次函数，根据欧拉齐次函数定理， $\sum_k \frac{\partial T}{\partial \dot{q}_k} \dot{q}_k = 2T$ 。因此：

$$H = \sum_k p_k \dot{q}_k - L = 2T - (T - V) = T + V = E.$$

此时 H 就是系统的总能量，且由 $\partial H / \partial t = -\partial L / \partial t = 0$ 可知，哈密顿量不随时间变化。但这里有一个重要的限定：这个结论依赖于动能是广义速度的二

次齐次函数。如果约束显含时间，动能中会出现 $\dot{q}$ 的一次项甚至零次项，欧拉齐次函数定理的结论不再成立， H 可能不再是总能量。如果系统处于非保守力场中， H 甚至可能显含时间。这提醒我们，哈密顿量 H 和总能量 E 虽然在很多情况下数值相等，但概念上并不相同。 H 是由系统的动力学结构决定的函数，而 E 是物理实在的能量。二者的关系需要具体分析，不能想当然地画等号。

从拉格朗日力学到哈密顿力学，认识经历了一次重要的跃迁。拉格朗日量 L 是坐标、速度和时间的函数，它描述的是系统在位形空间中的运动规律。哈密顿量 H 是坐标、动量和时间的函数，它描述的是系统在相空间中的运动规律。位形空间是 n 维的，相空间是 $2n$ 维的。维度的增加不仅是复杂化，而且是认识的深化——它让我们看到了坐标和动量之间的内在对称性，看到了运动状态的真正结构。这种深化在更高层次上带来了简洁性：正则方程是一阶方程组，形式对称，而拉格朗日方程是二阶的，形式不对称。更重要的是，相空间的 $2n$ 维不是简单的“坐标翻倍”，而是引入了新的几何结构——辛结构。这个结构在位形空间中不存在。相空间不是“更大的位形空间”，而是不同性质的空间：位形空间只有坐标，相空间有坐标和动量，后者通过辛形式相互耦合。这个区别是质的区别，不是量的区别。

这种转变也体现了描述方式的辩证发展。在牛顿力学中，力是核心概念，运动方程是 $F = ma$ ，加速度是力的直接响应。在拉格朗日力学中，力被能量取代，运动方程从能量结构中推导出来。在哈密顿力学中，能量本身成为描述的核心，但这里的能量不再是标量函数 E ，而是生成运动规律的哈密顿量 H 。 H 不仅包含能量信息，还通过其偏导数直接生成运动方程。认识从“力”到“能量”再到“生成结构”，每一步都抛掉了不必要的具体性，更接近物质运动的抽象本质。

但抽象不能脱离具体。正则方程虽然形式简洁，但求解它们并不总是比求解拉格朗日方程更容易。对于简单的系统，牛顿力学可能更直接；对于复杂的系统，拉格朗日方程可能更方便。哈密顿力学的优势在于它揭示了运动的深层结构——坐标和动量的对称性、相空间的几何性质、以及后来将看到的泊松括号代数。这些结构在经典力学中可能只是“方便的形式”，但在量子力学中它们成为了理论的核心。哈密顿力学因此成为连接经典和量子的桥梁，它的重要性在二十世纪才真正显现出来。

现在，我们从另一个角度审视刚才的数学操作。我们把 $p_k d\dot{q}_k$ 改写成 $d(p_k \dot{q}_k) - \dot{q}_k dp_k$ ，这在数学上只是乘积法则的反向运用。但这个操作在物理上意味着什么呢？它意味着我们主动改变了描述的重点。拉格朗日量 L 对速度的依赖，被转化为哈密顿量 H 对动量的依赖。这种转化不是被动的坐标变换，而是主动的视角转换。我们从“位形空间中的运动”转向“相空间中的演化”，

从“坐标如何随时间变化”转向“状态和共轭量如何相互规定”。

这种视角转换的合法性，依赖于数学结构本身的对称性。如果运动规律在本质上就不区分坐标和动量，那么选择哪一种描述方式就是自由的。正则方程正是这种自由选择的体现：我们可以用 q 和 $\dot{q}$ 描述运动，也可以用 q 和 p 描述运动，二者在数学上等价，在物理上同样有效。但不同的选择会揭示不同的结构，带来不同的启发。哈密顿力学的价值，不在于它“更正确”，而在于它“更深刻”——它让我们看到了拉格朗日力学看不到的对称性和几何结构。这种对称性的精确表述将在正则变换中给出，而由此产生的代数结构——泊松括号——将在下一节展开。

从拉格朗日量到哈密顿量的转变，是从“函数”到“生成元”的跃迁。拉格朗日量是一个函数，它通过欧拉-拉格朗日方程生成运动规律。哈密顿量也是一个函数，但它通过正则方程直接生成运动方程。更重要的是，哈密顿量在正则方程中扮演的角色，暗示了它是时间演化的生成元——相空间中的每一点代表一个运动状态，正则方程给出该点处的“速度”，所有点的速度拼成一个向量场，向量场的积分曲线就是运动轨迹。哈密顿量 H 就是这个向量场的生成函数。这一事实将在 9.3 节泊松括号中精确表述，并与诺特定理中“时间平移对称性对应能量守恒”的结论深刻呼应。从函数到生成元，从方程到代数，认识在不断抽象化的过程中，把握到了物质运动更普遍的结构。

这种抽象化不是远离实际，而是更深入地把握实际。正则方程在形式上的对称性，反映了物理实在的对称性。坐标和动量的平等地位，不是数学家的发明，而是自然界本身的属性。当我们用 q 和 p 描述运动时，我们并没有改变物理实在，我们只是选择了更贴近实在本来面目的描述方式。认识不是主观对客观的简单反映，而是在实践基础上对客观规律的能动把握。哈密顿力学比拉格朗日力学更深刻，不是因为它更“聪明”，而是因为它更真实地反映了物质运动的结构。

当然，这种深刻性是有代价的。哈密顿力学的数学形式更抽象，离日常经验更远。一个工程师设计机械系统时，可能更愿意用牛顿力学或拉格朗日力学，因为它们更直接地对应于可测量的物理量。但一个理论物理学家探索基本规律时，哈密顿力学提供了不可或缺的工具。这种分工不是理论的缺陷，而是理论丰富性的体现。同一个物理实在，可以在不同的描述层次上呈现出不同的面貌，每一种描述都有其适用范围和价值。

从拉格朗日方程到正则方程，数学上只是一步之遥，认识上却是一次飞跃。我们把运动状态从“坐标和速度”重新理解为“坐标和动量”，把运动规律从二阶微分方程重新理解为一阶方程组，把描述空间从位形空间扩展到相空间。每一步都让我们离物质运动的本质更近一步，同时也为更深入的

理论发展开辟了道路。正则方程因此不仅是经典力学的终点，也是量子力学的起点——但那是后话，我们现在只需要把握它自身的结构和意义。

最后需要指出，从拉格朗日量到哈密顿量的变换，在数学上具有深刻的普遍性。热力学中从内能到焓、从亥姆霍兹自由能到吉布斯自由能的变换，与这里的变换共享同一个结构——把某个变量换成它的共轭量，把函数换成它的变换。这种跨领域的结构统一性，正是普遍性寓于特殊性之中的具体体现。哈密顿力学不是孤立的形式技巧，而是这一普遍数学结构在力学中的特殊实现。

9.2 泊松括号与正则变换

上一节末了，我们说泊松括号要到这一节展开，也顺手落下了“代数结构”四个字，但没来得及讲清它到底指什么。这里我们就来补上。不过在补之前，得先弄明白我们究竟要回答一个什么样的问题。

先从一件再平常不过的事说起。如果不考虑阻力，秋千荡到最高点，速度为零，动能全变成了势能；荡到最低点，速度最大，势能又全变成了动能。来回之间，两种能量此消彼长，谁也不让谁，可它们的总和始终不变。能量守恒，我们从小就信，也早就拿它解题。但请你注意一个问题：我们是怎么知道它守恒的？

最笨的办法是把运动解出来，把能量代进去，发现它是常数。可这是实践以后的感性认识——解完了才宣布“你看，它不变”。真正的理性认识要的是能够指导实践的判断：给定一个系统，不求解，直接说出哪个量保持不变，哪个量要变。牛顿力学没有这种捷径；拉格朗日力学给了一半，叫循环坐标；上一节的正则方程给了另一半。这一节我们把两半合起来，答案的结构就露出来了。

不过在动手之前，有一件事得先交代清楚。上一节我们把 $L(q, \dot{q}, t)$ 换成 $H(q, p, t)$ ，把速度换成了动量。这个换法还有一个更一般的情形：要是拉格朗日量除了依赖坐标、速度、时间，还依赖一个从外面输入的参数 u ——比如一个可调节的外场——那么照做一遍同样的换法，会多挤出一条关系： $(\partial H / \partial u)_{p, q} = -(\partial L / \partial u)_{q, \dot{q}}$ 。同一个外部参数，在拉格朗日图像里通过 L 起作用，在哈密顿图像里通过 H 起作用，两个作用恰好一正一反。这说明 L 和 H 不是各说各话的两个函数，而是同一个实在在两组变量下的两种写法；正因为有这层一一对应，后面才有资格说“换变量”而不丢信息。先把它放在这儿。

现在进入正题。任意一个力学量 $f(q, p, t)$ ，问它随时间怎么变，直接求导，再代入正则方程，会冒出一个反复出现的组合。我们给它起个名字，把任意两个力学量 f 、 g 的泊松括号定义为

$$\{f, g\} = \sum_k \left(\frac{\partial f}{\partial q_k} \frac{\partial g}{\partial p_k} - \frac{\partial f}{\partial p_k} \frac{\partial g}{\partial q_k} \right).$$

这个记号不是凭空捏造的，它是从“力学量如何随时间变化”这个问题里产生出来的。有了它，任意力学量的时间演化就写成清清爽爽的一行：

$$\frac{df}{dt} = \frac{\partial f}{\partial t} + \{f, H\}.$$

答案一下子清楚了。一个不显含时间的量，只要它跟哈密顿量的括号是零，它就不变；括号不是零，它就要变，而且变的快慢正好由括号给出。不求解、

不验算，只算一个括号，就知道一个量守不守恒。这就是事前判断的捷径。回到那架秋千，它的机械能 E 对封闭系统正好就是 H ，而任何量跟自己的括号恒为零，于是能量守恒在括号的语言里就成了一个自明的事实——这恰恰是对开头那个问题最干脆的回答。

顺手把 f 依次取成 q_k 和 p_k ，就得到 $\dot{q}_k = \{q_k, H\}$ 、 $\dot{p}_k = \{p_k, H\}$ ——上一节那对正则方程，原来也是这同一个括号公式的特例。正则方程被括号吸收了。

括号最基本的性质，先看它作用在坐标和动量上是什么样子： $\{q_i, q_j\} = 0$ ， $\{p_i, p_j\} = 0$ ，而 $\{q_i, p_j\} = \delta_{ij}$ 。第三个式子尤其要记住：坐标和它自己的共轭动量，括号等于1。这个“1”眼下不解它，先揣在心里——到第十一部分，它会换一副完全不同的身份重新登场。

这个括号有几条基本的代数性质。第一条，反对称： $\{f, g\} = -\{g, f\}$ 。 f 对 g 的作用和 g 对 f 的作用，大小相等、方向相反，像作用力和反作用力；特别地，任何量跟自己括起来都是零，一个常数跟谁括也都是零——常数既不驱动别人，也不被别人驱动。第二条，它跟普通求导一样，对乘积满足分配律： $\{f_1 f_2, g\} = f_1 \{f_2, g\} + f_2 \{f_1, g\}$ 。这暗示括号骨子里也是一种求导运算，只不过求的不是空间，而是相空间里的方向。第三条，也是最要紧的一条，叫雅可比恒等式： $\{f, \{g, h\}\} + \{g, \{h, f\}\} + \{h, \{f, g\}\} = 0$ 。前两条一眼就懂，这一条要算，繁琐但直接。它的意思很深：括号的括号，仍按括号的规矩闭合，不产生任何新东西——这套运算规则在自身内部就是封闭的、自洽的。上一节我们说的“代数结构”，指的正是这几条性质合起来的这个整体。后来到了量子力学，这一条成了对易关系绕不过去的硬性要求。

性质摆完，一个漂亮的推论就自然得出了。设想 f 和 g 都是守恒量，问：它们的括号 $\{f, g\}$ 是不是守恒量？我们把 $\{f, g\}$ 作为一个整体代入时间演化公式：

$$\frac{d}{dt}\{f, g\} = \{\{f, g\}, H\}.$$

又由雅可比恒等式可得

$$\{f, \{g, H\}\} + \{g, \{H, f\}\} + \{H, \{f, g\}\} = 0.$$

已知 f 、 g 都是守恒量，即 $\{f, H\} = 0$ 、 $\{g, H\} = 0$ ，代入上式即有 $\{H, \{f, g\}\} = 0$ ，于是 $\frac{d}{dt}\{f, g\} = 0$ 。还真是。两个守恒量的泊松括号，仍然是个守恒量。这就是泊松定理。

它的意义要好好琢磨。它说的是：守恒量能生成新的守恒量。每找到一个守恒量，把它和手里已有的两两相括，往往又能括出新的来——有时意外收获一批从没想到过的守恒量，有时括来括去只是在老面孔之间打转。这提醒我们，一个系统的守恒量不是散在地上的零钱，而是一个由括号串起来的

家族；家族有多大，直接反映系统对称性有多丰富。泊松定理让我们不必一个个去发现守恒量，而是成批地、按这套代数规则去生成它们。守恒与对称的互生，在这条定理里第一次落到了实处。

说到这儿，得把守恒的含义再往深挖一层。 $\{f, H\} = 0$ 意味着 f 不随时间变，这是看得见的一面。还有一面看不见： f 自己也能生成一个变换——把 f 当成一个假想的哈密顿量，用它驱动一个假想的演化 $\frac{dq}{d\lambda} = \{q, f\}$ 、 $\frac{dp}{d\lambda} = \{p, f\}$ ，参数 λ 一路推进，相空间里的点就沿着 f 规定的方向流动。于是 $\{f, H\} = 0$ 就有了第二种读法： H 沿着 f 规定的方向保持不变。换句话说， f 生成的是一个不改变 H 的变换—— f 是某个对称性的生成元。

两种读法合起来，是一个完整的圆圈。诺特定理说：对称性给出守恒量。现在泊松括号给出反方向：守恒量生成对称性。不是先有对称性后有守恒量，也不是反过来；它们是同一个结构的两种读法，互为对方的存在方式。守恒就是不变，不变就是对称，这两个词在相空间里是同一件事。回到那架秋千：它的能量守恒落到括号语言里，对应的是时间平移对称性——能量正是时间演化的生成元，把秋千往后推一个小时再荡，它的摆法一模一样。我们开头看见的那个“总和不变”，和诺特定理里那条守恒律，原来写的是同一句话。

接下来是这一节的另一半：正则变换。为什么还要变换？因为坐标系是人选的，选它的标准只有一个——方便。单摆用角度，行星用极坐标，都只为让方程清爽。但我们真正想要的，不是让旧方程顺眼一点，而是找一族新坐标，让运动规律最深的结构自己露出来。这得回到更根本的地方。

我们从作用量说起。前面我们已经建立了作用量和作用量变分为零原理，那时我们让路径的起点和终点都固定，得到的是拉格朗日方程。现在放松一个要求：起点固定，终点可以挪动一点点。也就是说，我们在看这么一批真实运动的轨道——同一起点出发，只因初速度的细微差别，落在不同的终点。对这样的变分， $\delta q(t_1) = 0$ ，而 $\delta q(t_2)$ 不为零。把作用量的变分做出来，实际轨道上积分项因为满足拉格朗日方程而消失，剩下的只有终点那一项： $\delta S = p \delta q$ 。也就是说，作用量对终点坐标的偏导数，正是动量： $\partial S / \partial q = p$ 。

这个小小的等式，是两个世界的接口。它告诉我们，作用量本身就可以看成终点位置（和时间）的函数——哈密顿叫它“主函数”，记作 $S(q, t)$ 。把它对时间求全导，再用上 $L = \sum_i p_i \dot{q}_i - H$ ，一整理，就撞见 $H + \partial S / \partial t = 0$ 。这就是哈密顿-雅可比方程，后面 9.3 我们还要专门回去看它。眼下只取它附带的一条情报：综合 $p = \partial S / \partial q$ 和 $H + \partial S / \partial t = 0$ ，主函数的全微分是 $dS = \sum_k p_k dq_k - H dt$ 。

这个式子，就是正则变换的根。寻找新坐标，本质是寻找一个函数，把旧的坐标 q 和新的动量 P （或新的坐标 Q ）不丢信息地衔接起来。上面这条

全微分提醒我们，这样的衔接函数是存在的，主函数就是一个实例。推广到一般，我们不局限于“时间演化”这一种变换，而是允许任意一个既能容纳旧变量、又能容纳新变量的函数，管它叫母函数。最常用的一类母函数 $F(q, Q, t)$ ，令 $p_k = \partial F / \partial q_k$ 、 $P_k = -\partial F / \partial Q_k$ ，就能生成一个正则变换，新哈密顿量 $K = H + \partial F / \partial t$ 。这里不展开所有类型，原理就一句话：正则变换不是随便换变量，而是通过母函数、在保住括号结构的前提下换变量。结构先行，坐标随后。所谓“保住括号结构”，指的是新变量也必须满足与旧变量完全相同的基本括号关系，即

$$\{Q_i, Q_j\} = 0, \quad \{P_i, P_j\} = 0, \quad \{Q_i, P_j\} = \delta_{ij}.$$

这是正则变换区别于任意坐标变换的标志。（除了这里展开的 $F(q, Q, t)$ ，还有 $F(q, P, t)$ 、 $F(p, Q, t)$ 、 $F(p, P, t)$ 等类型，它们通过勒让德变换相互联系，原理相同，不再赘述。）

现在我们停下来，从整体上看看我们做成了什么。

泊松括号是一个纯粹的结构。它不携带任何具体的力，不描述任何具体的系统，却规定了所有系统共有的演化方式。牛顿力学里，我们问“谁推了谁”；拉格朗日力学里，我们问“系统的能量结构是什么”；到了泊松括号，我们问“运动规律的语法是什么”。力是投影，能量是结构，括号是语法。三步下来，认识离具体的相互作用越来越远，离物质运动的普遍形式越来越近。这不是脱离实际，而是更深地把握实际——因为不管什么力学系统，只要它有坐标和动量、服从正则方程，它就会说这门语法。

这门语法的核心是守恒与对称的互生。守恒量不是孤立的好运气，对称性也不是静止的装饰品；守恒量生成对称变换，对称性必然产出守恒量，二者互为对方的存在方式。泊松定理又把孤立的守恒量连成一个家族，让它们按这套代数规则互相生成。回头再看那三条守恒定律：动量、角动量、能量，不再是三个各自为政的经验事实，而是同一个代数结构在三种对称性下的三个投影。普遍性寓于特殊性之中，特殊性通过普遍性获得意义。

还有一层不能不提。 $\{q_k, p_k\} = 1$ 这个式子，今天看只是个平凡的括号值；可二十世纪的人们发现，把这个括号换成算符的对易关系，再除以 $i\hbar$ ，量子力学就从里面长出来了。泊松括号是经典力学为量子力学预留的语法，正则方程是连接两个世界的桥，括号是桥上刻的字。经典力学在自己的框架里把话说到头，剩下的半句，要等量子力学来接。不过那是第十一部分的事，眼下只需记住：这里写下的每一个括号，都同时是经典世界的终章和量子世界的序言。

从拉格朗日量到哈密顿量，从哈密顿量到泊松括号，从泊松括号到正则变换，认识走了一条不断抽象而又不断深入的路。每一次抽象都不是对具体内容的抛弃，而是把具体内容提升为结构。这就是扬弃。具体系统千差万别，

结构却有能知晓的规律：正是这可知的规律，让千差万别的系统能够被统一地理解。开头那架秋千，和一切守恒现象一样，最终都归结到这同一个结构上来。这就是泊松括号教给我们的：最深处的统一，不在物质的表面现象里，而在运动的普遍形式里。

9.3 哈密顿-雅可比方程和刘维尔定理

我们现在去池塘边站一会儿。

往平静的水面扔一颗石子，波纹一圈圈荡开。每一圈始终是圆的，只是半径越来越大；圈上的每一点，都朝着垂直于圈的方向往外走。这是再平常不过的景象。可是请想一想：要描述这一池水此刻的状态，我们并没有去追踪任何一个水分子，而是用一族同心圆就交代完了。一族曲线，把整片水面规定得清清楚楚。这个念头先放在心里，待会儿要回来找它。

这里要处理的，其实是经典力学从开篇起就悬着的一个问题。从牛顿到拉格朗日到哈密顿，我们始终在做同一件事：解运动方程。可是“解出来”这三个字，究竟是什么意思？给一组初值，算出一条轨道；换一组初值，从头再算一遍。每问一次，答一条。这是常微分方程天生的本领，也是它的局限——它的解是一条曲线，永远只能一条一条地给。有没有可能反过来，不给定初值，而是一次找到一个函数，把整个空间里所有可能的运动、所有时刻、所有初值，全都组织在一个框架里？要一次性把握全体，就得换一个层次的对象。哈密顿-雅可比方程干的就是这件事。它不是在旧办法旁边再添一种技巧，而是把问题整个换了个问法。

那么，这个函数从哪儿来？我们手里现成的、跟运动有关的量，只有一个——作用量 S 。但到今天为止，它一直是一条轨道的积分，是“轨道”的属性，还不是“空间”的属性。要把一个数变成一张网，只有一个办法：让作用量的终点动起来。

我们现在来试试。对作用量 $S = \int_{t_1}^{t_2} L dt$ 做变分，先固定时间端点：

$$\delta S = \int_{t_1}^{t_2} \left(\frac{\partial L}{\partial q} \delta q + \frac{\partial L}{\partial \dot{q}} \delta \dot{q} \right) dt.$$

第二项里， $\delta \dot{q} = \frac{d}{dt} \delta q$ 。要把变分从导数的背上卸下来，加一项又减一项 $\frac{d}{dt} \left(\frac{\partial L}{\partial \dot{q}} \right) \delta q$ ：

$$\delta S = \int_{t_1}^{t_2} \left[\frac{\partial L}{\partial q} \delta q + \frac{\partial L}{\partial \dot{q}} \frac{d}{dt} \delta q + \frac{d}{dt} \left(\frac{\partial L}{\partial \dot{q}} \right) \delta q - \frac{d}{dt} \left(\frac{\partial L}{\partial \dot{q}} \right) \delta q \right] dt.$$

中间三项并成一个乘积的全导数：

$$\delta S = \frac{\partial L}{\partial \dot{q}} \delta q \Big|_{t_1}^{t_2} + \int_{t_1}^{t_2} \left[\frac{\partial L}{\partial q} - \frac{d}{dt} \left(\frac{\partial L}{\partial \dot{q}} \right) \right] \delta q dt.$$

接下来的事，跟之前不一样。前面的推导里我们让起点和终点都固定，得到的是拉格朗日方程；现在只固定起点， $\delta q(t_1) = 0$ ，让终点可以挪动一点点， $\delta q(t_2) \neq 0$ 。不过我们考察的仍然全是真实运动的轨道——它们从同一点出发，只因初速度的细微差别，落在不同的终点。真实运动满足拉格朗日方程，

积分号里的方括号恒为零，整个积分项消失，只剩终点那一项。推广到多个坐标，注意到 $\partial L/\partial \dot{q}_i = p_i$ ：

$$\delta S = \sum_i p_i \delta q_i.$$

这一步的必要性，值得停下来多说一句。做这件事之前，作用量 S 只是某一条轨道上积出来的一个数；做完之后，它随终点位置变化，成了一个定义在空间上的函数。从数到函数，这是质的区别。也只有成了函数，它才可能承担“铺满全空间”的任务。于是

$$\frac{\partial S}{\partial q_i} = p_i.$$

作用量对终点坐标的偏导数，正是动量。这个式子小得不起眼，却是后面一切的地基。

既然 S 现在是函数，就该写出它的全微分。哈密顿称这个函数为主函数，仍记作 $S(q, t)$ 。对时间求全导，链式法则，代入刚得到的 $\partial S/\partial q_i = p_i$ ：

$$\frac{dS}{dt} = \frac{\partial S}{\partial t} + \sum_i \frac{\partial S}{\partial q_i} \dot{q}_i = \frac{\partial S}{\partial t} + \sum_i p_i \dot{q}_i.$$

另一方面，沿真实轨道，作用量对时间的导数就是拉格朗日量， $dS/dt = L$ 。两相对照，移项：

$$\frac{\partial S}{\partial t} = L - \sum_i p_i \dot{q}_i = -H.$$

把动量全部换成 $p_i = \partial S/\partial q_i$ 代进 H ，最终得到：

$$\frac{\partial S}{\partial t} + H\left(q_1, \dots, q_n, \frac{\partial S}{\partial q_1}, \dots, \frac{\partial S}{\partial q_n}, t\right) = 0.$$

这就是哈密顿-雅可比方程。

请仔细看它的身份。原来我们有 n 个二阶常微分方程，现在只剩一个方程，却是一阶偏微分方程。更有意思的是，未知函数 S 自身并不出现，出现的全是它的偏导数——所以若 S 是解， S 加任意常数还是解，方程永远只能把 S 定到相差一个常数为止。它的解必然是一族，而不是一个。方程个数从 n 降到1，类型却从常微分升到偏微分。这不是单方面的简化，而是矛盾形式的转化：把“逐条积分轨道”的困难，转移成了“整体构造一个函数”的困难。前者我们熟门熟路，后者却藏着全新的结构——这个结构，马上就要自己显形。

先看它的几何面貌。若 H 不显含时间，令

$$S(q, t) = W(q) - Et,$$

代进方程, E 作为分离常数出现, 得到 $H(q, \partial W / \partial q) = E$ 。这个 E 正是能量, W 称为哈密顿特征函数。固定某一时刻, 看位形空间中满足 $W(q) = \text{常数}$ 的那些曲面——一族等作用量面。动量 $p = \nabla W$ 处处垂直于这些面; 对于动能是速度二次型的通常系统, 动量与速度同向, 所以质点轨道处处垂直于等作用量面。轨道, 是这族曲面的法线族。

现在让我们回到池塘边上。波纹的每一圈是一个等相位面, 波沿垂直于波前的方向推进; 质点沿垂直于等作用量面的方向运动。波纹用一族圆描述整片水面, 作用量用一族曲面描述整个位形空间; 波前是场, 轨道是它的法线。水波和质点, 共用同一幅几何图像。

这不是修辞。前面讲几何光学的时候, 我们见过一模一样的东西: 光线处处垂直于波前, 费马原理和惠更斯原理说的是同一件事的两面。在那里我们论证过, 光之所以走光程取极值的路径, 是因为波前上每一点的次波在极值路径附近相位变化最慢、相干叠加最强——那是波动干涉的客观结果, 不是光有意志。现在这一幕在力学里原样重演: 等作用量面对应波前, 轨道对应光线, 作用量的梯度对应波矢方向, 约化作用量 $\int \sum_i p_i dq_i$ 对应光程, 作用量变分为零原理对应费马原理。历史上, 哈密顿本人正是从光线系统的研究出发, 把光学这套语言搬进力学的——他先在光学里建立了特征函数理论, 随后发现力学可以完全套用同一个框架。光的传播和质点的运动, 在更深的结构上本是同一种东西的两种表现。

方程有了, 几何图像也有了。但在讲怎么解之前, 得先把前面悬着的一个关节补上, 否则整个理论就吊在半空。我们曾摆出过母函数关系 $p_k = \partial F / \partial q_k$ 、 $P_k = -\partial F / \partial Q_k$, 却始终没交代它从哪儿来。现在补上。

问一个具体的问题: 从旧变量 (q, p) 换到新变量 (Q, P) , 什么样的变换才能让新变量也保持正则方程的形式, 即 $\dot{Q}_i = \partial H' / \partial P_i$ 、 $\dot{P}_i = -\partial H' / \partial Q_i$? 要回答它, 得回到分析力学里面已经确立的一个事实: 运动方程等价于作用量变分为零。新旧两套变量描述的必须是同一个物理系统, 所以新变量下的变分原理 $\delta \int (\sum_i P_i dQ_i - H' dt) = 0$ 和旧变量下的 $\delta \int (\sum_i p_i dq_i - H dt) = 0$ 必须给出同样的真实轨道。两个积分若相差一个全微分, 它们在固定端点的变分只差边界项, 结果完全相同。在通常的物理条件下可以证明, 两套作用量若要给出完全相同的运动方程, 它们的被积函数至多相差一个全微分。于是正则变换的条件是

$$\sum_i p_i dq_i - H dt = \sum_i P_i dQ_i - H' dt + dF,$$

其中 F 是任意函数, 称为这个变换的母函数。移项:

$$dF = \sum_i p_i dq_i - \sum_i P_i dQ_i + (H' - H) dt.$$

把 F 看成旧坐标和新坐标的函数 $F(q, Q, t)$, 这个全微分直接给出

$$p_i = \frac{\partial F}{\partial q_i}, \quad P_i = -\frac{\partial F}{\partial Q_i}, \quad H' = H + \frac{\partial F}{\partial t}.$$

那几条似乎凭空出现的母函数关系, 根子就在这里: 它不是人为规定, 而是“两套作用量变分为零原理必须相容”这一客观要求的产物。 Q 、 P 称为正则共轭变量; 可以验证, 泊松括号在新旧变量下算出来完全相同, $\{f, g\}_{P, Q} = \{f, g\}_{p, q}$ ——括号不因描述方式而改变。这就是所谓“结构先行”的含义。

回头再看作用量 S : 它的全微分 $dS = \sum_i p_i dq_i - H dt$ 正是这类式子中 $H' = 0$ 的特例。换句话说, 哈密顿-雅可比理论的核心, 就是用作用量这个最彻底的母函数, 把运动变换成静止。这是理解下面一切的一把钥匙。

现在讲怎么解, 这个问题由雅可比来回答。既然方程只能把 S 定到相差一个常数为止, 它的解必然是一族。取一组常数 $\alpha_1, \dots, \alpha_n$, 使 $S(q, \alpha, t)$ 成为完全积分——即 S 含有 n 个独立的常数 α_i , 且 $\det(\partial^2 S / \partial q_i \partial \alpha_j) \neq 0$ 。这个非退化条件保证了 $\partial S / \partial \alpha_k = \beta_k$ 能解出 $q_k(t)$ 。雅可比证明: 完全积分一到手, 运动问题就整个解决了。把 S 对每个 α_k 求偏导, 令其等于另一组常数 β_k :

$$\frac{\partial S}{\partial \alpha_k} = \beta_k,$$

这 n 个式子正是轨道方程。

这里 α_k 扮演的是新动量的角色, β_k 扮演的是新坐标的角色。主函数 S 生成一个正则变换, 把旧坐标变换成一组不随时间变化的常数——在新坐标系里, 系统纹丝不动。9.2里我们说, 正则变换的目标是让坐标变循环、让守恒量浮出来; 雅可比定理把这一步走到了尽头: 找到完全积分, 就等于找到了一组坐标, 在它们当中运动彻底消失。原来运动方程的全部内容——所有初值、所有轨道——被一个函数 S 整个儿装了进去。最彻底的母函数, 就是作用量本身。

拿一维谐振子试一遍。 $H = p^2/2m + kx^2/2$, 令 $S = W(x) - Et$, 方程是

$$\frac{1}{2m} \left(\frac{dW}{dx} \right)^2 + \frac{1}{2} kx^2 = E,$$

直接解出

$$W(x) = \int \sqrt{2mE - mkx^2} dx.$$

W 里已经含着一个可调常数 E 。对于一维系统而言, 一个独立常数就足以构成完全积分。严格说, $S = W - Et$ 才是这个问题的完全积分, 而 W 是它的哈密顿特征函数。按雅可比的规则, 把 S 对 E 求偏导, 令其等于另一个常数 β :

$$t + \beta = \int \frac{m dx}{\sqrt{2mE - mkx^2}}.$$

积分一算，正是 $x = \sqrt{2E/k} \sin(\omega t + \phi)$ 。前面我们用二阶常微分方程解出的简谐振动，在这里只做了一次积分，就从完全不同的路径重新走了出来，还顺手把全部初值条件下的所有运动一次装进了 W 。两条路殊途同归，而新的这条路看得更远。

不过这里要诚实。能走通分离变量的系统是少数。谐振子、开普勒问题、陀螺这些“可解”的漂亮系统，恰恰是因为对称性足、守恒量多；每分离出一个坐标，背后就站着一个守恒量——分离常数 E 和各坐标对应的常数，全都是守恒量。这条线索跟诺特定理接得上：对称性给出守恒量，守恒量给出可分离的坐标，可分离的坐标把方程拆散。可反过来，一般系统做不到这一点。庞加莱早就证明，绝大多数力学系统连 n 个独立的守恒量都凑不齐，谈不上分离变量，它们的运动里藏着混沌。讲统计规律时我们见过同样的格局：个别分子不可预言，大量分子的集体却服从稳定的分布。这里也一样：个别轨道可能混沌，哈密顿-雅可比方程描画的那个场的骨架却依然成立。一个理论知道自己的适用范围，比假装万能更接近真理。

还有一个结构性的结果必须交代。它本来可以放在前面讲，但它的根基在哈密顿-雅可比框架里才看得最清楚。刘维尔定理：哈密顿流保持相空间的体积元不变。设 $2n$ 维相空间中的体积元

$$d\Gamma = dq_1 \cdots dq_n dp_1 \cdots dp_n.$$

把相空间中的演化看成一种流动，速度场是 $\vec{v} = (\dot{q}, \dot{p})$ 。这个流场的散度是

$$\nabla \cdot \vec{v} = \sum_i \left(\frac{\partial \dot{q}_i}{\partial q_i} + \frac{\partial \dot{p}_i}{\partial p_i} \right).$$

代入正则方程 $\dot{q}_i = \partial H / \partial p_i$ 、 $\dot{p}_i = -\partial H / \partial q_i$ ：

$$\nabla \cdot \vec{v} = \sum_i \left(\frac{\partial^2 H}{\partial q_i \partial p_i} - \frac{\partial^2 H}{\partial p_i \partial q_i} \right) = 0.$$

两项恰好相等，散度恒为零；而散度为零的流场不改变体积。于是 $d\Gamma$ 不随运动改变——相空间不可压缩。哈密顿流把相空间里的一块区域带着走，形状可以任意扭曲、拉伸、折叠，体积却一丝不差。

这个性质在工程上不是空话。卫星轨道的长期数值预报，为什么轨道力学偏爱哈密顿框架下的数值算法？因为普通的数值算法每算一步都悄悄漏掉一点能量，十年二十年积下来，轨道就漂了；而建立在相体积守恒结构上的算法，把这种漂移压到极低。算不准的轨道不是数学错了，是结构没保住。再往远看，前面讲分子分布律时，相空间里那些统计假设的合法性，根基就在这里——正是相体积守恒，才让“在等体积的相空间元里状态出现的机会均等”这种假设有了客观依据。一个看似抽象的几何性质，一头连着卫星的轨道，一头撑着热学的大厦。

一圈波纹，一颗行星的轨道，一台陀螺的进动，竟然共用同一幅几何图像。这只能说明一件事：运动的普遍形式是客观存在的，它以不同的面貌出现在不同的物质系统里。波纹是圆的，不是水有意志；轨道垂直于等作用量面，不是质点做了选择。数学没有发明这个普遍形式，只是把它呈现出来。哈密顿-雅可比理论把“求解轨道”的问题转化成了“构造函数”的问题，把力学写成了波动的语言；经典力学走到这一步，已经把它自己框架内能说的话都说尽了。而说尽了的地方，正是新话语开始的地方——波前图像里已经埋着波，轨道图像里已经埋着量子。那扇虚掩的门，在后面等着我们。